Vision embarquée sur drone

État de l'art établi à partir du corpus PaperDatabase (base `drone`)

Léonard Rivals

29 septembre 2026 — brouillon

Résumé

Ce document fait l'état de l'art de la vision par réseaux de neurones embarquée sur drone. Il couvre les jeux de données, la détection de petits objets, les accélérateurs embarqués (FPGA, MCU, ASIC, neuromorphique), le suivi et la navigation, le contre-drone et le co-design entre calcul, énergie et vol. Il s'appuie sur les 73 fiches de lecture et les 324 lignes de mesures d'une base de 73 articles. Chaque chiffre porte sa source, et chaque puissance sa portée. Quatre constats en ressortent. D'abord, les YOLO spécialisés drone (tête P2, Transformer, attention) ne sont mesurés que sur GPU de bureau, alors que les implantations FPGA du corpus restent sur YOLOv3-tiny, YOLOv4 ou YOLOX, parfois amputés de leur branche multi-échelle. Ensuite, aucune des 324 lignes ne rapporte de précision par taille d'objet (AP_S) : l'effet de la quantification sur les petits objets n'est pas mesuré. Troisième constat : les trois gammes de puissance (nano en mW, FPGA en W, Jetson autour de 10 W) ne sont presque jamais comparées sur une même tâche, et 69 % des lignes n'ont pas de puissance. Enfin, les modèles qui relient latence, masse et vitesse de vol sûre existent (MAVBench, modèle F-1), mais aucun n'a été appliqué à un détecteur sur FPGA. En contre-drone, le cas embarqué (air → air, détecteur sur un intercepteur) n'a aucun coût mesuré sur SoC. Le document termine sur les gaps et trois questions de thèse candidates.

Table des matières

1 Introduction **2**

2 Méthode et conventions **3**

3 Jeux de données et challenges **4**

3.1 Détection vue du drone : VisDrone et UAVDT 4

3.2 Détection sous contrainte d'énergie : le DAC-SDC 4

3.3 Contre-drone : des jeux surtout sol → air 5

4 Détection de petits objets vus de drone **5**

4.1 La recette dominante : tête P2, attention, suppression de P5 5

4.2 Calculer seulement où sont les objets 7

4.3 Protocoles et comparabilité 7

5 Détection sur FPGA et SoC embarqués **7**

5.1 Le DAC-SDC : cinq ans de co-design sur un petit Zynq 7

5.2 YOLO sur SoC : DPU Vitis AI et dataflow 8

5.3 Surveys FPGA 10

6 Gamme nano : MCU, ASIC et neuromorphique **10**
6.1 Le GAP8 et la lignée PULP 10
6.2 ASIC et neuromorphique 11
6.3 Ce que la gamme nano apprend au reste 12

7 Suivi et navigation embarqués **12**
7.1 Suivi mono-objet sur Jetson 12
7.2 Vol agile : la référence Jetson de Zurich 12
7.3 Localisation et plateformes hétérogènes 13

8 Contre-drone : détecter des drones **13**
8.1 Sol → air : des références de contraste 13
8.2 Air → air : le cas embarqué 13
8.3 Bilan 14

9 Co-design calcul, énergie et vol **14**
9.1 Le calcul agit sur la mission par le temps et la masse 14
9.2 Fiabilité du calcul embarqué 15

10 Comparer les gammes de puissance **15**
10.1 Débit et puissance rapportés 15
10.2 Les rares comparaisons à modèle égal 16
10.3 Ordres de grandeur par gamme 17
10.4 Couverture du corpus 17

11 Zones non couvertes et pistes de recherche **17**
11.1 Trois gaps structurants 18
11.2 Questions de thèse candidates 19

12 Conclusion **19**

1 Introduction

Un drone impose au calcul embarqué des contraintes que les benchmarks de vision ignorent : la masse et la puissance du calculateur se paient en autonomie et en agilité, la latence de perception borne la vitesse de vol sûre, et les objets à détecter occupent souvent une infime fraction de l'image. Trois gammes de calcul coexistent : les nano-drones de quelques dizaines de grammes, avec des MCU parallèles comme le GAP8 (mW) ; les SoC FPGA (quelques W) ; les modules Jetson (autour de 10 W), qui équipent les drones agiles de moins d'un kilogramme.

Ce document répond à trois questions, à partir du corpus seulement :

— quels jeux de données et quels détecteurs font l'état de l'art de la vision depuis un drone, et à quel coût (sections 3 et 4) ?
— que sait-on exécuter à bord, dans chaque gamme de puissance, pour la détection, le suivi et la navigation (sections 5 à 8) ?
— comment relier ces chiffres à la mission du drone, et que reste-t-il à faire (sections 9 à 11) ?

La base `fpga` du même projet traite à part les toolflows, les autoencodeurs et l'apprentissage continu sur FPGA ; ils ne sont repris ici que lorsqu'un article porte sur le drone.

2 Méthode et conventions

Corpus. Ce document ne s'appuie que sur la base `drone` de PaperDatabase telle qu'elle était le 29 septembre 2026 : 73 articles, tous dotés d'une fiche de lecture complète, et 324 lignes de mesures dans `benchmarks.csv`, issues de 58 articles. Aucune référence extérieure à la base n'est citée comme source. Les travaux cités par un survey sont signalés comme tels ; leurs chiffres ne sont pas vérifiés à la source et servent à orienter la lecture, pas à comparer.

TABLE 1 – Composition du corpus. Un article peut relever de plusieurs axes.

Axe	Articles	Axe	Articles
Détection drone, petits objets	29	Nano-drones, MCU, ASIC, neuromorphique	16
Suivi et navigation	27	Accélération FPGA / SoC	14
Contre-drone	17	Co-design calcul–énergie–vol	14
Jeux de données et challenges	15	Surveys	7
		Fiabilité du calcul embarqué	2

Types : 30 articles de journal, 7 de conférence, 36 preprints arXiv (dont plusieurs publiés depuis, voir le texte).
Années : 2016–2020 : 14 ; 2021–2023 : 38 ; 2024–2026 : 21.

Origine des chiffres. Chaque valeur est reprise de la fiche ou de `benchmarks.csv`, avec la section ou le tableau de l'article entre crochets, par exemple [Table 4]. Une valeur que les auteurs ne donnent pas s'écrit `n/r` : elle n'est jamais estimée. Un calcul fait à partir des chiffres publiés (par exemple un FPS/W) est marqué *(déduit)*. Sur les 324 lignes, 176 sont en confiance *high* et 148 en *medium* : valeurs lues dans le texte qui commente une figure, ou tableaux reconstruits automatiquement. Ces dernières sont marquées ^{m} dans les tableaux. Aucune ligne n'est en confiance *low*.

Portée de la puissance. Une puissance n'a de sens qu'avec sa portée. La base distingue *board* (carte entière, au wattmètre), *chip* (rails de la puce ou télémétrie embarquée comme `tegrastats`), *estimated* (outil de conception, par exemple Vivado) et *unspecified* (méthode non décrite). Sur les 324 lignes, 222 n'ont pas de puissance (69 %) ; les autres se répartissent en 51 *board*, 20 *chip*, 29 *unspecified* et 2 *estimated*. Deux puissances de portées différentes ne se comparent pas.

Gamme de puissance. Tout résultat est situé dans une gamme : *nano* (GAP8, MCU, ASIC ; de quelques mW à quelques centaines de mW), *FPGA* (SoC Zynq ou Kria, de 1 à 30 W selon la carte), *Jetson* (autour de 10 W, de 5 à 30 W selon le module et le mode). Les résultats sur GPU de bureau (RTX, Titan, Tesla) sont signalés comme tels : ils ne sont jamais des résultats embarqués, quoi qu'en dise leur titre.

Métriques de précision. Elles ne se comparent qu'à protocole égal. L'IoU moyen mono-objet du DAC-SDC n'est pas une mAP ; la mAP@0.5 de VisDrone n'est pas l'AP COCO [.5 :.95] du protocole officiel ; l'AP d'UAVDT est calculée à IoU 0,7 dans l'article d'origine ; certains travaux de contre-drone évaluent à IoU 0,1 ou 0,25.

Contre-drone : point de vue du capteur. Chaque article de contre-drone est classé *air* → *air* (détecteur à bord d'un drone), *sol* → *air* (capteur fixe au sol) ou point de vue non déclaré. Seul

le premier relève de l'IA embarquée ; les autres sont cités comme jeux de données, métriques ou contrastes.

Lu contre déduit. Sauf mention, une affirmation résume ce que disent les auteurs. Une inférence de la fiche ou de ce document est marquée *(déduit)*. Un article marqué [PP] est un preprint non relu par les pairs dans la version ingérée ; quand une version publiée existe probablement, le texte le dit.

Limites de la méthode. Le corpus est petit et vient d'une bibliographie de départ constituée à partir de résumés. Il compte peu d'articles FPGA propres au drone (10 papiers mesurés sur FPGA) et seulement deux sur la fiabilité. Un « gap » signifie qu'un sujet est absent *de ce corpus* ; son absence de la littérature reste une hypothèse tant qu'une recherche ciblée ne l'a pas confirmée. Les fiches ont été rédigées à partir du texte extrait des PDF : les valeurs données seulement dans des figures sont souvent `n/r`.

3 Jeux de données et challenges

3.1 Détection vue du drone : VisDrone et UAVDT

VisDrone. Zhu et al. (2020)[PP] résument trois éditions du challenge (2018–2020). Le jeu compte 263 clips (179 264 images) et 10 209 images fixes, plus de 2,5 millions de boîtes sur 10 catégories, prises par des DJI dans 14 villes chinoises, jusqu'à 2000×1500 en image fixe [§1]. La tâche DET se découpe en 6 471 / 548 / 1 580 / 1 610 images (train / val / test-challenge / test-dev) [§4.1] et suit le protocole AP COCO. Le meilleur résultat de 2020, DroneEye2020 (Cascade R-CNN + DetectoRS), atteint 34,57 d'AP [Table 2] ; le meilleur détecteur reste sous 25 % sur *person* et *bicycle* [§4.5]. Les auteurs reconnaissent que les soumissions privilégient la précision sur l'efficacité : les méthodes vidéo tournent à moins de 10 FPS sur une GTX 1080Ti [§5.3, §8]. Le §8 formule d'ailleurs le problème de la thèse : les ressources d'un drone rendent impossible le déploiement de gros modèles.

UAVDT. Du et al. (2018)[PP] (version ECCV 2018 probable, non vérifiée) proposent 100 séquences urbaines à 1080×540, environ 80 000 images annotées et 0,84 M de boîtes de véhicules, avec des attributs d'altitude, de vue et de météo [§2.1]. 27,5 % des objets font moins de 400 pixels [§4]. Le meilleur détecteur (R-FCN) obtient 34,35 % d'AP, mais à un seuil d'IoU de 0,7 [§3.1] : ces chiffres ne se comparent pas aux AP@0.5 publiés ensuite sur UAVDT. L'attribut altitude relie directement la précision à un paramètre de vol *(déduit)*.

3.2 Détection sous contrainte d'énergie : le DAC-SDC

Le Low Power Object Detection Challenge du DAC est le seul contexte du corpus où la précision, le débit et l'énergie sont mesurés par un tiers selon un protocole commun, sur plateforme imposée. Xu et al. (2021) décrivent l'édition 2018 : images DJI 640×360, un seul objet par image, la plupart occupant 1 à 2 % de l'image ; plateformes PYNQ-Z1 et Jetson TX2 ; énergie mesurée au wattmètre pour le FPGA [§2]. Zhang et al. (2024) étendent l'analyse aux éditions 2018–2022 (PYNQ-Z1 puis Ultra96) et en tirent des règles de co-design (section 5).

Deux réserves pèsent sur toute réutilisation. La métrique est un IoU moyen sans classe sur un objet unique, qui ne se compare pas à une mAP multi-classe (Zhang et al., 2024, §2.3). Et la règle de mesure change : à partir de 2022, le temps ne compte plus le chargement des images [§2.3], ce qui explique une partie du saut de débit de cette édition.

3.3 Contre-drone : des jeux surtout sol → air

Le tableau 2 classe les jeux du corpus par point de vue. Le constat est net : les grands jeux (Anti-UAV, Anti-UAV410, Drone-vs-Bird, DUT Anti-UAV) sont pris depuis le sol ou ne déclarent pas le capteur ; les jeux air → air sont petits et récents. Aucun ne comporte de piste « efficacité » (FPS, puissance, plateforme) : le survey de Ding et al. (2025)[PP] le relève lui-même [§V-A].

TABLE 2 – Jeux de contre-drone du corpus, par point de vue du capteur.

Jeu, article	Point de vue	Contenu	Métrique
Det-Fly (Zheng et al., 2021)	air → air	13 271 images 4K, un DJI Mavic filmé par un M210, 10–100 m ; public [§III]	AP
NPS-Drones, FL-Drones, ré-annotés (Ashraf et al., 2021)[PP]	air → air	50 et 14 vidéos ; cibles de 0,05 et 0,07 % de l'image [§1]	AP, F1
ARD-MAV (Guo et al., 2023)[PP]	air → air	60 vidéos 1920×1080, 106 665 images, cibles de 0,02 % de l'image en moyenne [Table I]	AP50
Anti2 (Gao et al., 2024)	mixte	5 062 images, 4 classes (drone, oiseau, hélicoptère, avion) [§3]	mAP@0.5
Anti-UAV (Jiang et al., 2021)[PP]	non déclaré (sol probable)	318 paires RGB–IR non alignées, cibles < 40 px [Table I]	mSA
Anti-UAV410 (Huang et al., 2024)	non déclaré (sol probable)	410 séquences IR, plus de 100 à drone < 10 px [§III]	SA
MAV-VID, Drone-vs-Bird (Isaac-Medina et al., 2021)[PP]	surtout sol → air	64 et 77 vidéos ; Drone-vs-Bird : cibles de 0,10 % [§3.1]	AP50
Halmstad (Svanstrom et al., 2020)	sol → air	650 vidéos IR + visible, 90 clips audio ; public [§IV]	F1

Suivi vu du drone. WebUAV-3M (Zhang et al., 2022)[PP] compte 4 500 vidéos et 3,3 M d'images issues surtout de YouTube [§3.2]. Il évalue 43 trackers sur GPU de bureau et montre que la précision s'effondre sous 30 pixels de cible [§5.6].

Ce que les jeux ne mesurent pas. Aucun des grands benchmarks du corpus (VisDrone, UAVDT, Anti-UAV, Anti-UAV410, WebUAV-3M, Det-Fly) ne rapporte de débit sur plateforme embarquée ni de puissance. Seul le DAC-SDC le fait, au prix d'une tâche simplifiée. Les AP par taille d'objet sont rares même dans les jeux dédiés aux petits objets : VisDrone ne publie pas d'AP_S séparé dans ses tableaux de synthèse (Zhu et al., 2020, §4).

4 Détection de petits objets vus de drone

4.1 La recette dominante : tête P2, attention, suppression de P5

Les YOLO spécialisés drone du corpus modifient tous la pyramide de caractéristiques pour les petits objets. Trois gestes reviennent : ajouter une tête P2 (stride 4, carte de 160×160 pour une entrée de 640), ajouter de l'attention ou des blocs Transformer, et supprimer la tête P5, qui porte beaucoup de paramètres mais sert surtout aux grands objets.

TPH-YOLOv5 et TPH-YOLOv5++. TPH-YOLOv5 (Zhu et al., 2021)[PP] est la référence de cette famille : YOLOv5x, quatrième tête P2, têtes à Transformer, CBAM, test multi-échelle et ensemble de cinq modèles. L'ensemble atteint 39,18 de mAP [.5 :.95] sur le test-challenge VisDrone

2021 [§4.2]^{m}, sur RTX 3090, sans aucune vitesse rapportée. La tête P2 fait passer YOLOv5x de 219 à 259 GFLOPs [§4.3]. Zhao et al. (2023) mesurent ce coût : la tête P2 seule apporte +2,1 points d'AP, fait passer la mémoire GPU de 4 279 à 4 667 Mo et le débit de 13,68 à 10,89 FPS [Table 5]. TPH-YOLOv5++ remplace la tête P2 par un transfert d'information vers P3 (CA-Trans) et remonte à 11,86 FPS pour 33,1 d'AP sur test-dev, contre 7,36 FPS et 34,0 pour TPH-YOLOv5 [Table 5] ; toujours sur RTX 3090 Ti, à 1536×1536.

Variantes légères. Le tableau 3 rassemble les autres variantes. Toutes allègent le réseau en paramètres ; aucune ne mesure son coût sur une cible embarquée, sauf Drone-YOLO.

TABLE 3 – YOLO spécialisés drone du corpus, sur VisDrone. Plateformes de bureau sauf mention. Protocoles hétérogènes (split, résolution, métrique) : la colonne précision ne permet pas de classer.

Modèle	Modification principale	Précision	Coût, plateforme
GCL-YOLO-S (Cao et al., 2023)	GhostConv, P2 ajoutée, P5 retirée ; 1,64 M param.	39,6 mAP50 [Table 3]	53 FPS, GPU n/r
Efficient YOLOv7-Drone (Fu et al., 2023)	P2, P5 retirée, convolution creuse guidée par le premier plan	32,1 AP (val, 640) [Table 2]	89 FPS contre 213 pour YOLOv7, RTX 3090 [Table 5]
Drone-YOLO nano (Zhang, 2023)	P2, sandwich-fusion, RepVGG ; 3,05 M param.	38,1 mAP50 (val) [Table 5]	127,4 ms sur Jetson TX2 [Table 6]
SF-YOLOv5 (Liu et al., 2022)	P5 retirée, PB-FPN ; 2,23 M param.	34,3 mAP50^{m} [Table 4]	11,5 ms, RTX 2060
DroneScan-YOLO (Bellec, 2026)^{PP}	entrée 1280, branche P2, pruning non structuré	55,3 mAP50 (val) [Table 4]	96,7 FPS, RTX 4090 portable
YOLO-Drone (Jung, 2025)	GhostConv dans la tête de YOLOv11n	30,4 mAP50 [Table 2]	1,8 ms, Tesla T4
DEAL-YOLO (Naidu et al., 2025)^{PP}	P2 à la place de P5, NWD ; faune (hors VisDrone)	48,5 mAP50, BuckTales [Table 1]	`n/r`

Ce que coûte la tête P2. Trois articles donnent un chiffre. Drone-YOLO nano met 127,4 ms par image sur Jetson TX2, contre 30,8 ms pour YOLOv8n à nombre de paramètres égal, soit quatre fois plus lent pour +4,1 points de mAP50 (Zhang, 2023, Table 6) ; l'auteur conclut pourtant à des résultats « highly accurate » sans commenter la latence. Pour Efficient YOLOv7-Drone, ajouter P2 fait tomber le débit de 212,8 à 137,0 FPS sur RTX 3090 (Fu et al., 2023, Table 5). GCL-YOLO-S perd 7 FPS face à YOLOv5-S alors que ses GFLOPs baissent (Cao et al., 2023, Table 3, §5). Le coût de P2 est donc un coût d'activations et d'accès mémoire, que les FLOPs et le nombre de paramètres ne voient pas *(déduit)*. Sur un FPGA, où les activations d'une carte 160×160 doivent tenir en mémoire on-chip, c'est précisément ce coût qui domine *(déduit)*.

Paramètres et FLOPs ne prédisent pas la latence. Le constat revient dans cinq articles. SF-YOLOv5 retire 68 % des paramètres pour 7 % de latence en moins (Liu et al., 2022, Table 3). SlimYOLOv3 (Zhang et al., 2019a)^{PP} (version ICCVW 2019 probable) retire 90,8 % des FLOPs de YOLOv3-SPP3 par élagage de canaux pour 49,5 % de temps en moins sur GTX 1080 Ti [§5], et reste plus lent que YOLOv3-tiny à FLOPs comparables. F-YOLOv7 divise les FLOPs par 2,8 sans gain de débit sur RTX 4090 (Du et al., 2025, Table 2). DroneScan-YOLO reconnaît que son pruning non structuré ne retire aucun paramètre et n'accélère rien sur matériel embarqué (Bellec, 2026, §5). YOLO-GCOF, annoncé pour Raspberry Pi 4B, ne donne que des GFLOPs (Yu and Mo, 2025, §IV-D8). Tous ces résultats sont sur GPU de bureau : sur FPGA, NPU ou MCU, l'effet peut s'inverser (GhostConv et depthwise sont souvent mal servis par un DPU) *(déduit)*.

4.2 Calculer seulement où sont les objets

Une deuxième famille garde un détecteur à résolution modeste et concentre le calcul sur les régions utiles.

— **Tuilage** : SAHI (Akyon et al., 2022)[PP] (publié à ICIP 2022 d'après son DOI) découpe l'image en tuiles 640×640. Avec fine-tuning sur tuiles, TOOD passe de 29,4 à 43,5 d'AP50 sur VisDrone test-dev, et son $AP50_S$ de 18,1 à 31,7 [Table 1]. Le coût, linéaire en nombre de tuiles [§5], n'est pas mesuré.

— **Régions denses** : ClusDet (Yang et al., 2019)[PP] détecte des groupes d'objets puis les traite à part ; il atteint 26,7 d'AP et 17,6 d'AP_S en R-50 [Table 1], mais met 0,273 s par image sur GTX 1080 Ti, cinq fois plus que la baseline sans découpage. UFPMP-Det (Huang et al., 2021)[PP] assemble les régions en une mosaïque unique et atteint 36,6 d'AP en R-50 sur VisDrone val, pour 0,152 s par image [Tables 1, 3].

— **Requêtes éparses** : QueryDet (Yang et al., 2021)[PP] ne calcule la tête haute résolution qu'aux positions désignées par une carte basse résolution. Sur COCO, il garde le gain d'AP_S de P2 (24,33 contre 22,64) à 14,88 FPS, contre 4,85 pour une tête P2 dense [Table 1]. Sur VisDrone, il plafonne à 2,75 FPS [Table 2].

— **Sortie anticipée** : BlankSkip (Marra et al., 2026)[PP] saute le reste du réseau sur les images vides ; il est traité avec les nano-drones (section 6).

Aucune de ces méthodes n'est mesurée sur cible embarquée, sauf BlankSkip. Aucune ne rapporte la latence au pire cas ni la gigue, alors que leur coût dépend du contenu de la scène. Du point de vue matériel, elles ne se valent pas : la mosaïque de taille fixe d'UFPMP-Det ou le tuilage de SAHI gardent un calcul dense et régulier, favorable à un accélérateur à entrée fixe, alors que la convolution éparse de QueryDet repose sur des accès irréguliers *(déduit)*.

4.3 Protocoles et comparabilité

Les chiffres VisDrone du corpus ne se comparent presque jamais entre eux :

— le split varie (validation pour Efficient YOLOv7-Drone, ClusDet, UFPMP-Det, DroneScan-YOLO ; test-dev pour TPH-YOLOv5 et SAHI ; non précisé pour GCL-YOLO et YOLO-Drone) ;

— la métrique varie (mAP50 pour les YOLO, AP COCO pour les autres) ;

— la résolution varie de 640 à 1920 px, et DroneScan-YOLO compare son modèle à 1280 px à des baselines à 640 px (Bellec, 2026, §5) ;

— les baselines sont souvent réentraînées sans pré-entraînement, ou reprises des papiers d'origine.

Surtout, les gains annoncés sont souvent de l'ordre du point, sur un seul entraînement et sans écart-type : +0,9 point pour Jung and Choi (2022), +0,5 pour YOLO-Drone, +1,3 pour SF-YOLOv5. Enfin, l'AP_S n'est rapportée que par trois articles de ce groupe (ClusDet, SAHI, Efficient YOLOv7-Drone, ce dernier seulement pour ses modèles intermédiaires : 19,4 à 22,0 % (Fu et al., 2023, Tables 9, 12)), alors que tous visent les petits objets.

5 Détection sur FPGA et SoC embarqués

5.1 Le DAC-SDC : cinq ans de co-design sur un petit Zynq

Le tableau 4 reprend les champions FPGA du DAC-SDC compilés par Zhang et al. (2024), dont les auteurs sont les vainqueurs de 2022. Les mesures viennent de l'organisateur, avec une puissance à la carte au wattmètre : c'est la série la plus homogène du corpus pour la gamme FPGA.

L'énergie sur le jeu de test est divisée par 500 en quatre ans. Les auteurs attribuent ce gain à trois choix, devenus la recette gagnante : une architecture streaming (apparue en 2020), tous les poids sur puce, et une quantification W4/A4 avec DSP packing [§3.3–3.5, §4.5]. Trois limites en

TABLE 4 – Champions FPGA du DAC-SDC, 2018–2022 (Zhang et al., 2024, Tables 2–6). IoU mono-objet sans classe. Puissance *board*. PYNQ-Z1 (XC7Z020) en 2018, Ultra96 (ZU3EG) ensuite.

Année	Équipe	Réseau, précision numérique	IoU	FPS	P (W)	Énergie (J)
2018	TGIIF	SSD élagué, W8/A8	0,624	12,0	4,2	18 444
2019	iSmart3	SkyNet, W11/A9	0,716	25,1	7,26	15 216
2020	BJUT Runner	UltraNet, W4/A4	0,656	212,7	6,65	1 641
2021	Skrskr	SkyNet, W5/A8	0,716	299,3	3,77	661
2022	SEUer	UltraNet, W4/A4	0,703	2 020,6	1,41	36,7

bornent la portée :

— depuis 2020, tous les podiums utilisent UltraNet ou SkyNet, des réseaux de quelques centaines de milliers de poids ; en 2022, l'IoU ne progresse plus, seule l'efficacité matérielle progresse [§4.2] ;

— le saut de 2021 à 2022 (FPS ×6,8, énergie ÷18) vient en partie du changement de règle qui exclut le chargement des images [§2.3, §4.1] ;

— la tâche (un objet, sans classe) est très loin de la détection multi-classe de petits objets sur VisDrone *(déduit)*.

SkyNet (Zhang et al., 2019b)[PP] (publié à MLSys 2020 d'après le texte) est l'un des rares cas où le même réseau est mesuré sur GPU embarqué et sur FPGA : 0,731 d'IoU à 67,33 FPS et 13,50 W sur TX2, 0,716 à 25,05 FPS et 7,26 W sur Ultra96 [Tables 5–6], puissances de portée non décrite. Sa méthode *bottom-up* choisit des blocs selon leur latence mesurée sur la cible, puis cherche l'architecture sous contrainte matérielle [§4]. Sa solution aux petits objets (bypass et réordonnancement space-to-depth) est légère et portée sur FPGA : c'est un contrepoint à la tête P2 *(déduit)*. Ni ressources ni latence par image ne sont rapportées, et le débit FPGA est obtenu en lot de quatre images [§6.4].

5.2 YOLO sur SoC : DPU Vitis AI et dataflow

Le tableau 5 rassemble les implantations YOLO sur FPGA du corpus.

Le modèle déployé n'est pas le modèle drone. Aucun YOLO du tableau 3 n'est porté sur FPGA dans le corpus. Les implantations restent sur YOLOv3-tiny, YOLOv4, YOLOX et YOLOv5n, et deux d'entre elles simplifient le réseau dans le sens inverse des YOLO drone. Calì et al. (2025) retirent la branche multi-échelle pour tenir dans FINN et en BRAM : il ne reste qu'une tête 13×13, et la mAP50 chute de 41,8 à 17,7 %, sans ablation qui sépare l'effet de l'architecture de celui du W4/A4 [§3.1, Table 5]. Les auteurs citent explicitement la limite de FINN sur les topologies branchées [§3.1]. Karki et al. (2026)[PP] contournent le DPU, qui ne supporte ni SiLU ni softmax ni matmul, en remplaçant l'attention de YOLOv11 et YOLOv26 par un produit terme à terme et une hard-sigmoid [§III-B] : ce n'est plus une attention au sens matriciel *(déduit)*, et la modification coûte environ 3 points de mAP avant quantification [Table I]. SATAY, le seul toolflow streaming du corpus pour YOLOv3 à v8, garde tous les poids sur puce (jusqu'à 26 MB) et ne vise de SoC embarqué qu'avec YOLOv5n sur ZCU104 (Montgomerie-Corcoran et al., 2023, §IV-C, Table IV).

La quantification coûte cher, et jamais par taille d'objet. Sur DPU, le passage à l'INT8 coûte 6 à 7 points de mAP pour les YOLOv4 de Nguyen et al. (2024, Tables 10–11), la conversion Darknet → TensorFlow ne coûtant rien. Il coûte jusqu'à 30 points pour YOLOv8n sur KITTI (0,64 → 0,34) chez Karki et al. (2026, Table II)[PP]. Même hors FPGA, la PTQ INT8 de TensorRT fait perdre 12,3 points de mAP50-95 à YOLOv8n sur Jetson Orin (Rey et al., 2025, Table 4). Aucun de ces articles ne rapporte l'AP_S : la perte sur les petits objets, qui sont pourtant la raison d'être de

TABLE 5 – YOLO sur FPGA dans le corpus. Précisions non comparables entre lignes (jeux, seuils et classes différents). Débit de l'accélérateur sauf mention.

Travail	Carte, flot	Modèle, précision	FPS	Puissance (portée)
Calì et al. (2025)	Z-turn XC7Z020, FINN	YOLOv3-tiny réduit à une tête, W4/A4 ; 17,68 mAP50 VisDrone *car* seule [Table 5]	164,8 (b. 1) / 208,7 (b. 100) [Table 9]	2,55 W (board)
Nguyen et al. (2024)	ZCU104, DPU ×2	YOLOv4-tiny 3L INT8 ; 72,24 mAP@0.25, jeu propre [Table 11]	52,1 / 125,0 [Table 13]	19,4 / 26,4 W (board, prise)
Nguyen et al. (2024)	ZCU104, DPU ×2	YOLOv4 INT8 ; 83,70 mAP@0.25	9,2 / 17,9	23,1 / 30,1 W (board)
Elhence et al. (2025)	KV260, DPU ×1 / ×2	LCAM-YOLOX élagué INT8 ; 78,11 % mAP, feux de forêt [§V-A2]^{m}	195 / 387 [§V-D]^{m}	9,72 / 10,45 W (board)
Montgomerie-Corcoran et al. (2023)	ZCU104, SATAY	YOLOv5n 640, W8/A16 ; 26,7 mAP50 COCO [Table IV]^{m}	21,41 ms	14,5 W (non décrite)
Karki et al. (2026)^{PP}	ZCU104, DPU B4096	YOLOv26n INT8, attention approximée ; 0,29 mAP COCO [Table II]	34,05 (bout en bout)^{m}	8,76 W (Vivado, estimée)
Blott et al. (2018)	Ultra96, FINN-R (MO)	Tincy YOLO W1/A3 ; 50,1 mAP VOC [§5.1]	`n/r` (288 GOp/s)	9,7 W (board)

ces détecteurs, n'est pas connue.

Le goulot est souvent sur le processeur. Quatre articles montrent que l'accélérateur n'est pas ce qui limite le système. Chez Calì et al. (2025, Table 10), le prétraitement (32,2 ms) et le post-traitement (25,8 ms, dont NMS 9,2 ms) en Python sur le Cortex-A9 pèsent environ cinq fois l'inférence ; le système réel tombe à 30 FPS en streaming caméra [§4.4], loin des 208 FPS de l'accélérateur. Chez Elhence et al. (2025, §V-F), le pré- et post-traitement sur le PS ne profite pas des cœurs DPU supplémentaires. Chez Karki et al. (2026, §IV-C)^{PP}, agrandir le DPU ne change pas le débit de bout en bout. Le survey de Sali et al. (2025, §VI-C)^{PP} cite un YOLOv8n à 195 FPS dont le débit tombe à 24 FPS quand le post-traitement tourne en Python sur le PS. Nuance : chez Nguyen et al. (2024, Table 12), le NMS en C++ sur les A53 ne prend que 3,9 ms.

Des puissances de carte de développement. Les puissances du tableau 5 sont élevées pour un drone. Le ZCU104 de Nguyen et al. consomme 16,1 W au repos, mesurés à la prise [§5.3]. La KV260 d'Elhence et al. consomme environ 10 W, soit la gamme Jetson *(déduit)*. Seul le Zynq-7020 de Calì et al. reste sous 3 W, avec 1,9 W au repos [§4.3]. Aucune de ces implantations n'a volé : Elhence et al. décrivent une intégration KV260 + Pixhawk mais évaluent sur images [§IV-C].

Comparaisons biaisées. Les baselines des articles FPGA sont souvent choisies à leur avantage. Nguyen et al. comparent leur FPS/W à une RTX 2080 Ti et à une GTX 1650 en FP32 sous Darknet, sans Jetson ni TensorRT [§5.3]. Calì et al. prennent la puissance du Coral Edge TPU dans sa datasheet, contre une mesure à la carte côté FPGA [Table 15]. Elhence et al. donnent pour un STM32H7A3 15 FPS avec un modèle de 6,7 M de paramètres, chiffre invraisemblable pour un Cortex-M7 *(déduit)* [§V-D]. SATAY compare en GOP/s par DSP, ce qui efface les écarts de précision numérique et de carte.

5.3 Surveys FPGA

Hozhabr and Giorgi (2025) est la revue la plus proche du sujet. Elle distingue temps réel dur et mou, conteste le critère des 30 FPS et propose de normaliser le débit par le nombre de pixels (*pixel throughput*) [§II-C2]. Elle pointe deux travaux absents de la base qui traitent le post-traitement en matériel : un NMS pipeliné à 2,13 ms de bout en bout, et un YOLOv3-tiny entièrement sur FPGA, NMS compris [§V-A]. Le survey de Sali et al. (2025)[PP] sert d'index de références 2025 (YOLOv8n FINN + SORT, SiamRPN++ sur KV260 à 1,11 W), avec de nombreuses incohérences internes : ses chiffres doivent toujours être vérifiés à la source. Wan et al. (2022)[PP] plaident pour le FPGA comme substrat du calcul robotique (localisation, planification), sans comparaison chiffrée et sans accélérateur de détection recensé.

6 Gamme nano : MCU, ASIC et neuromorphique

6.1 Le GAP8 et la lignée PULP

Le GAP8 (Flamand et al., 2018) est la puce de l'AI-deck du Crazyflie, utilisée par la plupart des travaux nano du corpus. C'est un SoC RISC-V de 55 nm : un contrôleur et un cluster de 8 cœurs, 512 kB de L2, 64 kB de L1, un accélérateur de convolution, environ 10 GMAC/s en crête et au plus 75 mW au pire cas [§II, Table II]. Le papier, court et écrit par le concepteur, ne rapporte aucune détection : seulement CIFAR-10 en 650 µs pour 15 mW, méthode de mesure non décrite [§IV]. Son enseignement durable est que la gestion explicite de la mémoire (tuilage L3/L2/L1 par DMA) est le cœur de l'effort de portage *(déduit)*, comme sur un accélérateur FPGA dataflow.

Le tableau 6 rassemble les réseaux déployés sur GAP8 et sur MCU.

Table 6 – Réseaux déployés en gamme nano. Tâches très différentes : les chiffres donnent des ordres de grandeur.

Travail	Tâche, réseau	Puce	Débit	Puissance (portée), source
PULP-Dronet (Palossi et al., 2018)[PP]	navigation, DroNet Fixed16, 41 MMAC	GAP8	6 / 18 FPS	64 / 284 mW (shield), §VI[m]
Tiny-PULP-Dronet (Lamberti et al., 2024)[PP]	navigation, 1,5 MMAC, 6,4 kB	GAP8	89 / 160 FPS	34 mW (chip), 0,38 mJ/image, §III-B[m]
PULP-Frontnet (Palossi et al., 2021)[PP]	pose humaine, INT8, 4 MMAC	GAP8	134,7 FPS	86,6 mW (chip), §V-B[m]
NanoFlowNet (Bouwmeester et al., 2022)[PP]	flot optique dense, INT8	GAP8	5,57 FPS	`n/r`, Table IV[m]
Lamberti et al. (2023)[PP]	détection SSD-MbV2 1,0×, 2 classes, 534 MMAC ; 50 % mAP	GAP8	1,6 FPS	134,5 mW (AI-deck), Table II
BlankSkip (Marra et al., 2026)[PP]	même détecteur + sortie anticipée ; 0,540 mAP	GAP8	1,86 FPS moyen	`n/r`, Table 2
TinyissimoYOLO (Moosmann et al., 2023)	détection 88×88, 3 classes VOC ; 58,5 % mAP	MAX78000	5,5 ms	196 µJ/inférence (MCU), §III[m]
TinyissimoYOLO	idem	STM32H7A3	359 ms	`n/r`, §III[m]

Navigation. PULP-Dronet (Palossi et al., 2018)[PP] (publié dans IEEE IoT Journal d'après le DOI) est le premier CNN de navigation en boucle fermée entièrement à bord d'un nano-drone de

27 g. À 64 mW, le calcul représente 0,8 % de la puissance du drone, estimée à 7,6 W [Fig. 12]. Son apport le plus utile ici est système : l'autonomie en vol stationnaire passe de 440 s pour le Crazyflie seul à 340 s avec le shield qui calcule, et la masse du module en coûte l'essentiel (90 s contre 10 s pour le calcul) [Table IV]. Tiny-PULP-Dronet (Lamberti et al., 2024)[PP] réduit le réseau d'un facteur 50 en taille et 27 en MAC, pour un gain de latence de 8,5 seulement : la première couche et le format mémoire deviennent le goulot [§III-B]. Aucun vol n'est rapporté, et le multitâche qui motive le travail n'est pas démontré.

Pose et flot optique. PULP-Frontnet (Palossi et al., 2021)[PP] ferme la boucle de contrôle sur une estimation de pose humaine. Son résultat le plus instructif : le réseau le plus rapide (135 Hz) suit moins bien la personne que le plus lent (48 Hz), avec une erreur de position médiane de 0,63 contre 0,41 m [Table IV]. Le débit maximal n'est pas la bonne cible *(déduit)*. NanoFlowNet (Bouwmeester et al., 2022)[PP] calcule un flot optique dense à 5,57 FPS sur GAP8 et sert l'évitement d'obstacles, sans mesure de puissance ni précision après quantification [Table IV].

Détection. Deux articles seulement font de la détection sur GAP8, sur la même tâche jouet : deux classes d'objets posés au sol dans une pièce. Lamberti et al. (2023)[PP] obtiennent 1,6 FPS pour 134,5 mW à l'AI-deck [Table II] et un taux de détection de 90 % en mission à 0,5 m/s, qui tombe à 83 % à 1 m/s [Table III]. Le bilan de puissance du drone entier est un chiffre clé : moteurs 7,32 W (91 %), AI-deck 0,134 W (1,67 %) [Table IV]. BlankSkip (Marra et al., 2026)[PP] ajoute une branche qui détecte les images vides et arrête l'inférence : +24 % de débit moyen pour −0,015 de mAP [Table 2]. Le gain dépend de la proportion d'images vides, fabriquée par les auteurs sur le jeu de test, et la latence au pire cas reste celle du modèle complet *(déduit)*.

MCU à accélérateur. TinyissimoYOLO (Moosmann et al., 2023) montre que l'accélérateur CNN intégré au MCU fait la différence : 5,5 ms sur MAX78000 contre 359 ms sur STM32H7A3, pour le même réseau [§III]. Sa mAP (3 classes, au plus 3 objets par image, entrée 88×88) ne se compare à aucune autre du corpus, et varie de 57 à 59 % selon la section du papier.

6.2 ASIC et neuromorphique

Navion. Suleiman et al. (2019) intègrent une odométrie visuelle-inertielle complète sur un ASIC de 65 nm, sans DRAM externe : 24 mW en configuration maximale et 2 mW à 20 FPS quand les paramètres sont adaptés à chaque séquence (puissance de la puce) [§V-A, §V-D][m]. La méthode de co-design est transposable à un détecteur : tout sur puce, tampons d'image compressés, parcimonie exploitée *(déduit)*. Les 2 mW supposent un réglage fait a posteriori, et aucun vol n'est rapporté : les données sont rejouées depuis un ZC706 [§V-B].

Loihi. Deux travaux de contrôle de drone utilisent la puce neuromorphique Loihi d'Intel. Vitale et al. (2021)[PP] calculent une transformée de Hough sur les événements d'une caméra DVS en 250 µs, soit une estimation à 20 kHz contre 1 kHz sur CPU, sur un banc à un degré de liberté [Fig. 2, §III-A][m] ; aucune puissance n'est mesurée. Paredes-Vallés et al. (2023)[PP] ferment la boucle vision → contrôle sur un quadrirotor de 1 kg, avec un SNN de flot optique à 27 µJ par inférence à 200 Hz [Abstract]. Deux réserves : l'énergie est mesurée sans entrées-sorties, alors que l'USB est le vrai goulot selon les auteurs, et la comparaison à trois ou quatre ordres de grandeur oppose Loihi à une émulation du SNN en PyTorch sur Jetson Nano, ce que les auteurs reconnaissent [Discussion]. Aucun des deux ne fait de détection d'objets.

6.3 Ce que la gamme nano apprend au reste

La gamme nano est la seule du corpus où la part du calcul dans le budget du drone est mesurée : 1,67 % de la puissance pour la vision (Lamberti et al., 2023, Table IV), et un coût en autonomie dominé par la masse (Palossi et al., 2018, Table IV). Elle montre aussi que le débit limite la vitesse de mission (taux de détection qui baisse à 1 m/s) et que la qualité de contrôle ne croît pas avec le débit (PULP-Frontnet). Ces trois constats n'ont pas d'équivalent mesuré pour un FPGA ou une Jetson sur un drone de taille moyenne.

7 Suivi et navigation embarqués

7.1 Suivi mono-objet sur Jetson

Le groupe Vision4Robotics (Tongji) publie trois trackers siamois à backbone AlexNet, testés à bord d'un drone sur Jetson AGX Xavier, tous sans TensorRT et sans mesure de puissance.

TABLE 7 – Trackers aériens mesurés à bord (gamme Jetson). Aucune puissance ni mode de puissance n'est rapporté.

Tracker	Précision sur benchmark (bureau)	FPS à bord	FPS bureau
SiamAPN++ (Cao et al., 2021a)[PP]	UAV20L : précision 0,736, AUC 0,560 [Fig. 4a][m]	34,9 [§V][m]	`n/r`
HiFT (Cao et al., 2021b)[PP]	UAV20L : précision 0,763 [Table 2]	31,2 [§5][m]	127 (GPU non précisé)
TCTrack (Cao et al., 2022)[PP]	UAVTrack112_L : succès 0,582 [§4.2][m]	> 27 [§5][m]	125,6 (« PC »)

Le passage du bureau à la Xavier divise le débit par quatre environ, sans analyse du goulot *(déduit)*. TCTrack apporte une observation utile au choix d'un backbone : sur Xavier, AlexNet prend 3,4 ms contre 13,7 ms pour MobileNetV2, attribués au coût d'accès mémoire des réseaux « mobiles » (Cao et al., 2022, Table 1). Aucun tracker siamois ou à Transformer n'est porté sur FPGA ou MCU dans le corpus, et aucun n'étudie la quantification. Du côté multi-objets, les trackers par association de positions sont quasi gratuits : SORT tourne à 245 FPS sur CPU dans UAVDT (Du et al., 2018, Table 3)[m]. Le coût embarqué du suivi est donc dans le détecteur *(déduit)*.

7.2 Vol agile : la référence Jetson de Zurich

Deux travaux de l'université de Zurich fixent les ordres de grandeur de la gamme Jetson pour un drone agile de moins d'un kilogramme.

— Loquercio et al. (2021) (Science Robotics) apprennent une politique de bout en bout à partir d'images de profondeur. Sur Jetson TX2, la latence est de 41,6 ms, dont 38,9 d'inférence [Table 1]. En forêt, le drone réussit 100 % des vols à 5 m/s et 60 % à 10 m/s [§2-A]. Le papier relie explicitement latence et vitesse sûre maximale [§S5].

— Kaufmann et al. (2023) (Nature) battent des champions humains de course FPV avec des capteurs et un calcul embarqués. Le détecteur de portes (un petit U-Net) prend 40 ms en TensorRT FP16 sur le GPU du TX2, la politique 8 ms sur son CPU (Methods)[m]. La vision est le goulot, et la caméra à 30 Hz est un facteur limitant face aux 120 Hz des pilotes (Discussion).

Aucun des deux ne mesure la puissance du calculateur. Le survey de Hanover et al. (2023) affirme que la famille Jetson est le plus petit matériel suffisant pour des réseaux complexes, ce qui fixe des châssis de 6 pouces [§VII-C] : il ignore les nano-drones et ne discute pas le FPGA. Il cite comme question ouverte la détection d'un adversaire depuis la caméra embarquée (*multiplayer racing*, §VIII-C), c'est-à-dire un cas air → air.

7.3 Localisation et plateformes hétérogènes

Guo et al. (2021) proposent de réunir contrôle de vol (PID) et prétraitement sur un Zynq-7020, avec une Jetson AGX Xavier pour l'inférence. C'est une proposition sans aucune mesure de latence, de masse ou de puissance, à citer avec prudence [§III–IV]. Pourjabar et al. (2023)[PP] localisent un essaim de nano-drones par UWB, sans vision ; le module radio seul consomme environ 350 mW par drone [§V-C], un ordre de grandeur à garder face au budget de calcul d'un nano-drone.

8 Contre-drone : détecter des drones

Sur les 17 articles de contre-drone du corpus, 11 relèvent du sol → air ou ne déclarent pas le capteur. Les deux surveys du domaine (Dong et al., 2025; Ding et al., 2025)[PP] ne font pas la distinction : ils mêlent Det-Fly et ARD-MAV, pris depuis un drone, aux jeux pris du sol, et ne discutent aucune plateforme embarquée chiffrée. Cette section suit donc le critère du profil de la base : seul l'air → air relève de l'IA embarquée.

8.1 Sol → air : des références de contraste

Les détecteurs sol → air du corpus sont tous mesurés sur GPU de bureau ou sur ordinateur portable :

- YOLOv4 élagué (Liu et al., 2021) : 90,5 mAP50 et 69 FPS sur Tesla P100, sur un jeu propre de deux drones DJI [Table 4] ; l'élagage fait chuter le rappel sur les petits drones à 30,7 %, qu'une augmentation ciblée remonte à 72,6 % [§4.3] ;
- F-YOLOv7 (Du et al., 2025) : 98,8 d'AP50 de validation sur DUT Anti-UAV avec soustraction de fond, sur RTX 4090 [Table 2] ;
- DotD-YOLOv9-C (Gao et al., 2024) : 92,6 de mAP@0.5 sur Anti2, sur RTX 4060 portable, sans aucun temps d'inférence [Table 5] ;
- YOLO-GCOF (Yu and Mo, 2025) : 91,5 de mAP@50 sur DUT Anti-UAV[m], annoncé pour Raspberry Pi 4B sans aucun chiffre sur la carte ;
- soustraction de fond + MobileNetV2 (Seidaliyeva et al., 2020) : F1 0,742 sur Drone-vs-Bird, 9 FPS en 1080p sur un matériel non nommé [Table 1, §3.4] ;
- réseau de caméras stéréo panoramiques (Zheng et al., 2023) : 9 FPS avec une RTX 3070 par groupe de 8 objectifs [§VII-B.3][m] ;
- fusion IR + visible + audio (Svanstrom et al., 2020) sur portable : la fusion à deux capteurs supprime les fausses alarmes relevées en 10 minutes sans drone [§V-D].

Le seul portage FPGA est celui de Nguyen et al. (2024) sur ZCU104 (section 5), sur un jeu d'images d'Internet et de caméras au sol. Trois idées de ces travaux restent utiles pour l'embarqué : l'augmentation « petits objets » après élagage, l'appariement DotD sans coût d'inférence, et les jeux multi-classes (drone, oiseau, avion) pour mesurer les fausses alarmes. En revanche, la soustraction de fond, centrale dans trois d'entre eux, suppose une caméra fixe : elle ne fonctionne pas depuis un drone en mouvement, ce que reconnaissent Seidaliyeva et al. (2020, §2.1).

8.2 Air → air : le cas embarqué

Évaluer les détecteurs. Zheng et al. (2021) posent explicitement la distinction : en air → air, le fond peut être urbain ou naturel et la cible faire moins de 10×10 pixels [§I]. Sur Det-Fly, les huit détecteurs évalués vont de 69,5 (RefineDet) à 82,4 d'AP (Grid R-CNN), YOLOv3 étant à 72,3 d'AP pour 32 ms sur RTX 2080Ti [§V-A, §V-B][m]. L'AP moyenne des huit passe de 88,3 % sur fond de ciel à 62,0 % sur fond urbain [Table III]. Aucun détecteur n'est porté à bord, alors que le choix de ResNet-50 est motivé par l'embarqué [§IV].

Exploiter le mouvement. En air → air, les méthodes les plus précises combinent apparence et mouvement :

- Dogfight (Ashraf et al., 2021)[PP] (CVPR 2021 probable) segmente les drones image par image, puis retrouve des candidats par frontières de mouvement et les valide par un I3D sur des cuboïdes de 8 images. Le F1 passe de 0,90 (apparence) à 0,92 (apparence et mouvement) sur NPS-Drones [Table 3]. Aucun temps de calcul n'est rapporté ; la fenêtre temporelle impose au moins 4 images de latence *(déduit)*.
- GLAD (Guo et al., 2023)[PP] combine un YOLOv5s global, un module de mouvement avec compensation de l'ego-motion par homographie, et un YOLOv5s local sur une région de 300×300 suivie par Kalman. Sur ARD-MAV, il obtient 0,80 d'AP50 contre 0,56 pour YOLOv5s à 640 et 0,73 pour TPH-YOLOv5l à 1536 (12,8 FPS) [Table IV]. Sur Jetson Xavier NX, en TensorRT, il tourne à 23,6 FPS en moyenne, mais à 5,1 FPS quand le module de mouvement global est appelé [Table VIII] ; la précision sur la carte et la puissance ne sont pas mesurées.
- GL-YOMO (Liu et al., 2024)[PP] suit la même logique global/local avec flot optique et Kalman, à 21,6 FPS sur Xavier NX [§IV-E]. Sur Drone-vs-Bird, son AP (0,763) est sous celle de RT-DETR (0,773), à un seuil d'IoU de 0,1 [Table II]. Le point de vue du capteur n'est pas déclaré.

GLAD est le seul travail air → air du corpus avec un chiffre embarqué. Sa décomposition montre que la partie non neuronale (homographie, Lucas-Kanade, morphologie) devient le goulot sur Jetson, ce qui plaide pour son accélération matérielle *(déduit)*. L'idée global → local contourne aussi la perte de résolution du sous-échantillonnage à 640 px sans tête P2 : un petit YOLO sur une région de 320×320 est un candidat naturel pour un FPGA *(déduit)*.

8.3 Bilan

Aucun détecteur air → air du corpus n'est mesuré sur SoC FPGA ou MCU, et aucun n'a de puissance mesurée. Aucun n'est évalué en boucle fermée sur un intercepteur. Il manque aussi un jeu air → air multi-classes (drones, oiseaux, avions) qui permette de mesurer les fausses alarmes d'un intercepteur ; Anti2 (Gao et al., 2024) a les classes mais mêle les points de vue. C'est le manque le plus net de la base (section 11).

9 Co-design calcul, énergie et vol

9.1 Le calcul agit sur la mission par le temps et la masse

MAVBench. Boroujerdian et al. (2019) (MICRO 2018) évaluent le calcul en boucle fermée : simulateur AirSim et Jetson TX2 réelle en *hardware-in-the-loop*, modèle d'énergie du drone et cinq applications complètes. Leur constat central : sur un drone de 300 à 400 W, le calcul consomme moins de 5 % de la puissance [§I], mais il agit sur l'énergie totale par le temps de mission et la vitesse sûre. Monter la fréquence et le nombre de cœurs du TX2 réduit le temps de mission de 84 % et l'énergie de 82 % en livraison de colis [§V-C]. Tout est en simulation sauf le TX2 ; la masse du calculateur ne varie pas avec sa puissance, et aucune précision de détection n'est rapportée.

Le modèle F-1. Krishnan et al. (2020) puis Krishnan et al. (2022)[PP] formalisent un « roofline pour drone ». La vitesse sûre maximale dépend du débit de décision $f = \min(1/T_{\text{capteur}}, 1/T_{\text{calcul}}, 1/T_{\text{contrôle}})$, de la portée du capteur et de l'accélération maximale, elle-même réduite par la masse du calculateur et de son dissipateur. Un point de genou sépare trois régimes : limité par le capteur, par le calcul ou par la physique. Le modèle est validé en vol sur quatre drones S500, avec une erreur de 5 à 10 % sur la vitesse sûre (Krishnan et al., 2022, Fig. 7b). Ses études de cas donnent des arguments directement utiles :

— une AGX Xavier à 230 FPS donne un plafond plus bas qu'un Intel NCS à 150 FPS sur un DJI Spark, à cause de sa masse et de son dissipateur (280 + 162 g contre 47 g) [§VI-A] ;
— une redondance double (2 × TX2) coûte 33 % de vitesse sûre [§VI-C] ;
— PULP-Dronet, à 6 FPS, est limité par le calcul et devrait gagner un facteur 4,3 [§VII].

Les limites sont connues : pas de traînée, masse réduite au dissipateur estimé par le TDP, consommation électrique du calcul hors modèle, et qualité de détection absente (une détection ratée ne réduit pas la portée du capteur dans le modèle) *(déduit)*. Aucun FPGA n'y figure.

Mesures en vol. Les mesures réelles du lien calcul–vol viennent surtout de la gamme nano (section 6) : coût en autonomie décomposé en masse et calcul, bilan de puissance du drone entier, taux de détection qui baisse avec la vitesse. Dans la gamme Jetson, Loquercio et al. (2021) relient latence et vitesse sûre, et Kaufmann et al. (2023) donnent une latence sensorimotrice de 40 ms. Côté neuromorphique, Vitale et al. (2021)[PP] montrent qu'une perception à 20 kHz reste sous-exploitée quand la mécanique a 100 à 150 ms de retard [§III-A].

Le chaînon manquant. Les papiers YOLO/FPGA du corpus donnent des FPS et parfois des watts, jamais l'effet sur l'autonomie ou la vitesse de vol sûre : ni Calì et al. (2025), ni Elhence et al. (2025), ni Nguyen et al. (2024), ni les analyses du DAC-SDC. Le cadre existe (F-1, MAVBench), les données partielles aussi (FPS, puissance à la carte) ; il manque la masse des cartes et l'application du modèle. Le défi « hardware-in-the-loop » de Wan et al. (2022, §IV)[PP] (co-simulation FPGA + AirSim) va dans ce sens, sans réalisation.

9.2 Fiabilité du calcul embarqué

L'axe ne compte que deux articles. Ahmed and Jenihhin (2022) passent en revue les fautes des plateformes de calcul de drone (soft errors, fautes permanentes, vieillissement) et les techniques de tolérance. Ils constatent que les SoC FPGA dominent les études de fautes et que la reconfiguration partielle dynamique est la technique dominante pour les accélérateurs CNN [§5.1]. Le survey ne donne presque aucune donnée quantitative (une couche CNN quantifiée 39 % moins sensible aux radiations, citée d'un tiers, §5), ne décrit pas sa méthode de sélection, et ne recense aucune étude d'injection de fautes sur un détecteur de type YOLO en contexte drone [§5.2, §6]. Son modèle de fiabilité multi-couches reste conceptuel. MAVBench cite les soft errors comme extension non réalisée (Boroujerdian et al., 2019, §VI-C). Le seul chiffre sur le coût de la tolérance aux fautes est modélisé : −33 % de vitesse sûre pour une redondance double (Krishnan et al., 2022, §VI-C). La mémoire de configuration SRAM d'un FPGA est sensible aux SEU, point absent de tous les papiers YOLO/FPGA du corpus *(déduit)*.

10 Comparer les gammes de puissance

10.1 Débit et puissance rapportés

La figure 1 place les 79 lignes de `benchmarks.csv` qui ont à la fois un débit et une puissance, sur 324. Les points pleins ont une puissance mesurée (puce ou carte) ; les points creux, une puissance estimée ou de portée non décrite.

Pour la détection (panneau de gauche), la figure montre trois groupes. Les deux points MCU (SSD-MobileNetV2 sur GAP8) sont vers 0,14 W et 2 FPS. Les GPU embarqués (Jetson) se regroupent entre 7 et 15 W pour quelques dizaines d'images par seconde. Les FPGA s'étalent sur trois ordres de grandeur de débit, de 1,4 à 30 W ; les points au-dessus de 1 000 FPS sont les réseaux minuscules du DAC-SDC, mesurés sans chargement d'images. Ce que la figure ne permet pas : conclure qu'une

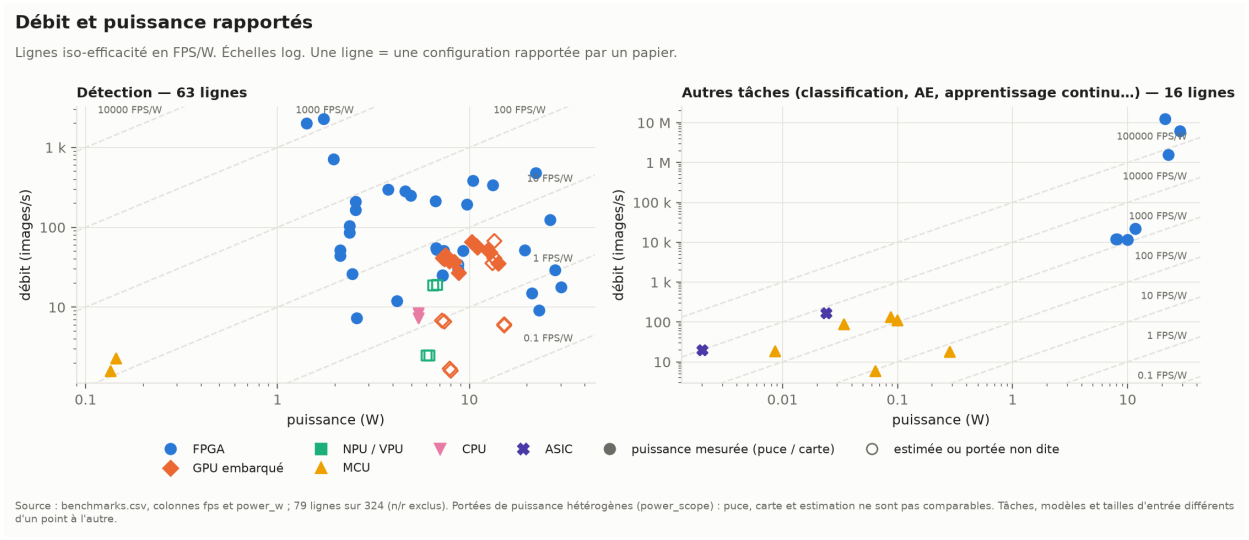


FIGURE 1 – Débit et puissance rapportés, en échelles logarithmiques ; droites pointillées d'iso-efficacité en FPS/W. Figure générée par `bin/pdb plot` à partir de `benchmarks.csv` (28/09/2026).

famille est plus efficace qu'une autre. Aucun couple de points ne partage à la fois le modèle, la résolution, la précision numérique et la méthode de mesure *(déduit)*.

10.2 Les rares comparaisons à modèle égal

TABLE 8 – Comparaisons du corpus où un même réseau est mesuré sur plusieurs familles de plateformes.

Travail	Modèle	Résultat	Réserve
SkyNet (Zhang et al., 2019b)[PP]	SkyNet, DAC-SDC	TX2 : 67,3 FPS, 13,5 W ; Ultra96 : 25,1 FPS, 7,3 W [Tables 5–6]	portée non décrite ; lot de 4 sur FPGA
SATAY (Montgomerie-Corcoran et al., 2023)	YOLOv5n 640	ZCU104 : 317 mJ/image ; TX2 : 277 mJ [Table IV][m]	portée non décrite ; runtime du TX2 `n/r`
Elhence et al. (2025)	LCAM-YOLOX	KV260 : 195 FPS ; Jetson Nano : 65 FPS ; STM32H7A3 : 15 FPS [§V-D][m]	précision et puissance `n/r` hors FPGA ; chiffre MCU invraisemblable
TinyissimoYOLO (Moosmann et al., 2023)	réseau 88×88	MAX78000 : 5,5 ms, 196 µJ ; Apollo4b : 6,1 mJ [§III][m]	MCU seulement
Rey et al. (2025)	YOLOv8n INT8	Orin NX : 65,8 FPS, 10,3 W ; Orin Nano : 44,9 FPS, 7,5 W [Table 4]	Jetson seulement ; télémétrie ; jeu privé facile
Alqahtani et al. (2024)[PP]	YOLOv8n	Orin Nano : 16 ms ; RPi 5 + Hailo-8 : 76 ms ; mAP COCO 31–32 [§IV][m]	précision numérique `n/r` ; pas de FPGA
Feng et al. (2022)	YOLOv3-tiny	Xavier NX : 41,1 FPS ; RPi + NCS2 : 18,8 ; Nano : 6,8 [Table 3]	pas de mAP ; sans TensorRT

Le tableau 8 montre qu'aucun article ne mesure le même détecteur sur les trois gammes (nano, FPGA, Jetson) avec la même portée de puissance. Les comparaisons FPGA–Jetson existantes utilisent des Jetson de 2017 (TX2) ou des modèles minuscules ; la seule qui ajoute un MCU (Elhence et al.) n'est pas crédible sur ce point. Les baselines Jetson récentes (Orin, TensorRT INT8) existent dans le corpus (Rey et al., 2025), mais sans FPGA en face.

10.3 Ordres de grandeur par gamme

Faute de comparaison directe, le corpus donne des ordres de grandeur, à ne lire que comme tels :

— **nano** : de 4 à 41 MMAC par image pour la navigation, 534 MMAC pour le seul détecteur déployé (SSD-MbV2, 1,6 FPS) ; de 34 à 284 mW ; 0,4 mJ par image pour la pose humaine (Palossi et al., 2021, §V-B)[PP] ;

— **FPGA** : de 2,5 W (Zynq-7020, carte) à 10 W (KV260, carte) et 30 W (ZCU104, à la prise), pour des YOLO réduits à quelques centaines de FPS d'accélérateur, et quelques dizaines de bout en bout ;

— **Jetson** : de 7 à 15 W de télémétrie pour YOLOv8n et YOLOv8s en INT8 (45 à 66 FPS), 40 ms pour les réseaux de vol agile sur TX2, de 23 à 35 FPS pour les trackers et GLAD sur Xavier.

L'écart entre gammes est de l'ordre de trois ordres de grandeur en puissance, mais la tâche change aussi : navigation en 200×200 en niveaux de gris d'un côté, détection en 640×640 de l'autre *(déduit)*.

10.4 Couverture du corpus

La figure 2 croise la famille de plateforme des mesures et l'axe des articles. Elle confirme les déséquilibres décrits dans ce document : la détection drone est surtout mesurée sur GPU de bureau (17 articles), le contre-drone aussi (9 articles), aucune mesure FPGA ne concerne un nano-drone et aucune mesure du corpus ne porte sur la fiabilité. Un zéro signifie « absent de la base », pas « absent de la littérature ».

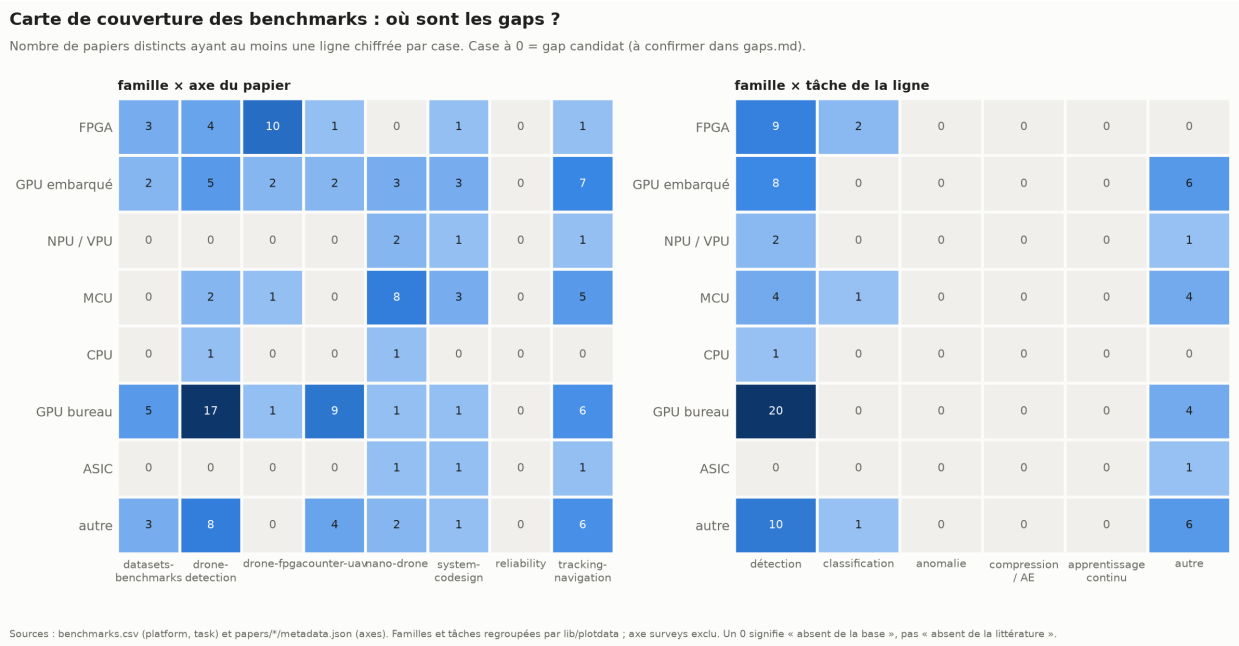


FIGURE 2 – Nombre d'articles ayant au moins une ligne chiffrée, par famille de plateforme et par axe (gauche) ou tâche (droite). Figure générée par `bin/pdb plot` (28/09/2026).

11 Zones non couvertes et pistes de recherche

Les gaps ci-dessous viennent de `gaps.md` (2e passe, 28/09/2026, 73 fiches et 324 lignes). Un gap *étayé* est constaté dans plusieurs fiches (mesure absente, limite reconnue par les auteurs) ; cela ne prouve pas qu'il est absent de la littérature. Un gap à l'état d'*hypothèse* ne repose que sur l'absence

de papiers dans la base.

TABLE 9 – Gaps du corpus drone : statut et piste principale.

Gap	Statut	Piste
Décalage algorithme / matériel : YOLO drone (P2, attention) jamais portés sur FPGA	étayé	YOLOv8n-P2 ou Drone-YOLO nano en INT8 sur KV260 (Vitis AI), contre FINN ou hls4ml ; mAP VisDrone avant et après
Quantification et petits objets : 0 ligne avec AP_S sur 324	étayé	balayage PTQ / QAT (FP32, INT8, INT4) d'un YOLO drone sur VisDrone, AP_S mesurée sur la carte
Tête P2 et haute résolution : coût mémoire on-chip non mesuré	étayé (coût) ; hypothèse (absence FPGA)	tailles d'activation par couche de YOLOv8n et YOLOv8n-P2 face au budget BRAM d'un ZU3EG ou d'une KV260
Paramètres et FLOPs ≠ latence sur cible	étayé	trois variantes légères d'un même YOLO profilées sur KV260 et Orin, à précision égale
Post-traitement sur le PS : goulot de bout en bout	étayé	NMS matériel ou tête sans NMS ; latence caméra → sortie instrumentée
Calcul adaptatif ou épars jamais évalué à bord	étayé	SAHI à tuiles fixes contre saut de tuiles vides sur KV260, latence au pire cas
Métriques non comparables ; benchmarks sans métrique d'efficacité	étayé	protocole commun : métrique, résolution, portée de la puissance
Métrique système absente des papiers YOLO/FPGA	étayé	designs FPGA publiés placés sur le modèle F-1 avec masse de carte mesurée
Fiabilité des accélérateurs de détection sur drone	étayé (corpus mince)	injection de fautes sur un détecteur FPGA avec métrique de mission
Pas de comparaison entre gammes de puissance	étayé	même réseau, même entrée, même portée de puissance sur GAP8, FPGA et Jetson
Détection et navigation sur le même budget	étayé	partage d'un SoC par reconfiguration partielle, interférence mesurée
Suivi embarqué sans puissance ni FPGA	étayé	HiFT ou SiamAPN++ sur FPGA, énergie par image
Contre-drone évalué sur GPU de bureau	étayé	YOLOv8n sur Det-Fly, INT8 sur KV260 contre Orin, puissance à la carte
Détecteur air → air embarqué sur intercepteur	étayé	détecteur sur SoC avec AP, FPS, W et latence de bout en bout ; Det-Fly et ARD-MAV
Air → air : coût du mouvement multi-images	étayé (coût) ; hypothèse (FPGA)	profil par étage de GL-YOMO ou GLAD ; tampon on-chip de 8 images
Fusion visible + thermique à bord	hypothèse	recherche ciblée (`/paper-discover`)
Apprentissage continu à bord du drone	hypothèse	base `fpga` ; recherche ciblée
Code et bitstreams rarement publiés	étayé (relevé approximatif)	distinguer code d'entraînement et design matériel

11.1 Trois gaps structurants

Le décalage algorithme / matériel. C'est l'hypothèse de départ de la base, et le corpus l'étaye. Les détecteurs qui font l'état de l'art sur VisDrone ajoutent une tête P2 et de l'attention (section 4). Les implantations FPGA restent sur des YOLO anciens et, pour tenir, retirent la branche multi-échelle (Calì et al., 2025) ou remplacent l'attention (Karki et al., 2026)[PP]. La seule mesure embarquée d'une tête P2 (Jetson TX2) montre un facteur 3 à 4 en latence (Zhang, 2023, Table 6).

Deux familles d'alternatives à P2 existent, jamais évaluées sur FPGA : transférer l'information de P2 vers P3 (TPH-YOLOv5++), ou recadrer à pleine résolution autour des régions utiles (SAHI, UFPMP-Det, GLAD).

La précision sur petits objets après quantification. Aucune des 324 lignes ne rapporte d'AP_S. Les pertes de quantification connues sont globales et souvent fortes (6 à 30 points de mAP selon le modèle et le jeu). On ne sait donc pas si la quantification, indispensable sur FPGA et MCU, détruit précisément ce que les YOLO drone cherchent à gagner.

La métrique de mission. Le lien entre latence, masse et vitesse sûre est modélisé (Krishnan et al., 2022)[PP] et mesuré pour des nano-drones, jamais pour un détecteur sur FPGA. Le modèle lui-même ignore la qualité de perception, et la gamme nano montre qu'un réseau plus rapide peut moins bien servir la mission (Palossi et al., 2021, Table IV)[PP].

11.2 Questions de thèse candidates

Les trois questions ci-dessous sont des déductions à partir des gaps, pas des conclusions du corpus.

1. **Détecteur air → air sur SoC embarquable.** Peut-on détecter un drone de quelques pixels à bord d'un intercepteur, sur KV260 ou Zynq UltraScale+, avec une AP, une latence de bout en bout et une puissance à la carte mesurées, et comment se compare-t-on à une Jetson Orin à protocole égal ? Données : Det-Fly, ARD-MAV, NPS-Drones. Point de départ : l'architecture globale/locale de GLAD, dont la partie non neuronale est à accélérer.
2. **Petits objets et précision numérique.** Quelle est la perte d'AP_S d'un YOLO drone (avec et sans tête P2) quand on passe de FP32 à INT8 puis INT4, en PTQ et en QAT, mesurée sur la carte ? Quelle alternative à P2 (recadrage, transfert vers P3) tient dans la mémoire on-chip d'une petite FPGA à précision égale ?
3. **Du FPS à la vitesse sûre.** Comment traduire le débit, la puissance et la masse d'un accélérateur de détection en vitesse de vol sûre et en autonomie, en intégrant la qualité de détection au modèle F-1 ? À quelle gamme de puissance (nano, FPGA, Jetson) correspond l'optimum pour un drone donné ?

Laboratoires français à approcher : `labs.md` ne recense encore que le LIRMM (test et fiabilité), sans papier du corpus à l'appui ; la liste reste à construire.

12 Conclusion

La vision embarquée sur drone dispose de jeux de données de référence (VisDrone, UAVDT, DAC-SDC, Det-Fly), d'une littérature abondante de détecteurs pour petits objets et de démonstrations convaincantes dans chaque gamme de puissance : SSD-MobileNetV2 sur GAP8 à 134 mW, YOLOX sur KV260 à 10 W, perception et contrôle de course sur Jetson TX2. Le corpus montre pourtant que ces trois littératures se croisent peu :

— les détecteurs les plus précis sur VisDrone sont mesurés sur GPU de bureau, et le seul portage embarqué d'une tête P2 (Drone-YOLO sur TX2) coûte un facteur 3 à 4 en latence ;
— les designs FPGA optimisent le débit sur des réseaux minuscules (DAC-SDC) ou simplifiés, avec des précisions non comparables et sans AP_S ;
— le co-design calcul–vol est modélisé, rarement mesuré, et jamais pour un FPGA ;
— le contre-drone air → air a des jeux publics (Det-Fly, NPS-Drones, ARD-MAV) mais un seul chiffre embarqué, sur Jetson et sans puissance.

Ces manques dessinent un sujet de thèse cohérent : porter un détecteur de petits objets récent sur un SoC embarquable, mesurer honnêtement sa précision par taille d'objet et sa puissance à la carte, et traduire le résultat en métrique de mission.

Pistes concrètes.

1. **Papier à lire en priorité** : les deux références de Hozhabr and Giorgi (2025) sur le post-traitement matériel (NMS pipeliné d'Anupreetham et al., système tout-FPGA de D. Zhang et al.), absentes de la base : elles répondent au goulot PS observé dans quatre papiers.
2. **Expérience à reproduire** : YOLOv8n entraîné sur Det-Fly (Zheng et al., 2021), en INT8 sur KV260 (Vitis AI) et sur Jetson Orin, avec AP et AP_S mesurées sur la carte, latence de bout en bout et puissance à la carte des deux côtés.
3. **Gap à creuser** : placer les designs de Calì et al. (2025) et Elhence et al. (2025) sur le modèle F-1 de Krishnan et al. (2022), pour obtenir la première métrique de vitesse sûre d'un détecteur FPGA.

Références

Foisal Ahmed and Maksim Jenihhin. A Survey on UAV Computing Platforms : A Hardware Reliability Perspective. *Sensors 22(16), 6286*, 2022. doi : 10.3390/s22166286. URL `https://doi.org/10.3390/s22166286`.

Fatih Cagatay Akyon, Sinan Onur Altinuc, and Alptekin Temizel. Slicing Aided Hyper Inference and Fine-tuning for Small Object Detection. arXiv preprint, 2022. URL `https://arxiv.org/abs/2202.06934`. arXiv :2202.06934. Preprint non relu par les pairs.

Daghash K Alqahtani, Muhammad Aamir Cheema, Maria A Rodriguez, and Adel N Toosi. A Comprehensive Evaluation of Deep Learning Object Detection Models on Heterogeneous Edge Devices. arXiv preprint, 2024. URL `https://arxiv.org/abs/2409.16808`. arXiv :2409.16808. Preprint non relu par les pairs.

Muhammad Waseem Ashraf, Waqas Sultani, and Mubarak Shah. Dogfight : Detecting Drones from Drones Videos. arXiv preprint, 2021. URL `https://arxiv.org/abs/2103.17242`. arXiv :2103.17242. Preprint non relu par les pairs.

Yann V Bellec. DroneScan-YOLO : Redundancy-Aware Lightweight Detection for Tiny Objects in UAV Imagery. arXiv preprint, 2026. URL `https://arxiv.org/abs/2604.13278`. arXiv :2604.13278. Preprint non relu par les pairs.

Michaela Blott, Thomas B. Preußer, Nicholas J. Fraser, Giulio Gambardella, Kenneth O'brien, Yaman Umuroglu, Miriam Leeser, and Kees Vissers. FINN-R : An End-to-End Deep-Learning Framework for Fast Exploration of Quantized Neural Networks. *ACM Transactions on Reconfigurable Technology and Systems 11(3)*, 2018. doi : 10.1145/3242897. URL `https://arxiv.org/abs/1809.04570`.

Behzad Boroujerdian, Hasan Genc, Srivatsan Krishnan, Wenzhi Cui, Aleksandra Faust, and Vijay Janapa Reddi. MAVBench : Micro Aerial Vehicle Benchmarking. In *2018 51st Annual IEEE/ACM International Symposium on Microarchitecture (MICRO)*, 2019. URL `https://arxiv.org/abs/1905.06388`.

Rik J Bouwmeester, Federico Paredes-Vallés, and Guido C H E De Croon. NanoFlowNet : Real-time Dense Optical Flow on a Nano Quadcopter. arXiv preprint, 2022. URL `https://arxiv.org/abs/2209.06918`. arXiv :2209.06918. Preprint non relu par les pairs.

Riccardo Calì, Laura Falaschetti, and Giorgio Biagetti. Optimized Implementation of YOLOv3-Tiny for Real-Time Image and Video Recognition on FPGA. *Electronics 14(20), 3993*, 2025. doi : 10.3390/electronics14203993. URL https://doi.org/10.3390/electronics14203993.

Jinshan Cao, Wenshu Bao, Haixing Shang, Ming Yuan, and Qian Cheng. GCL-YOLO : A GhostConv-Based Lightweight YOLO Network for UAV Small Object Detection. *Remote Sensing 15(20), 4932*, 2023. doi : 10.3390/rs15204932. URL https://doi.org/10.3390/rs15204932.

Ziang Cao, Changhong Fu, Junjie Ye, Bowen Li, and Yiming Li. SiamAPN++ : Siamese Attentional Aggregation Network for Real-Time UAV Tracking. arXiv preprint, 2021a. URL https://arxiv.org/abs/2106.08816. arXiv :2106.08816. Preprint non relu par les pairs.

Ziang Cao, Changhong Fu, Junjie Ye, Bowen Li, and Yiming Li. HiFT : Hierarchical Feature Transformer for Aerial Tracking. arXiv preprint, 2021b. URL https://arxiv.org/abs/2108.00202. arXiv :2108.00202. Preprint non relu par les pairs.

Ziang Cao, Ziyuan Huang, Liang Pan, Shiwei Zhang, Ziwei Liu, and Changhong Fu. TCTrack : Temporal Contexts for Aerial Tracking. arXiv preprint, 2022. URL https://arxiv.org/abs/2203.01885. arXiv :2203.01885. Preprint non relu par les pairs.

Guanghai Ding, Yihua Ren, Yuting Liu, Qijun Zhao, and Shuiwang Li. Vision-Based Anti Unmanned Aerial Technology : Opportunities and Challenges. arXiv preprint, 2025. URL https://arxiv.org/abs/2507.10006. arXiv :2507.10006. Preprint non relu par les pairs.

Yifei Dong, Fengyi Wu, Sanjian Zhang, Guangyu Chen, Yuzhi Hu, Masumi Yano, Jingdong Sun, Siyu Huang, Feng Liu, Qi Dai, and Zhi-Qi Cheng. Securing the Skies : A Comprehensive Survey on Anti-UAV Methods, Benchmarking, and Future Directions. arXiv preprint, 2025. URL https://arxiv.org/abs/2504.11967. arXiv :2504.11967. Preprint non relu par les pairs.

Dawei Du, Yuankai Qi, Hongyang Yu, Yifan Yang, Kaiwen Duan, Guorong Li, Weigang Zhang, Qingming Huang, and Qi Tian. The Unmanned Aerial Vehicle Benchmark : Object Detection and Tracking. arXiv preprint, 2018. URL https://arxiv.org/abs/1804.00518. arXiv :1804.00518. Preprint non relu par les pairs.

Yan Du, Teng Wu, Zifeng Dai, Hui Xie, Changzhen Hu, and Shengjun Wei. F-yolov7 : fast and robust real-time UAV detection. *Computing 107(1), 50*, 2025. doi : 10.1007/s00607-024-01406-7. URL https://doi.org/10.1007/s00607-024-01406-7.

Anubhav Elhence, Anubhav Panda, Vinay Chamola, and Biplab Sikdar. FPGA-Accelerated YOLOX With Enhanced Attention Mechanisms for Real-Time Wildfire Detection on AAVs. *IEEE Transactions on Instrumentation and Measurement 74, 1-14*, 2025. doi : 10.1109/TIM.2025.3556164. URL https://doi.org/10.1109/TIM.2025.3556164.

Haogang Feng, Gaoze Mu, Shida Zhong, Peichang Zhang, and Tao Yuan. Benchmark Analysis of YOLO Performance on Edge Intelligence Devices. *Cryptography 6(2), 16*, 2022. doi : 10.3390/cryptography6020016. URL https://doi.org/10.3390/cryptography6020016.

Eric Flamand, Davide Rossi, Francesco Conti, Igor Loi, Antonio Pullini, Florent Rotenberg, and Luca Benini. GAP-8 : A RISC-V SoC for AI at the Edge of the IoT. In *2018 IEEE 29th International Conference on Application-specific Systems, Architectures and Processors (ASAP) 1-4*, 2018. doi : 10.1109/ASAP.2018.8445101. URL https://doi.org/10.1109/ASAP.2018.8445101.

Xiaofeng Fu, Guoting Wei, Xia Yuan, Yongshun Liang, and Yuming Bo. Efficient YOLOv7-Drone : An Enhanced Object Detection Approach for Drone Aerial Imagery. *Drones 7(10), 616*, 2023. doi : 10.3390/drones7100616. URL https://doi.org/10.3390/drones7100616.

Depeng Gao, Jianlin Tang, Hongqi Li, Bingshu Wang, Jianlin Qiu, Shuxi Chen, and Xiangxiang Mei. A Novel Dataset and Detection Method for Unmanned Aerial Vehicles Using an Improved YOLOv9 Algorithm. *Sensors 24(23), 7512*, 2024. doi : 10.3390/s24237512. URL https://doi.org/10.3390/s24237512.

Hanqing Guo, Ye Zheng, Yin Zhang, Zhi Gao, and Shiyu Zhao. Global-Local MAV Detection under Challenging Conditions based on Appearance and Motion. arXiv preprint, 2023. URL https://arxiv.org/abs/2312.11008. arXiv :2312.11008. Preprint non relu par les pairs.

Junpeng Guo, Bo Jiang, and Hong Xu. FPGA-based UAV Heterogeneous Computing Platform Architecture. In *2021 6th International Conference on Computational Intelligence and Applications (ICCIA) 252-256*, 2021. doi : 10.1109/ICCIA52886.2021.00056. URL https://doi.org/10.1109/ICCIA52886.2021.00056.

Drew Hanover, Antonio Loquercio, Leonard Bauersfeld, Angel Romero, Robert Penicka, Yunlong Song, Giovanni Cioffi, Elia Kaufmann, and Davide Scaramuzza. Autonomous Drone Racing : A Survey. *IEEE Transactions on Robotics (T-RO), Vol. 40, 2024*, 2023. doi : 10.1109/TRO.2024.3400838. URL https://arxiv.org/abs/2301.01755.

Seyed Hani Hozhabr and Roberto Giorgi. A Survey on Real-Time Object Detection on FPGAs. *IEEE Access 13, 38195-38238*, 2025. doi : 10.1109/ACCESS.2025.3544515. URL https://doi.org/10.1109/ACCESS.2025.3544515.

Bo Huang, Jianan Li, Junjie Chen, Gang Wang, Jian Zhao, and Tingfa Xu. Anti-UAV410 : A Thermal Infrared Benchmark and Customized Scheme for Tracking Drones in the Wild. *IEEE Transactions on Pattern Analysis and Machine Intelligence 46(5), 2852-2865*, 2024. doi : 10.1109/TPAMI.2023.3335338. URL https://doi.org/10.1109/TPAMI.2023.3335338.

Yecheng Huang, Jiaxin Chen, and Di Huang. UFPMP-Det : Toward Accurate and Efficient Object Detection on Drone Imagery. arXiv preprint, 2021. URL https://arxiv.org/abs/2112.10415. arXiv :2112.10415. Preprint non relu par les pairs.

Brian K S Isaac-Medina, Matt Poyser, Daniel Organisciak, Chris G Willcocks, Toby P Breckon, and Hubert P H Shum. Unmanned Aerial Vehicle Visual Detection and Tracking using Deep Neural Networks : A Performance Benchmark. arXiv preprint, 2021. URL https://arxiv.org/abs/2103.13933. arXiv :2103.13933. Preprint non relu par les pairs.

Nan Jiang, Kuiran Wang, Xiaoke Peng, Xuehui Yu, Qiang Wang, Junliang Xing, Guorong Li, Jian Zhao, Guodong Guo, and Zhenjun Han. Anti-UAV : A Large Multi-Modal Benchmark for UAV Tracking. arXiv preprint, 2021. URL https://arxiv.org/abs/2101.08466. arXiv :2101.08466. Preprint non relu par les pairs.

Hyun-Ki Jung. YOLO-Drone : An Efficient Object Detection Approach Using the GhostHead Network for Drone Images. *Journal of Information Systems Engineering and Management, Vol. 10, No. 26s, 2025, pp. 236-247*, 2025. doi : 10.52783/jisem.v10i26s.4216. URL https://arxiv.org/abs/2511.10905.

Hyun-Ki Jung and Gi-Sang Choi. Improved YOLOv5 : Efficient Object Detection Using Drone Images under Various Conditions. *Applied Sciences 12(14), 7255*, 2022. doi : 10.3390/app12147255. URL https://doi.org/10.3390/app12147255.

Suraj Karki, Qazi Arbab Ahmed, and Thorsten Jungeblut. No Attention, No Problem : DPU-Aware Attention Approximation in Modern YOLO on FPGA. arXiv preprint, 2026. URL https://arxiv.org/abs/2607.13106. arXiv :2607.13106. Preprint non relu par les pairs.

Elia Kaufmann, Leonard Bauersfeld, Antonio Loquercio, Matthias Müller, Vladlen Koltun, and Davide Scaramuzza. Champion-level drone racing using deep reinforcement learning. *Nature 620(7976), 982-987*, 2023. doi : 10.1038/s41586-023-06419-4. URL https://doi.org/10.1038/s41586-023-06419-4.

Srivatsan Krishnan, Zishen Wan, Kshitij Bhardwaj, Paul Whatmough, Aleksandra Faust, Gu-Yeon Wei, David Brooks, and Vijay Janapa Reddi. The Sky Is Not the Limit : A Visual Performance Model for Cyber-Physical Co-Design in Autonomous Machines. *IEEE Computer Architecture Letters 19(1), 38-42*, 2020. doi : 10.1109/LCA.2020.2981022. URL https://doi.org/10.1109/LCA.2020.2981022.

Srivatsan Krishnan, Zishen Wan, Kshitij Bhardwaj, Ninad Jadhav, Aleksandra Faust, and Vijay Janapa Reddi. Roofline Model for UAVs : A Bottleneck Analysis Tool for Onboard Compute Characterization of Autonomous Unmanned Aerial Vehicles. arXiv preprint, 2022. URL https://arxiv.org/abs/2204.10898. arXiv :2204.10898. Preprint non relu par les pairs.

Lorenzo Lamberti, Luca Bompani, Victor Javier Kartsch, Manuele Rusci, Daniele Palossi, and Luca Benini. Bio-inspired Autonomous Exploration Policies with CNN-based Object Detection on Nano-drones. arXiv preprint, 2023. URL https://arxiv.org/abs/2301.12175. arXiv :2301.12175. Preprint non relu par les pairs.

Lorenzo Lamberti, Vlad Niculescu, Michał Barcis, Lorenzo Bellone, Enrico Natalizio, Luca Benini, and Daniele Palossi. Tiny-PULP-Dronets : Squeezing Neural Networks for Faster and Lighter Inference on Multi-Tasking Autonomous Nano-Drones. arXiv preprint, 2024. URL https://arxiv.org/abs/2407.02405. arXiv :2407.02405. Preprint non relu par les pairs.

Haiying Liu, Fengqian Sun, Jason Gu, and Lixia Deng. SF-YOLOv5 : A Lightweight Small Object Detection Algorithm Based on Improved Feature Fusion Mode. *Sensors 22(15), 5817*, 2022. doi : 10.3390/s22155817. URL https://doi.org/10.3390/s22155817.

Hansen Liu, Kuangang Fan, Qinghua Ouyang, and Na Li. Real-Time Small Drones Detection Based on Pruned YOLOv4. *Sensors 21(10), 3374*, 2021. doi : 10.3390/s21103374. URL https://doi.org/10.3390/s21103374.

Juanqin Liu, Leonardo Plotegher, Eloy Roura, Cristino De Souza Junior, and Shaoming He. Real-Time Detection for Small UAVs : Combining YOLO and Multi-frame Motion Analysis. arXiv preprint, 2024. URL https://arxiv.org/abs/2411.02582. arXiv :2411.02582. Preprint non relu par les pairs.

Antonio Loquercio, Elia Kaufmann, René Ranftl, Matthias Müller, Vladlen Koltun, and Davide Scaramuzza. Learning High-Speed Flight in the Wild. *Science Robotics 2021 Vol. 6, Issue 59, abg5810*, 2021. doi : 10.1126/scirobotics.abg5810. URL https://arxiv.org/abs/2110.05113.

Carlo Marra, Beatrice Alessandra Motetti, Alessio Burrello, Enrico Macii, Massimo Poncino, and Daniele Jahier Pagliari. BlankSkip : Early-exit Object Detection onboard Nano-drones. arXiv preprint, 2026. URL https://arxiv.org/abs/2603.28149. arXiv :2603.28149. Preprint non relu par les pairs.

Alexander Montgomerie-Corcoran, Petros Toupas, Zhewen Yu, and Christos-Savvas Bouganis. SATAY : A Streaming Architecture Toolflow for Accelerating YOLO Models on FPGA Devices. In *2023 International Conference on Field Programmable Technology (ICFPT) 179-187*, 2023. doi : 10.1109/ICFPT59805.2023.00025. URL https://doi.org/10.1109/ICFPT59805.2023.00025.

Julian Moosmann, Marco Giordano, Christian Vogt, and Michele Magno. TinyissimoYOLO : A Quantized, Low-Memory Footprint, TinyML Object Detection Network for Low Power Microcontrollers. In *IEEE AICAS 2023 (d'après le DOI 10.1109/AICAS57966.2023.10168657)*, 2023. doi : 10.1109/AICAS57966.2023.10168657. URL https://arxiv.org/abs/2306.00001.

Aditya Prashant Naidu, Hem Gosalia, Ishaan Gakhar, Shaurya Singh Rathore, Krish Didwania, and Ujjwal Verma. DEAL-YOLO : Drone-based Efficient Animal Localization using YOLO. arXiv preprint, 2025. URL https://arxiv.org/abs/2503.04698. arXiv :2503.04698. Preprint non relu par les pairs.

Dai-Duong Nguyen, Dang-Tuan Nguyen, Minh-Thuy Le, and Quoc-Cuong Nguyen. FPGA-SoC implementation of YOLOv4 for flying-object detection. *Journal of Real-Time Image Processing 21(3), 63*, 2024. doi : 10.1007/s11554-024-01440-w. URL https://doi.org/10.1007/s11554-024-01440-w.

Daniele Palossi, Antonio Loquercio, Francesco Conti, Eric Flamand, Davide Scaramuzza, and Luca Benini. A 64mW DNN-based Visual Navigation Engine for Autonomous Nano-Drones. arXiv preprint, 2018. URL https://arxiv.org/abs/1805.01831. arXiv :1805.01831. Preprint non relu par les pairs.

Daniele Palossi, Nicky Zimmerman, Alessio Burrello, Francesco Conti, Hanna Müller, Luca Maria Gambardella, Luca Benini, Alessandro Giusti, and Jérôme Guzzi. Fully Onboard AI-powered Human-Drone Pose Estimation on Ultra-low Power Autonomous Flying Nano-UAVs. arXiv preprint, 2021. URL https://arxiv.org/abs/2103.10873. arXiv :2103.10873. Preprint non relu par les pairs.

Federico Paredes-Vallés, Jesse Hagenaars, Julien Dupeyroux, Stein Stroobants, Yingfu Xu, and Guido de Croon. Fully neuromorphic vision and control for autonomous drone flight. arXiv preprint, 2023. URL https://arxiv.org/abs/2303.08778. arXiv :2303.08778. Preprint non relu par les pairs.

Mahyar Pourjabar, Ahmed Alkatheeri, Manuele Rusci, Agata Barcis, Vlad Niculescu, Eliseo Ferrante, Daniele Palossi, and Luca Benini. Land & Localize : An Infrastructure-free and Scalable Nano-Drones Swarm with UWB-based Localization. arXiv preprint, 2023. URL https://arxiv.org/abs/2307.10255. arXiv :2307.10255. Preprint non relu par les pairs.

Lucas Rey, Ana M Bernardos, Andrzej D Dobrzycki, David Carramiñana, Luca Bergesio, Juan A Besada, and José Ramón Casar. A Performance Analysis of You Only Look Once Models for Deployment on Constrained Computational Edge Devices in Drone Applications. *Electronics 2025, 14(3), 638*, 2025. doi : 10.3390/electronics14030638. URL https://arxiv.org/abs/2502.15737.

Safa Mohammed Sali, Mahmoud Meribout, and Ashiyana Abdul Majeed. Real Time FPGA Based CNNs for Detection, Classification, and Tracking in Autonomous Systems : State of the Art Designs and Optimizations. arXiv preprint, 2025. URL https://arxiv.org/abs/2509.04153. arXiv :2509.04153. Preprint non relu par les pairs.

Ulzhalgas Seidaliyeva, Daryn Akhmetov, Lyazzat Ilipbayeva, and Eric T. Matson. Real-Time and Accurate Drone Detection in a Video with a Static Background. *Sensors 20(14), 3856*, 2020. doi : 10.3390/s20143856. URL https://doi.org/10.3390/s20143856.

Amr Suleiman, Zhengdong Zhang, Luca Carlone, Sertac Karaman, and Vivienne Sze. Navion : A 2-mW Fully Integrated Real-Time Visual-Inertial Odometry Accelerator for Autonomous Navigation of Nano Drones. *IEEE Journal of Solid-State Circuits 54(4), 1106-1119*, 2019. doi : 10.1109/JSSC.2018.2886342. URL https://doi.org/10.1109/JSSC.2018.2886342.

Fredrik Svanstrom, Cristofer Englund, and Fernando Alonso-Fernandez. Real-Time Drone Detection and Tracking With Visible, Thermal and Acoustic Sensors. In *Proc. Intl Conf on Pattern Recognition, ICPR, Milan, Italy, 10-15 January 2021*, 2020. URL https://arxiv.org/abs/2007.07396.

Antonio Vitale, Alpha Renner, Celine Nauer, Davide Scaramuzza, and Yulia Sandamirskaya. Event-driven Vision and Control for UAVs on a Neuromorphic Chip. arXiv preprint, 2021. URL https://arxiv.org/abs/2108.03694. arXiv :2108.03694. Preprint non relu par les pairs.

Zishen Wan, Ashwin Lele, Bo Yu, Shaoshan Liu, Yu Wang, Vijay Janapa Reddi, Cong Hao, and Arijit Raychowdhury. Robotic Computing on FPGAs : Current Progress, Research Challenges, and Opportunities. arXiv preprint, 2022. URL https://arxiv.org/abs/2205.07149. arXiv :2205.07149. Preprint non relu par les pairs.

Xiaowei Xu, Xinyi Zhang, Bei Yu, Xiaobo Sharon Hu, Christopher Rowen, Jingtong Hu, and Yiyu Shi. DAC-SDC Low Power Object Detection Challenge for UAV Applications. *IEEE Transactions on Pattern Analysis and Machine Intelligence 43(2), 392-403*, 2021. doi : 10.1109/TPAMI.2019.2932429. URL https://doi.org/10.1109/TPAMI.2019.2932429.

Chenhongyi Yang, Zehao Huang, and Naiyan Wang. QueryDet : Cascaded Sparse Query for Accelerating High-Resolution Small Object Detection. arXiv preprint, 2021. URL https://arxiv.org/abs/2103.09136. arXiv :2103.09136. Preprint non relu par les pairs.

Fan Yang, Heng Fan, Peng Chu, Erik Blasch, and Haibin Ling. Clustered Object Detection in Aerial Images. arXiv preprint, 2019. URL https://arxiv.org/abs/1904.08008. arXiv :1904.08008. Preprint non relu par les pairs.

Wanjun Yu and Kongxin Mo. YOLO-GCOF : A Lightweight Low-Altitude Drone Detection Model. *IEEE Access 13, 53053-53064*, 2025. doi : 10.1109/ACCESS.2025.3553477. URL https://doi.org/10.1109/ACCESS.2025.3553477.

Chunhui Zhang, Guanjie Huang, Li Liu, Shan Huang, Yinan Yang, Xiang Wan, Shiming Ge, and Dacheng Tao. WebUAV-3M : A Benchmark for Unveiling the Power of Million-Scale Deep UAV Tracking. arXiv preprint, 2022. URL https://arxiv.org/abs/2201.07425. arXiv :2201.07425. Preprint non relu par les pairs.

Jingwei Zhang, Guoqing Li, Meng Zhang, Xinye Cao, Yu Zhang, Xiang Li, Ziyang Chen, and Jun Yang. A comprehensive analysis of DAC-SDC FPGA low power object detection challenge. *Science China Information Sciences 67(8), 182401*, 2024. doi : 10.1007/s11432-023-3958-4. URL https://doi.org/10.1007/s11432-023-3958-4.

Pengyi Zhang, Yunxin Zhong, and Xiaoqiong Li. SlimYOLOv3 : Narrower, Faster and Better for Real-Time UAV Applications. arXiv preprint, 2019a. URL https://arxiv.org/abs/1907.11093. arXiv :1907.11093. Preprint non relu par les pairs.

Xiaofan Zhang, Haoming Lu, Cong Hao, Jiachen Li, Bowen Cheng, Yuhong Li, Kyle Rupnow, Jinjun Xiong, Thomas Huang, Honghui Shi, Wen-Mei Hwu, and Deming Chen. SkyNet : a Hardware-Efficient Method for Object Detection and Tracking on Embedded Systems. arXiv preprint, 2019b. URL https://arxiv.org/abs/1909.09709. arXiv :1909.09709. Preprint non relu par les pairs.

Zhengxin Zhang. Drone-YOLO : An Efficient Neural Network Method for Target Detection in Drone Images. *Drones 7(8), 526*, 2023. doi : 10.3390/drones7080526. URL https://doi.org/10.3390/drones7080526.

Qi Zhao, Binghao Liu, Shuchang Lyu, Chunlei Wang, and Hong Zhang. TPH-YOLOv5++ : Boosting Object Detection on Drone-Captured Scenarios with Cross-Layer Asymmetric Transformer. *Remote Sensing 15(6), 1687*, 2023. doi : 10.3390/rs15061687. URL https://doi.org/10.3390/rs15061687.

Ye Zheng, Zhang Chen, Dailin Lv, Zhixing Li, Zhenzhong Lan, and Shiyu Zhao. Air-to-Air Visual Detection of Micro-UAVs : An Experimental Evaluation of Deep Learning. *IEEE Robotics and Automation Letters 6(2), 1020-1027*, 2021. doi : 10.1109/LRA.2021.3056059. URL `https://doi.org/10.1109/LRA.2021.3056059`.

Ye Zheng, Canlun Zheng, Xiaoyu Zhang, Fei Chen, Zhang Chen, and Shiyu Zhao. Detection, Localization, and Tracking of Multiple MAVs With Panoramic Stereo Camera Networks. *IEEE Transactions on Automation Science and Engineering 20(2), 1226-1243*, 2023. doi : 10.1109/TASE.2022.3176294. URL `https://doi.org/10.1109/TASE.2022.3176294`.

Pengfei Zhu, Longyin Wen, Dawei Du, Xiao Bian, Heng Fan, Qinghua Hu, and Haibin Ling. Detection and Tracking Meet Drones Challenge. arXiv preprint, 2020. URL `https://arxiv.org/abs/2001.06303`. arXiv :2001.06303. Preprint non relu par les pairs.

Xingkui Zhu, Shuchang Lyu, Xu Wang, and Qi Zhao. TPH-YOLOv5 : Improved YOLOv5 Based on Transformer Prediction Head for Object Detection on Drone-captured Scenarios. arXiv preprint, 2021. URL `https://arxiv.org/abs/2108.11539`. arXiv :2108.11539. Preprint non relu par les pairs.