Vision embarquée sur drone

État de l'art établi à partir du corpus PaperDatabase (base `drone`)

Léonard Rivals

29 septembre 2026, mis à jour le 1er octobre 2026 — brouillon

Résumé

Ce document fait l'état de l'art de la vision par réseaux de neurones embarquée sur drone. Il couvre les jeux de données, la détection de petits objets, les accélérateurs embarqués (FPGA, MCU, ASIC, neuromorphique), le suivi et la navigation, le contre-drone et le co-design entre calcul, énergie et vol. Il s'appuie sur les 86 fiches de lecture et les 352 lignes de mesures de la base. Chaque chiffre porte sa source, et chaque puissance sa portée. Quatre constats en ressortent. D'abord, les YOLO spécialisés drone (tête P2, Transformer, attention) ne sont mesurés que sur GPU de bureau, alors que les implantations FPGA du corpus restent sur YOLOv3-tiny, YOLOv4 ou YOLOX, parfois amputés de leur branche multi-échelle. Ensuite, aucune des 352 lignes ne rapporte de précision par taille d'objet (AP_S) : l'effet de la quantification sur les petits objets n'est pas mesuré. Troisième constat : les trois gammes de puissance (nano en mW, FPGA en W, Jetson autour de 10 W) ne sont presque jamais comparées sur une même tâche, et 70 % des lignes n'ont pas de puissance ; aucun des 13 articles ajoutés en octobre (GAP9, navigation sur Orin, modèles vision-langage embarqués) n'en mesure à la carte. Enfin, les modèles qui relient latence, masse et vitesse de vol sûre existent (MAVBench, modèle F-1), mais aucun n'a été appliqué à un détecteur sur FPGA. En contre-drone, le cas embarqué (air → air, détecteur sur un intercepteur) n'a été évalué en vol que sur Jetson, sans puissance, et jamais sur SoC FPGA ou MCU. Le document termine sur les gaps et trois questions de thèse candidates.

Table des matières

1 Introduction **3**

2 Méthode et conventions **3**

3 Jeux de données et challenges **4**

3.1 Détection vue du drone : VisDrone et UAVDT 4

3.2 Détection sous contrainte d'énergie : le DAC-SDC 5

3.3 Contre-drone : des jeux surtout sol → air 5

4 Détection de petits objets vus de drone **6**

4.1 La recette dominante : tête P2, attention, suppression de P5 6

4.2 Calculer seulement où sont les objets 7

4.3 Protocoles et comparabilité 7

5 Détection sur FPGA et SoC embarqués **8**

5.1 Le DAC-SDC : cinq ans de co-design sur un petit Zynq 8

5.2 YOLO sur SoC : DPU Vitis AI et dataflow 8

5.3 Surveys FPGA 10

6 Gamme nano : MCU, ASIC et neuromorphique **10**
6.1 Le GAP8 et la lignée PULP 10
6.2 La génération GAP9 12
6.3 ASIC et neuromorphique 13
6.4 Ce que la gamme nano apprend au reste 13

7 Suivi et navigation embarqués **13**
7.1 Suivi mono-objet sur Jetson 13
7.2 Vol agile : la référence Jetson de Zurich 14
7.3 Suivi de cible et navigation sémantique sur Jetson Orin 15
7.4 Localisation et plateformes hétérogènes 16

8 Contre-drone : détecter des drones **16**
8.1 Sol → air : des références de contraste 16
8.2 Air → air : le cas embarqué 17
8.3 Bilan 18

9 Co-design calcul, énergie et vol **18**
9.1 Le calcul agit sur la mission par le temps et la masse 18
9.2 Modèles vision-langage embarqués : où placer le calcul 19
9.3 Fiabilité du calcul embarqué 20

10 Comparer les gammes de puissance **20**
10.1 Débit et puissance rapportés 20
10.2 Les rares comparaisons à modèle égal 21
10.3 Ordres de grandeur par gamme 22
10.4 Couverture du corpus 22

11 Zones non couvertes et pistes de recherche **23**
11.1 Trois gaps structurants 23
11.2 Questions de thèse candidates 23

12 Conclusion **25**

A Glossaire des acronymes **32**

B Lexique **34**

Glossaires **35**

Glossaire des plateformes **35**

Glossaire des modèles **40**

Glossaire des métriques et unités **47**

1 Introduction

Un drone impose au calcul embarqué des contraintes que les benchmarks de vision ignorent : la masse et la puissance du calculateur se paient en autonomie et en agilité, la latence de perception borne la vitesse de vol sûre, et les objets à détecter occupent souvent une infime fraction de l'image. Trois gammes de calcul coexistent : les nano-drones de quelques dizaines de grammes, avec des MCU parallèles comme le GAP8 et le GAP9 (mW) ; les SoC FPGA (quelques W) ; les modules Jetson (autour de 10 W), qui équipent les drones agiles de moins d'un kilogramme.

Ce document répond à trois questions, à partir du corpus seulement :

— quels jeux de données et quels détecteurs font l'état de l'art de la vision depuis un drone, et à quel coût (sections 3 et 4) ?

— que sait-on exécuter à bord, dans chaque gamme de puissance, pour la détection, le suivi et la navigation (sections 5 à 8) ?

— comment relier ces chiffres à la mission du drone, et que reste-t-il à faire (sections 9 à 11) ?

La base `fpga` du même projet traite à part les toolflows, les autoencodeurs et l'apprentissage continu sur FPGA ; ils ne sont repris ici que lorsqu'un article porte sur le drone.

2 Méthode et conventions

Corpus. Ce document ne s'appuie que sur la base `drone` de PaperDatabase telle qu'elle était le 1er octobre 2026 : 86 articles, tous dotés d'une fiche de lecture complète, et 352 lignes de mesures dans `benchmarks.csv`, issues de 67 articles. La première version (29 septembre) reposait sur 73 articles et 324 lignes ; les 13 articles ajoutés portent surtout sur la navigation, le SoC GAP9 et les modèles vision-langage embarqués. Un 87e article de la base, consacré au guidage terminal d'un drone vers une cible, n'est pas traité. Aucune référence extérieure à la base n'est citée comme source. Les travaux cités par un survey sont signalés comme tels ; leurs chiffres ne sont pas vérifiés à la source et servent à orienter la lecture, pas à comparer.

Table 1 – Composition du corpus. Un article peut relever de plusieurs axes.

Axe	Articles	Axe	Articles
Détection drone, petits objets	29	Nano-drones, MCU, ASIC, neuromorphique	20
Suivi et navigation	37	Accélération FPGA / SoC	14
Contre-drone	19	Co-design calcul–énergie–vol	19
Jeux de données et challenges	16	Surveys	8
		Fiabilité du calcul embarqué	2

Types : 30 articles de journal, 7 de conférence, 49 preprints arXiv (dont plusieurs publiés depuis, voir le texte).
Années : 2016–2020 : 14 ; 2021–2023 : 38 ; 2024–2026 : 34.

Origine des chiffres. Chaque valeur est reprise de la fiche ou de `benchmarks.csv`, avec la section ou le tableau de l'article entre crochets, par exemple [Table 4]. Une valeur que les auteurs ne donnent pas s'écrit `n/r` : elle n'est jamais estimée. Un calcul fait à partir des chiffres publiés (par exemple un FPS/W) est marqué *(déduit)*. Sur les 352 lignes, 177 sont en confiance *high* et 175 en *medium* : valeurs lues dans le texte qui commente une figure, ou tableaux reconstruits automatiquement. Ces dernières sont marquées [m] dans les tableaux. Aucune ligne n'est en confiance *low*.

Portée de la puissance. Une puissance n'a de sens qu'avec sa portée. La base distingue *board* (carte entière, au wattmètre), *chip* (rails de la puce ou télémétrie embarquée comme `tegrastats`), *estimated* (outil de conception, par exemple Vivado) et *unspecified* (méthode non décrite). Sur les 352 lignes, 247 n'ont pas de puissance (70 %) ; les autres se répartissent en 51 *board*, 20 *chip*, 32

unspecified et 2 *estimated*. Aucune des 28 lignes ajoutées le 1er octobre n'a de puissance mesurée à la carte. Deux puissances de portées différentes ne se comparent pas.

Gamme de puissance. Tout résultat est situé dans une gamme : *nano* (GAP8, MCU, ASIC ; de quelques mW à quelques centaines de mW), *FPGA* (SoC Zynq ou Kria, de 1 à 30 W selon la carte), *Jetson* (autour de 10 W, de 5 à 30 W selon le module et le mode). Les résultats sur GPU de bureau (RTX, Titan, Tesla) sont signalés comme tels : ils ne sont jamais des résultats embarqués, quoi qu'en dise leur titre.

Métriques de précision. Elles ne se comparent qu'à protocole égal. L'IoU moyen mono-objet du DAC-SDC n'est pas une mAP ; la mAP@0.5 de VisDrone n'est pas l'AP COCO [.5 :.95] du protocole officiel ; l'AP d'UAVDT est calculée à IoU 0,7 dans l'article d'origine ; certains travaux de contre-drone évaluent à IoU 0,1 ou 0,25.

Contre-drone : point de vue du capteur. Chaque article de contre-drone est classé *air* → *air* (détecteur à bord d'un drone), *sol* → *air* (capteur fixe au sol) ou point de vue non déclaré. Seul le premier relève de l'IA embarquée ; les autres sont cités comme jeux de données, métriques ou contrastes.

Lu contre déduit. Sauf mention, une affirmation résume ce que disent les auteurs. Une inférence de la fiche ou de ce document est marquée *(déduit)*. Un article marqué PP est un preprint non relu par les pairs dans la version ingérée ; quand une version publiée existe probablement, le texte le dit.

Limites de la méthode. Le corpus est petit et vient d'une bibliographie de départ constituée à partir de résumés. Il compte peu d'articles FPGA propres au drone (10 papiers mesurés sur FPGA) et seulement deux sur la fiabilité. Un « gap » signifie qu'un sujet est absent *de ce corpus* ; son absence de la littérature reste une hypothèse tant qu'une recherche ciblée ne l'a pas confirmée. Les fiches ont été rédigées à partir du texte extrait des PDF : les valeurs données seulement dans des figures sont souvent `n/r`.

3 Jeux de données et challenges

3.1 Détection vue du drone : VisDrone et UAVDT

VisDrone. Zhu et al. (2020)PP résument trois éditions du challenge (2018–2020). Le jeu compte 263 clips (179 264 images) et 10 209 images fixes, plus de 2,5 millions de boîtes sur 10 catégories, prises par des DJI dans 14 villes chinoises, jusqu'à 2000×1500 en image fixe [§1]. La tâche DET se découpe en 6 471 / 548 / 1 580 / 1 610 images (train / val / test-challenge / test-dev) [§4.1] et suit le protocole AP COCO. Le meilleur résultat de 2020, DroneEye2020 (Cascade R-CNN + DetectoRS), atteint 34,57 d'AP [Table 2] ; le meilleur détecteur reste sous 25 % sur *person* et *bicycle* [§4.5]. Les auteurs reconnaissent que les soumissions privilégient la précision sur l'efficacité : les méthodes vidéo tournent à moins de 10 FPS sur une GTX 1080Ti [§5.3, §8]. Le §8 formule d'ailleurs le problème de la thèse : les ressources d'un drone rendent impossible le déploiement de gros modèles.

UAVDT. Du et al. (2018)PP (version ECCV 2018 probable, non vérifiée) proposent 100 séquences urbaines à 1080×540, environ 80 000 images annotées et 0,84 M de boîtes de véhicules, avec des attributs d'altitude, de vue et de météo [§2.1]. 27,5 % des objets font moins de 400 pixels [§4]. Le meilleur détecteur (R-FCN) obtient 34,35 % d'AP, mais à un seuil d'IoU de 0,7 [§3.1] : ces chiffres ne se comparent pas aux AP@0.5 publiés ensuite sur UAVDT. L'attribut altitude relie directement la précision à un paramètre de vol *(déduit)*.

3.2 Détection sous contrainte d'énergie : le DAC-SDC

Le Low Power Object Detection Challenge du DAC est le seul contexte du corpus où la précision, le débit et l'énergie sont mesurés par un tiers selon un protocole commun, sur plateforme imposée. Xu et al. (2021) décrivent l'édition 2018 : images DJI 640×360, un seul objet par image, la plupart occupant 1 à 2 % de l'image ; plateformes PYNQ-Z1 et Jetson TX2 ; énergie mesurée au wattmètre pour le FPGA [§2]. Zhang et al. (2024) étendent l'analyse aux éditions 2018–2022 (PYNQ-Z1 puis Ultra96) et en tirent des règles de co-design (section 5).

Deux réserves pèsent sur toute réutilisation. La métrique est un IoU moyen sans classe sur un objet unique, qui ne se compare pas à une mAP multi-classe (Zhang et al., 2024, §2.3). Et la règle de mesure change : à partir de 2022, le temps ne compte plus le chargement des images [§2.3], ce qui explique une partie du saut de débit de cette édition.

3.3 Contre-drone : des jeux surtout sol → air

Le tableau 2 classe les jeux du corpus par point de vue. Le constat est net : les grands jeux (Anti-UAV, Anti-UAV410, Drone-vs-Bird, DUT Anti-UAV) sont pris depuis le sol ou ne déclarent pas le capteur ; les jeux air → air sont petits et récents. Aucun ne comporte de piste « efficacité » (FPS, puissance, plateforme) : le survey de Ding et al. (2025)[PP] le relève lui-même [§V-A].

Table 2 – Jeux de contre-drone du corpus, par point de vue du capteur.

Jeu, article	Point de vue	Contenu	Métrique
Det-Fly (Zheng et al., 2021)	air → air	13 271 images 4K, un DJI Mavic filmé par un M210, 10–100 m ; public [§III]	AP
NPS-Drones, FL-Drones, ré-annotés (Ashraf et al., 2021)[PP]	air → air	50 et 14 vidéos ; cibles de 0,05 et 0,07 % de l'image [§1]	AP, F1
ARD-MAV (Guo et al., 2023)[PP]	air → air	60 vidéos 1920×1080, 106 665 images, cibles de 0,02 % de l'image en moyenne [Table I]	AP50
Anti2 (Gao et al., 2024)	mixte	5 062 images, 4 classes (drone, oiseau, hélicoptère, avion) [§3]	mAP@0.5
Anti-UAV (Jiang et al., 2021)[PP]	non déclaré (sol probable)	318 paires RGB–IR non alignées, cibles < 40 px [Table I]	mSA
Anti-UAV410 (Huang et al., 2024)	non déclaré (sol probable)	410 séquences IR, plus de 100 à drone < 10 px [§III]	SA
MAV-VID, Drone-vs-Bird (Isaac-Medina et al., 2021)[PP]	surtout sol → air	64 et 77 vidéos ; Drone-vs-Bird : cibles de 0,10 % [§3.1]	AP50
Halmstad (Svanstrom et al., 2020)	sol → air	650 vidéos IR + visible, 90 clips audio ; public [§IV]	F1

Suivi vu du drone. WebUAV-3M (Zhang et al., 2022)[PP] compte 4 500 vidéos et 3,3 M d'images issues surtout de YouTube [§3.2]. Il évalue 43 trackers sur GPU de bureau et montre que la précision s'effondre sous 30 pixels de cible [§5.6].

Ce que les jeux ne mesurent pas. Aucun des grands benchmarks du corpus (VisDrone, UAVDT, Anti-UAV, Anti-UAV410, WebUAV-3M, Det-Fly) ne rapporte de débit sur plateforme embarquée ni de puissance. Seul le DAC-SDC le fait, au prix d'une tâche simplifiée. Les AP par taille d'objet sont rares même dans les jeux dédiés aux petits objets : VisDrone ne publie pas d'AP_S séparé dans ses tableaux de synthèse (Zhu et al., 2020, §4).

4 Détection de petits objets vus de drone

4.1 La recette dominante : tête P2, attention, suppression de P5

Les YOLO spécialisés drone du corpus modifient tous la pyramide de caractéristiques pour les petits objets. Trois gestes reviennent : ajouter une tête P2 (stride 4, carte de 160×160 pour une entrée de 640), ajouter de l'attention ou des blocs Transformer, et supprimer la tête P5, qui porte beaucoup de paramètres mais sert surtout aux grands objets.

TPH-YOLOv5 et TPH-YOLOv5++. TPH-YOLOv5 (Zhu et al., 2021)[PP] est la référence de cette famille : YOLOv5x, quatrième tête P2, têtes à Transformer, CBAM, test multi-échelle et ensemble de cinq modèles. L'ensemble atteint 39,18 de mAP [.5 :.95] sur le test-challenge VisDrone 2021 [§4.2][m], sur RTX 3090, sans aucune vitesse rapportée. La tête P2 fait passer YOLOv5x de 219 à 259 GFLOPs [§4.3]. Zhao et al. (2023) mesurent ce coût : la tête P2 seule apporte +2,1 points d'AP, fait passer la mémoire GPU de 4 279 à 4 667 Mo et le débit de 13,68 à 10,89 FPS [Table 5]. TPH-YOLOv5++ remplace la tête P2 par un transfert d'information vers P3 (CA-Trans) et remonte à 11,86 FPS pour 33,1 d'AP sur test-dev, contre 7,36 FPS et 34,0 pour TPH-YOLOv5 [Table 5] ; toujours sur RTX 3090 Ti, à 1536×1536.

Variantes légères. Le tableau 3 rassemble les autres variantes. Toutes allègent le réseau en paramètres ; aucune ne mesure son coût sur une cible embarquée, sauf Drone-YOLO.

TABLE 3 – YOLO spécialisés drone du corpus, sur VisDrone. Plateformes de bureau sauf mention. Protocoles hétérogènes (split, résolution, métrique) : la colonne précision ne permet pas de classer.

Modèle	Modification principale	Précision	Coût, plateforme
GCL-YOLO-S (Cao et al., 2023)	GhostConv, P2 ajoutée, P5 retirée ; 1,64 M param.	39,6 mAP50 [Table 3]	53 FPS, GPU n/r
Efficient YOLOv7-Drone (Fu et al., 2023)	P2, P5 retirée, convolution creuse guidée par le premier plan	32,1 AP (val, 640) [Table 2]	89 FPS contre 213 pour YOLOv7, RTX 3090 [Table 5]
Drone-YOLO nano (Zhang, 2023)	P2, sandwich-fusion, RepVGG ; 3,05 M param.	38,1 mAP50 (val) [Table 5]	127,4 ms sur Jetson TX2 [Table 6]
SF-YOLOv5 (Liu et al., 2022)	P5 retirée, PB-FPN ; 2,23 M param.	34,3 mAP50[m] [Table 4]	11,5 ms, RTX 2060
DroneScan-YOLO (Bellec, 2026)[PP]	entrée 1280, branche P2, pruning non structuré	55,3 mAP50 (val) [Table 4]	96,7 FPS, RTX 4090 portable
YOLO-Drone (Jung, 2025)	GhostConv dans la tête de YOLOv11n	30,4 mAP50 [Table 2]	1,8 ms, Tesla T4
DEAL-YOLO (Naidu et al., 2025)[PP]	P2 à la place de P5, NWD ; faune (hors VisDrone)	48,5 mAP50, BuckTales [Table 1]	n/r

Ce que coûte la tête P2. Trois articles donnent un chiffre. Drone-YOLO nano met 127,4 ms par image sur Jetson TX2, contre 30,8 ms pour YOLOv8n à nombre de paramètres égal, soit quatre fois plus lent pour +4,1 points de mAP50 (Zhang, 2023, Table 6) ; l'auteur conclut pourtant à des résultats « highly accurate » sans commenter la latence. Pour Efficient YOLOv7-Drone, ajouter P2 fait tomber le débit de 212,8 à 137,0 FPS sur RTX 3090 (Fu et al., 2023, Table 5). GCL-YOLO-S perd 7 FPS face à YOLOv5-S alors que ses GFLOPs baissent (Cao et al., 2023, Table 3, §5). Le coût de P2 est donc un coût d'activations et d'accès mémoire, que les FLOPs et le nombre de

paramètres ne voient pas *(déduit)*. Sur un FPGA, où les activations d'une carte 160×160 doivent tenir en mémoire on-chip, c'est précisément ce coût qui domine *(déduit)*.

Paramètres et FLOPs ne prédisent pas la latence. Le constat revient dans cinq articles. SF-YOLOv5 retire 68 % des paramètres pour 7 % de latence en moins (Liu et al., 2022, Table 3). SlimYOLOv3 (Zhang et al., 2019a)[PP] (version ICCVW 2019 probable) retire 90,8 % des FLOPs de YOLOv3-SPP3 par élagage de canaux pour 49,5 % de temps en moins sur GTX 1080 Ti [§5], et reste plus lent que YOLOv3-tiny à FLOPs comparables. F-YOLOv7 divise les FLOPs par 2,8 sans gain de débit sur RTX 4090 (Du et al., 2025, Table 2). DroneScan-YOLO reconnaît que son pruning non structuré ne retire aucun paramètre et n'accélère rien sur matériel embarqué (Bellec, 2026, §5). YOLO-GCOF, annoncé pour Raspberry Pi 4B, ne donne que des GFLOPs (Yu and Mo, 2025, §IV-D8). Tous ces résultats sont sur GPU de bureau : sur FPGA, NPU ou MCU, l'effet peut s'inverser (GhostConv et depthwise sont souvent mal servis par un DPU) *(déduit)*.

4.2 Calculer seulement où sont les objets

Une deuxième famille garde un détecteur à résolution modeste et concentre le calcul sur les régions utiles.

- **Tuilage** : SAHI (Akyon et al., 2022)[PP] (publié à ICIP 2022 d'après son DOI) découpe l'image en tuiles 640×640. Avec fine-tuning sur tuiles, TOOD passe de 29,4 à 43,5 d'AP50 sur VisDrone test-dev, et son $AP50_S$ de 18,1 à 31,7 [Table 1]. Le coût, linéaire en nombre de tuiles [§5], n'est pas mesuré.
- **Régions denses** : ClusDet (Yang et al., 2019)[PP] détecte des groupes d'objets puis les traite à part ; il atteint 26,7 d'AP et 17,6 d'AP_S en R-50 [Table 1], mais met 0,273 s par image sur GTX 1080 Ti, cinq fois plus que la baseline sans découpage. UFPMP-Det (Huang et al., 2021)[PP] assemble les régions en une mosaïque unique et atteint 36,6 d'AP en R-50 sur VisDrone val, pour 0,152 s par image [Tables 1, 3].
- **Requêtes éparses** : QueryDet (Yang et al., 2021)[PP] ne calcule la tête haute résolution qu'aux positions désignées par une carte basse résolution. Sur COCO, il garde le gain d'AP_S de P2 (24,33 contre 22,64) à 14,88 FPS, contre 4,85 pour une tête P2 dense [Table 1]. Sur VisDrone, il plafonne à 2,75 FPS [Table 2].
- **Sortie anticipée** : BlankSkip (Marra et al., 2026)[PP] saute le reste du réseau sur les images vides ; il est traité avec les nano-drones (section 6).

Aucune de ces méthodes n'est mesurée sur cible embarquée, sauf BlankSkip. Aucune ne rapporte la latence au pire cas ni la gigue, alors que leur coût dépend du contenu de la scène. Du point de vue matériel, elles ne se valent pas : la mosaïque de taille fixe d'UFPMP-Det ou le tuilage de SAHI gardent un calcul dense et régulier, favorable à un accélérateur à entrée fixe, alors que la convolution éparse de QueryDet repose sur des accès irréguliers *(déduit)*.

4.3 Protocoles et comparabilité

Les chiffres VisDrone du corpus ne se comparent presque jamais entre eux :

- le split varie (validation pour Efficient YOLOv7-Drone, ClusDet, UFPMP-Det, DroneScan-YOLO ; test-dev pour TPH-YOLOv5 et SAHI ; non précisé pour GCL-YOLO et YOLO-Drone) ;
- la métrique varie (mAP50 pour les YOLO, AP COCO pour les autres) ;
- la résolution varie de 640 à 1920 px, et DroneScan-YOLO compare son modèle à 1280 px à des baselines à 640 px (Bellec, 2026, §5) ;
- les baselines sont souvent réentraînées sans pré-entraînement, ou reprises des papiers d'origine.

Surtout, les gains annoncés sont souvent de l'ordre du point, sur un seul entraînement et sans écart-type : +0,9 point pour Jung and Choi (2022), +0,5 pour YOLO-Drone, +1,3 pour SF-YOLOv5. Enfin, l'AP_S n'est rapportée que par trois articles de ce groupe (ClusDet, SAHI, Efficient

YOLOv7-Drone, ce dernier seulement pour ses modèles intermédiaires : 19,4 à 22,0 % (Fu et al., 2023, Tables 9, 12)), alors que tous visent les petits objets.

5 Détection sur FPGA et SoC embarqués

5.1 Le DAC-SDC : cinq ans de co-design sur un petit Zynq

Le tableau 4 reprend les champions FPGA du DAC-SDC compilés par Zhang et al. (2024), dont les auteurs sont les vainqueurs de 2022. Les mesures viennent de l'organisateur, avec une puissance à la carte au wattmètre : c'est la série la plus homogène du corpus pour la gamme FPGA.

TABLE 4 – Champions FPGA du DAC-SDC, 2018–2022 (Zhang et al., 2024, Tables 2–6). IoU mono-objet sans classe. Puissance *board*. PYNQ-Z1 (XC7Z020) en 2018, Ultra96 (ZU3EG) ensuite.

Année	Équipe	Réseau, précision numérique	IoU	FPS	P (W)	Énergie (J)
2018	TGIIF	SSD élagué, W8/A8	0,624	12,0	4,2	18 444
2019	iSmart3	SkyNet, W11/A9	0,716	25,1	7,26	15 216
2020	BJUT Runner	UltraNet, W4/A4	0,656	212,7	6,65	1 641
2021	Skrskr	SkyNet, W5/A8	0,716	299,3	3,77	661
2022	SEUer	UltraNet, W4/A4	0,703	2 020,6	1,41	36,7

L'énergie sur le jeu de test est divisée par 500 en quatre ans. Les auteurs attribuent ce gain à trois choix, devenus la recette gagnante : une architecture streaming (apparue en 2020), tous les poids sur puce, et une quantification W4/A4 avec DSP packing [§3.3–3.5, §4.5]. Trois limites en bornent la portée :

- depuis 2020, tous les podiums utilisent UltraNet ou SkyNet, des réseaux de quelques centaines de milliers de poids ; en 2022, l'IoU ne progresse plus, seule l'efficacité matérielle progresse [§4.2] ;
- le saut de 2021 à 2022 (FPS ×6,8, énergie ÷18) vient en partie du changement de règle qui exclut le chargement des images [§2.3, §4.1] ;
- la tâche (un objet, sans classe) est très loin de la détection multi-classe de petits objets sur VisDrone *(déduit)*.

SkyNet (Zhang et al., 2019b)[PP] (publié à MLSys 2020 d'après le texte) est l'un des rares cas où le même réseau est mesuré sur GPU embarqué et sur FPGA : 0,731 d'IoU à 67,33 FPS et 13,50 W sur TX2, 0,716 à 25,05 FPS et 7,26 W sur Ultra96 [Tables 5–6], puissances de portée non décrite. Sa méthode *bottom-up* choisit des blocs selon leur latence mesurée sur la cible, puis cherche l'architecture sous contrainte matérielle [§4]. Sa solution aux petits objets (bypass et réordonnancement space-to-depth) est légère et portée sur FPGA : c'est un contrepoint à la tête P2 *(déduit)*. Ni ressources ni latence par image ne sont rapportées, et le débit FPGA est obtenu en lot de quatre images [§6.4].

5.2 YOLO sur SoC : DPU Vitis AI et dataflow

Le tableau 5 rassemble les implantations YOLO sur FPGA du corpus.

Le modèle déployé n'est pas le modèle drone. Aucun YOLO du tableau 3 n'est porté sur FPGA dans le corpus. Les implantations restent sur YOLOv3-tiny, YOLOv4, YOLOX et YOLOv5n, et deux d'entre elles simplifient le réseau dans le sens inverse des YOLO drone. Calì et al. (2025) retirent la branche multi-échelle pour tenir dans FINN et en BRAM : il ne reste qu'une tête 13×13, et la mAP50 chute de 41,8 à 17,7 %, sans ablation qui sépare l'effet de l'architecture de celui du W4/A4 [§3.1, Table 5]. Les auteurs citent explicitement la limite de FINN sur les topologies

TABLE 5 – YOLO sur FPGA dans le corpus. Précisions non comparables entre lignes (jeux, seuils et classes différents). Débit de l'accélérateur sauf mention.

Travail	Carte, flot	Modèle, précision	FPS	Puissance (portée)
Calì et al. (2025)	Z-turn XC7Z020, FINN	YOLOv3-tiny réduit à une tête, W4/A4 ; 17,68 mAP50 VisDrone *car* seule [Table 5]	164,8 (b. 1) / 208,7 (b. 100) [Table 9]	2,55 W (board)
Nguyen et al. (2024)	ZCU104, DPU ×2	YOLOv4-tiny 3L INT8 ; 72,24 mAP@0.25, jeu propre [Table 11]	52,1 / 125,0 [Table 13]	19,4 / 26,4 W (board, prise)
Nguyen et al. (2024)	ZCU104, DPU ×2	YOLOv4 INT8 ; 83,70 mAP@0.25	9,2 / 17,9	23,1 / 30,1 W (board)
Elhence et al. (2025)	KV260, DPU ×1 / ×2	LCAM-YOLOX élagué INT8 ; 78,11 % mAP, feux de forêt [§V-A2]^{m}	195 / 387 [§V-D]^{m}	9,72 / 10,45 W (board)
Montgomerie-Corcoran et al. (2023)	ZCU104, SATAY	YOLOv5n 640, W8/A16 ; 26,7 mAP50 COCO [Table IV]^{m}	21,41 ms	14,5 W (non décrite)
Karki et al. (2026)[PP]	ZCU104, DPU B4096	YOLOv26n INT8, attention approximée ; 0,29 mAP COCO [Table II]	34,05 (bout en bout)^{m}	8,76 W (Vivado, estimée)
Blott et al. (2018)	Ultra96, FINN-R (MO)	Tincy YOLO W1/A3 ; 50,1 mAP VOC [§5.1]	`n/r` (288 GOp/s)	9,7 W (board)

branchées [§3.1]. Karki et al. (2026)[PP] contournent le DPU, qui ne supporte ni SiLU ni softmax ni matmul, en remplaçant l'attention de YOLOv11 et YOLOv26 par un produit terme à terme et une hard-sigmoid [§III-B] : ce n'est plus une attention au sens matriciel *(déduit)*, et la modification coûte environ 3 points de mAP avant quantification [Table I]. SATAY, le seul toolflow streaming du corpus pour YOLOv3 à v8, garde tous les poids sur puce (jusqu'à 26 MB) et ne vise de SoC embarqué qu'avec YOLOv5n sur ZCU104 (Montgomerie-Corcoran et al., 2023, §IV-C, Table IV).

La quantification coûte cher, et jamais par taille d'objet. Sur DPU, le passage à l'INT8 coûte 6 à 7 points de mAP pour les YOLOv4 de Nguyen et al. (2024, Tables 10–11), la conversion Darknet → TensorFlow ne coûtant rien. Il coûte jusqu'à 30 points pour YOLOv8n sur KITTI (0,64 → 0,34) chez Karki et al. (2026, Table II)[PP]. Même hors FPGA, la PTQ INT8 de TensorRT fait perdre 12,3 points de mAP50-95 à YOLOv8n sur Jetson Orin (Rey et al., 2025, Table 4). Aucun de ces articles ne rapporte l'AP_S : la perte sur les petits objets, qui sont pourtant la raison d'être de ces détecteurs, n'est pas connue.

Le goulot est souvent sur le processeur. Quatre articles montrent que l'accélérateur n'est pas ce qui limite le système. Chez Calì et al. (2025, Table 10), le prétraitement (32,2 ms) et le post-traitement (25,8 ms, dont NMS 9,2 ms) en Python sur le Cortex-A9 pèsent environ cinq fois l'inférence ; le système réel tombe à 30 FPS en streaming caméra [§4.4], loin des 208 FPS de l'accélérateur. Chez Elhence et al. (2025, §V-F), le pré- et post-traitement sur le PS ne profite pas des cœurs DPU supplémentaires. Chez Karki et al. (2026, §IV-C)[PP], agrandir le DPU ne change pas le débit de bout en bout. Le survey de Sali et al. (2025, §VI-C)[PP] cite un YOLOv8n à 195 FPS dont le débit tombe à 24 FPS quand le post-traitement tourne en Python sur le PS. Nuance : chez Nguyen et al. (2024, Table 12), le NMS en C++ sur les A53 ne prend que 3,9 ms.

Des puissances de carte de développement. Les puissances du tableau 5 sont élevées pour un drone. Le ZCU104 de Nguyen et al. consomme 16,1 W au repos, mesurés à la prise [§5.3]. La KV260 d'Elhence et al. consomme environ 10 W, soit la gamme Jetson *(déduit)*. Seul le Zynq-7020 de Calì et al. reste sous 3 W, avec 1,9 W au repos [§4.3]. Aucune de ces implantations n'a volé :

Elhence et al. décrivent une intégration KV260 + Pixhawk mais évaluent sur images [§IV-C].

Comparaisons biaisées. Les baselines des articles FPGA sont souvent choisies à leur avantage. Nguyen et al. comparent leur FPS/W à une RTX 2080 Ti et à une GTX 1650 en FP32 sous Darknet, sans Jetson ni TensorRT [§5.3]. Calì et al. prennent la puissance du Coral Edge TPU dans sa datasheet, contre une mesure à la carte côté FPGA [Table 15]. Elhence et al. donnent pour un STM32H7A3 15 FPS avec un modèle de 6,7 M de paramètres, chiffre invraisemblable pour un Cortex-M7 *(déduit)* [§V-D]. SATAY compare en GOP/s par DSP, ce qui efface les écarts de précision numérique et de carte.

5.3 Surveys FPGA

Hozhabr and Giorgi (2025) est la revue la plus proche du sujet. Elle distingue temps réel dur et mou, conteste le critère des 30 FPS et propose de normaliser le débit par le nombre de pixels (*pixel throughput*) [§II-C2]. Elle pointe deux travaux absents de la base qui traitent le post-traitement en matériel : un NMS pipeliné à 2,13 ms de bout en bout, et un YOLOv3-tiny entièrement sur FPGA, NMS compris [§V-A]. Le survey de Sali et al. (2025)[PP] sert d'index de références 2025 (YOLOv8n FINN + SORT, SiamRPN++ sur KV260 à 1,11 W), avec de nombreuses incohérences internes : ses chiffres doivent toujours être vérifiés à la source. Wan et al. (2022)[PP] plaident pour le FPGA comme substrat du calcul robotique (localisation, planification), sans comparaison chiffrée et sans accélérateur de détection recensé.

6 Gamme nano : MCU, ASIC et neuromorphique

6.1 Le GAP8 et la lignée PULP

Le GAP8 (Flamand et al., 2018) est la puce de l'AI-deck du Crazyflie, utilisée par la plupart des travaux nano du corpus. C'est un SoC RISC-V de 55 nm : un contrôleur et un cluster de 8 cœurs, 512 kB de L2, 64 kB de L1, un accélérateur de convolution, environ 10 GMAC/s en crête et au plus 75 mW au pire cas [§II, Table II]. Le papier, court et écrit par le concepteur, ne rapporte aucune détection : seulement CIFAR-10 en 650 µs pour 15 mW, méthode de mesure non décrite [§IV]. Son enseignement durable est que la gestion explicite de la mémoire (tuilage L3/L2/L1 par DMA) est le cœur de l'effort de portage *(déduit)*, comme sur un accélérateur FPGA dataflow.

Le tableau 6 rassemble les réseaux déployés sur GAP8, sur son successeur GAP9 (section 6.2) et sur MCU.

Navigation. PULP-Dronet (Palossi et al., 2018)[PP] (publié dans IEEE IoT Journal d'après le DOI) est le premier CNN de navigation en boucle fermée entièrement à bord d'un nano-drone de 27 g. À 64 mW, le calcul représente 0,8 % de la puissance du drone, estimée à 7,6 W [Fig. 12]. Son apport le plus utile ici est système : l'autonomie en vol stationnaire passe de 440 s pour le Crazyflie seul à 340 s avec le shield qui calcule, et la masse du module en coûte l'essentiel (90 s contre 10 s pour le calcul) [Table IV]. Tiny-PULP-Dronet (Lamberti et al., 2024)[PP] réduit le réseau d'un facteur 50 en taille et 27 en MAC, pour un gain de latence de 8,5 seulement : la première couche et le format mémoire deviennent le goulot [§III-B]. Aucun vol n'est rapporté, et le multitâche qui motive le travail n'est pas démontré.

Pose et flot optique. PULP-Frontnet (Palossi et al., 2021)[PP] ferme la boucle de contrôle sur une estimation de pose humaine. Son résultat le plus instructif : le réseau le plus rapide (135 Hz) suit moins bien la personne que le plus lent (48 Hz), avec une erreur de position médiane de 0,63 contre 0,41 m [Table IV]. Le débit maximal n'est pas la bonne cible *(déduit)*. NanoFlowNet (Bouwmeester

TABLE 6 – Réseaux déployés en gamme nano. Tâches très différentes : les chiffres donnent des ordres de grandeur. Les deux lignes GAP9 n'ont aucune puissance mesurée, et la latence de Tiny-DroNeRF est simulée.

Travail	Tâche, réseau	Puce	Débit	Puissance (portée), source
PULP-Dronet (Palossi et al., 2018)[PP]	navigation, DroNet Fixed16, 41 MMAC	GAP8	6 / 18 FPS	64 / 284 mW (shield), §VI[m]
Tiny-PULP-Dronet (Lamberti et al., 2024)[PP]	navigation, 1,5 MMAC, 6,4 kB	GAP8	89 / 160 FPS	34 mW (chip), 0,38 mJ/image, §III-B[m]
PULP-Frontnet (Palossi et al., 2021)[PP]	pose humaine, INT8, 4 MMAC	GAP8	134,7 FPS	86,6 mW (chip), §V-B[m]
NanoFlowNet (Bouwmeester et al., 2022)[PP]	flot optique dense, INT8	GAP8	5,57 FPS	n/r, Table IV[m]
Lamberti et al. (2023)[PP]	détection SSD-MbV2 1,0×, 2 classes, 534 MMAC ; 50 % mAP	GAP8	1,6 FPS	134,5 mW (AI-deck), Table II
BlankSkip (Marra et al., 2026)[PP]	même détecteur + sortie anticipée ; 0,540 mAP	GAP8	1,86 FPS moyen	n/r, Table 2
Carlotti et al. (2026)[PP]	pose 3D d'une porte de course, CNN INT8, 318 MMAC ; MAE ψ 13,1°	GAP9 (NE16)	32,8 FPS	n/r, §V, Table I[m]
Tiny-DroNeRF (Carboni et al., 2026)[PP]	*entraînement* NeRF, FP16, 160×160 ; PSNR 26,94 dB	GAP9 (cluster)	73 ms/pas, simulé	60 mW (non décrite), §III-B, §V-C[m]
TinyissimoYOLO (Moosmann et al., 2023)	détection 88×88, 3 classes VOC ; 58,5 % mAP	MAX78000	5,5 ms	196 µJ/inférence (MCU), §III[m]
TinyissimoYOLO	idem	STM32H7A3	359 ms	n/r, §III[m]

et al., 2022)[PP] calcule un flot optique dense à 5,57 FPS sur GAP8 et sert l'évitement d'obstacles, sans mesure de puissance ni précision après quantification [Table IV].

Détection. Deux articles seulement font de la détection sur GAP8, sur la même tâche jouet : deux classes d'objets posés au sol dans une pièce. Lamberti et al. (2023)[PP] obtiennent 1,6 FPS pour 134,5 mW à l'AI-deck [Table II] et un taux de détection de 90 % en mission à 0,5 m/s, qui tombe à 83 % à 1 m/s [Table III]. Le bilan de puissance du drone entier est un chiffre clé : moteurs 7,32 W (91 %), AI-deck 0,134 W (1,67 %) [Table IV]. BlankSkip (Marra et al., 2026)[PP] ajoute une branche qui détecte les images vides et arrête l'inférence : +24 % de débit moyen pour −0,015 de mAP [Table 2]. Le gain dépend de la proportion d'images vides, fabriquée par les auteurs sur le jeu de test, et la latence au pire cas reste celle du modèle complet *(déduit)*.

MCU à accélérateur. TinyissimoYOLO (Moosmann et al., 2023) montre que l'accélérateur CNN intégré au MCU fait la différence : 5,5 ms sur MAX78000 contre 359 ms sur STM32H7A3, pour le même réseau [§III]. Sa mAP (3 classes, au plus 3 objets par image, entrée 88×88) ne se compare à aucune autre du corpus, et varie de 57 à 59 % selon la section du papier.

6.2 La génération GAP9

Trois preprints récents remplacent l'AI-deck par le GAP9Shield, module enfichable sur le Crazyflie construit autour du GAP9, successeur du GAP8 chez le même fondeur. Le papier de présentation (Müller et al., 2024)[PP] décrit un cluster RISC-V de 9 cœurs avec l'accélérateur NE16 et un calcul flottant FP32/FP16/bfloat16, jusqu'à 370 MHz, 1,6 MB de L2 (contre 512 kB pour le GAP8) et 330 µW/GOP [§2.1]. Ce sont des chiffres constructeur, et ils ne s'accordent pas d'un papier à l'autre : 150 GOPS dans le titre, mais 15,6 GOPS (DSP) et 32,2 GMAC/s (ML) dans le texte [§2.1] ; 150 GOp/s entiers pour le seul NE16 selon Carboni et al. (2026, §III-B)[PP] ; 220 GOp/s combinés pour moins de 100 mW selon Carlotti et al. (2026, §IV-A)[PP]. Le shield ajoute une caméra OV5647 de 5 MP, un module Wi-Fi et cinq capteurs de distance ToF, pour environ 6 g, contre 7 g pour l'AI-deck et le Multi-ranger réunis [§3.1]. Le texte annonce une réduction de masse de 15 % (§3.1) puis de 20 % (Abstract) ; le rapport 6/7 donne 14 % *(déduit)*. Ses seules mesures propres portent sur les périphériques, sans méthode décrite : caméra 80 mW en QVGA à 15 FPS et 120 mW en VGA à 45 FPS, Wi-Fi 250–260 mW, capteurs ToF au plus 150 mW [§3.1]. La promesse « sous 100 mW » ne vaut donc que pour le SoC en calcul, pas pour le module *(déduit)*. Les chiffres de détection qu'il met en avant (YOLO en 17 ms et 1,59 mJ) viennent de travaux cités, sans précision ni résolution, et ne sont pas mesurés dans le papier [§3.2] ; ils n'entrent pas dans le tableau 6. Schémas et PCB sont annoncés, pas publiés à la lecture [Intro].

Inférence sur le NE16. Carlotti et al. (2026)[PP] estiment la pose 3D d'une porte de course (sous-thème vol agile) avec un CNN entraîné en simulation, puis adapté au réel sans étiquette : une perte de cohérence entre les poses prédites et l'odométrie embarquée du drone remplace la capture de mouvement. Quantifié en INT8 et déployé sur le NE16, le réseau de 318 MMAC tourne en 30,4 ms, ou 32,8 FPS [§V], soit environ 10,4 GMAC/s effectifs, contre 0,85 pour le SSD-MobileNetV2 sur GAP8 (534 MMAC à 1,6 FPS) : un ordre de grandeur, entre réseaux et chaînes d'outils différents *(déduit)*. L'erreur sur le jeu réel reste de 26, 28 et 10 cm en position et 13° en lacet [Table I][m], pour une porte de 100×80 cm. Trois limites : la puissance du modèle déployé n'est pas mesurée (`n/r` ; les 100 mW sont ceux du constructeur), la précision après quantification est dite « sans perte » sans être chiffrée, et aucun vol en boucle fermée n'est rapporté [§VI].

Apprentissage à bord. Tiny-DroNeRF (Carboni et al., 2026)[PP] (accepté à ICRA 2026 selon les auteurs) est le seul travail du corpus qui *entraîne* un réseau sur un nano-drone : un NeRF dérivé d'Instant-NGP, réduit à 21,4 MB contre 527 MB, entraîné en FP16 sur le cluster par rétropropagation

[§I, §IV-B]. Le NE16 reste inutilisé, car il ne sait faire que la passe avant en entier [§III-B]. Un pas d'entraînement prend 73 ms, soit 97 min pour une reconstruction, et le rendu d'une image 160×160 environ 4,1 s [§V-C], avec un PSNR de 26,94 dB, 5,7 dB sous Instant-NGP, mais avec des images de 160 contre 800 px de côté [Table I]^{m}. Ces latences sortent du simulateur GVSOC, pas de la puce [§V-C]. La puissance de 60 mW est une « moyenne » à 370 MHz sans méthode décrite [§III-B], et ni l'énergie d'un entraînement de 97 min ni son effet sur une batterie de 350 mAh ne sont chiffrés. En conditions réelles, le PSNR tombe à 21,2 dB, et l'entraînement de cette expérience n'est pas dit fait à bord [§V-D]. L'apprentissage fédéré sur un essaim de quatre drones est simulé, sans canal radio réel [§V-E].

Le GAP9 élargit donc la gamme nano vers le flottant et l'entraînement, et multiplie la mémoire sur puce par trois, sans changer d'ordre de grandeur de puissance d'après le constructeur. Mais aucun des trois papiers ne mesure la puissance d'un réseau sur GAP9, ni à la puce ni à la carte, et aucun ne fait de détection : ce que la génération GAP9 apporte à un détecteur embarqué reste à mesurer *(déduit)*.

6.3 ASIC et neuromorphique

Navion. Suleiman et al. (2019) intègrent une odométrie visuelle-inertielle complète sur un ASIC de 65 nm, sans DRAM externe : 24 mW en configuration maximale et 2 mW à 20 FPS quand les paramètres sont adaptés à chaque séquence (puissance de la puce) [§V-A, §V-D]^{m}. La méthode de co-design est transposable à un détecteur : tout sur puce, tampons d'image compressés, parcimonie exploitée *(déduit)*. Les 2 mW supposent un réglage fait a posteriori, et aucun vol n'est rapporté : les données sont rejouées depuis un ZC706 [§V-B].

Loihi. Deux travaux de contrôle de drone utilisent la puce neuromorphique Loihi d'Intel. Vitale et al. (2021)^{PP} calculent une transformée de Hough sur les événements d'une caméra DVS en 250 µs, soit une estimation à 20 kHz contre 1 kHz sur CPU, sur un banc à un degré de liberté [Fig. 2, §III-A]^{m} ; aucune puissance n'est mesurée. Paredes-Vallés et al. (2023)^{PP} ferment la boucle vision → contrôle sur un quadrirotor de 1 kg, avec un SNN de flot optique à 27 µJ par inférence à 200 Hz [Abstract]. Deux réserves : l'énergie est mesurée sans entrées-sorties, alors que l'USB est le vrai goulot selon les auteurs, et la comparaison à trois ou quatre ordres de grandeur oppose Loihi à une émulation du SNN en PyTorch sur Jetson Nano, ce que les auteurs reconnaissent [Discussion]. Aucun des deux ne fait de détection d'objets.

6.4 Ce que la gamme nano apprend au reste

La gamme nano est la seule du corpus où la part du calcul dans le budget du drone est mesurée : 1,67 % de la puissance pour la vision (Lamberti et al., 2023, Table IV), et un coût en autonomie dominé par la masse (Palossi et al., 2018, Table IV). Elle montre aussi que le débit limite la vitesse de mission (taux de détection qui baisse à 1 m/s) et que la qualité de contrôle ne croît pas avec le débit (PULP-Frontnet). Ces trois constats n'ont pas d'équivalent mesuré pour un FPGA ou une Jetson sur un drone de taille moyenne. Ils reposent tous sur le GAP8 : pour le GAP9, le corpus n'a encore ni puissance mesurée ni bilan à l'échelle du drone (section 6.2).

7 Suivi et navigation embarqués

7.1 Suivi mono-objet sur Jetson

Le groupe Vision4Robotics (Tongji) publie trois trackers siamois à backbone AlexNet, testés à bord d'un drone sur Jetson AGX Xavier, tous sans TensorRT et sans mesure de puissance.

TABLE 7 – Trackers aériens mesurés à bord (gamme Jetson). Aucune puissance ni mode de puissance n'est rapporté.

Tracker	Précision sur benchmark (bureau)	FPS à bord	FPS bureau
SiamAPN++ (Cao et al., 2021a)[PP]	UAV20L : précision 0,736, AUC 0,560 [Fig. 4a][m]	34,9 [§V][m]	`n/r`
HiFT (Cao et al., 2021b)[PP]	UAV20L : précision 0,763 [Table 2]	31,2 [§5][m]	127 (GPU non précisé)
TCTrack (Cao et al., 2022)[PP]	UAVTrack112_L : succès 0,582 [§4.2][m]	> 27 [§5][m]	125,6 (« PC »)

Le passage du bureau à la Xavier divise le débit par quatre environ, sans analyse du goulot *(déduit)*. TCTrack apporte une observation utile au choix d'un backbone : sur Xavier, AlexNet prend 3,4 ms contre 13,7 ms pour MobileNetV2, attribués au coût d'accès mémoire des réseaux « mobiles » (Cao et al., 2022, Table 1). Aucun tracker siamois ou à Transformer n'est porté sur FPGA ou MCU dans le corpus, et aucun n'étudie la quantification. Du côté multi-objets, les trackers par association de positions sont quasi gratuits : SORT tourne à 245 FPS sur CPU dans UAVDT (Du et al., 2018, Table 3)[m]. Le coût embarqué du suivi est donc dans le détecteur *(déduit)*.

7.2 Vol agile : la référence Jetson de Zurich

Deux travaux de l'université de Zurich fixent les ordres de grandeur de la gamme Jetson pour un drone agile de moins d'un kilogramme.

— Loquercio et al. (2021) (Science Robotics) apprennent une politique de bout en bout à partir d'images de profondeur. Sur Jetson TX2, la latence est de 41,6 ms, dont 38,9 d'inférence [Table 1]. En forêt, le drone réussit 100 % des vols à 5 m/s et 60 % à 10 m/s [§2-A]. Le papier relie explicitement latence et vitesse sûre maximale [§S5].

— Kaufmann et al. (2023) (Nature) battent des champions humains de course FPV avec des capteurs et un calcul embarqués. Le détecteur de portes (un petit U-Net) prend 40 ms en TensorRT FP16 sur le GPU du TX2, la politique 8 ms sur son CPU (Methods)[m]. La vision est le goulot, et la caméra à 30 Hz est un facteur limitant face aux 120 Hz des pilotes (Discussion).

Aucun des deux ne mesure la puissance du calculateur. Le survey de Hanover et al. (2023) affirme que la famille Jetson est le plus petit matériel suffisant pour des réseaux complexes, ce qui fixe des châssis de 6 pouces [§VII-C] : il ignore les nano-drones et ne discute pas le FPGA. Il cite comme question ouverte la détection d'un adversaire depuis la caméra embarquée (*multiplayer racing*, §VIII-C), c'est-à-dire un cas air → air.

Politiques apprises en simulation. Deux preprints récents poussent la politique pixels → commandes (poussée collective et vitesses angulaires) plus loin, mais sans aucune mesure de calcul à bord. Romero et al. (2025)[PP] entraînent une politique de course par DreamerV3 (apprentissage par renforcement avec modèle du monde) sur des images RGB 64×64 [§IV] ; PPO et SAC n'apprennent aucun vol utile dans les mêmes conditions (Fig. 3, sans valeur numérique). L'entraînement prend environ 240 h sur un GPU de bureau Quadro RTX 8000 [§IV-A], et le vol « réel », jusqu'à 9 m/s (résumé), est un hardware-in-the-loop : images rendues par simulateur, commandes calculées sur un ordinateur déporté [§V-A]. Latence, débit, puissance et taille du réseau embarqué : `n/r`. Sun et al. (2026)[PP] proposent une chaîne complète d'entraînement (simulation différentiable, PPO ou rétropropagation dans le temps), de validation et de déploiement, avec un quadrirotor embarquant un Intel N100 (x86 basse consommation, gamme non mesurée) [§VI-A]. Le seul chiffre de calcul est une latence de communication d'environ 90 ms en commande déportée, ramenée sous 30 ms avec le calcul à bord [§VI-C2]. Les 100 % de réussite en course avec obstacles sont obtenus en simulation [§VII-E] ; le transfert réel n'est montré qu'en figures, sans taux de succès ni baseline publiée. Ces

deux travaux confirment que la politique de contrôle elle-même n'est pas le goulot *(déduit)*, mais ni l'un ni l'autre ne donne la latence d'inférence de sa politique sur le calculateur de bord.

7.3 Suivi de cible et navigation sémantique sur Jetson Orin

Quatre preprints de 2025–2026 font tourner une chaîne complète perception → estimation → contrôle sur un module Jetson Orin, en vol réel (tableau 8). Aucun ne rapporte de puissance ni de mode de puissance : ils se situent dans la gamme Jetson (5 à 30 W selon le module et le mode) sans plus de précision *(déduit)*. Le seul repère de puissance Orin du corpus porte sur une autre charge, YOLOv8n INT8 (10,3 W sur Orin NX, 7,5 W sur Orin Nano, par télémétrie) (Rey et al., 2025, Table 4) : un ordre de grandeur, pas une mesure de ces systèmes.

TABLE 8 – Chaînes de navigation et de suivi mesurées à bord sur Jetson Orin (tous preprints). Puissance `n/r` partout ; résultats de mission sur les essais propres aux auteurs, non comparables entre eux.

Système	Calculateur	Calcul mesuré à bord	Résultat de mission
YOPOv2-Tracker (Lu et al., 2025)[PP]	Orin NX	perception → action 8,2 ms en moyenne [§IV-B-3][m] ; précision numérique `n/r`	suivi d'un humain à 6 m/s en forêt, 5,6 m/s entre bâtiments [§IV-B-3]
NOVA (Saviolo and Loianno, 2025)[PP]	Orin NX 16 Go	YOLOv11-s FP16 TensorRT : 92 Hz [§IV-B][m] ; complétion de profondeur (DepthAnythingV2 ViT-S) : 31,6 ms [§IV-C][m]	détections 93,1 à 98,6 % selon le scénario, cible à plus de 53 km/h en forêt [§V-E][m]
NGPS (Sharma, 2026)[PP]	Orin NX	appariement satellite 2,6 Hz sur GPU, 0,5 Hz sur CPU [§IV-D][m]	RMSE de position 2,94 m contre 10,37 m en VIO seul [§IV-B, §IV-E4][m]
SINGER (Adang et al., 2025)[PP]	Orin Nano 8 Go	CLIPSeg (ViT-B/16, 86 M param.) 12 Hz en ONNX Runtime, 3 Hz sans optimisation [§V][m]	76,67 % des essais à moins de 1 m du but (30 essais), contre 53,33 % pour la baseline [§VI-D][m]

Suivi agile de bout en bout. Lu et al. (2025)[PP] remplacent la chaîne détection → carte → planification par un seul réseau convolutionnel (ResNet-18, entrée RGB-D 160×96) qui prédit directement des primitives de trajectoire, à la manière des boîtes d'ancrage d'un détecteur [§III-C]. Sur un quadrotor de 850 g, la latence perception → action est de 8,2 ms sur Orin NX [§IV-B-3], soit près de cinq fois moins que l'inférence de Loquercio et al. (2021) sur TX2 *(déduit)* (calculateurs et réseaux différents). Les 3 ms annoncés en simulation sont mesurés sur un GPU de bureau RTX 3060 [§IV-B-1]. Les baselines (Elas. Tracker, Vis. Tracker) sont conçues pour 2 à 2,5 m/s et les taux de succès ne sont donnés qu'en figure, sur 10 essais par vitesse : comparaison favorable à la méthode *(déduit)*.

Suivi à haute vitesse sans GPS. Saviolo and Loianno (2025)[PP] suivent une personne ou un véhicule sans capture de mouvement ni localisation globale, dans le repère de la cible : détecteur YOLOv11-s avec zoom adaptatif, complétion de profondeur, filtre de Kalman *unscented* et commande prédictive non linéaire, le tout sur Orin NX [§III]. Le chiffre utile pour le calcul est l'écart entre modules : la complétion de profondeur (31,6 ms) est environ trois fois plus lente que le détecteur (92 Hz, soit 10,9 ms) *(déduit)*. Sur ce pipeline, le coût n'est donc pas dans le détecteur, contrairement au suivi multi-objets ci-dessus. Le « taux de détection » n'est pas défini contre une vérité terrain : il ne se compare ni à une mAP ni à un IoU. Un seul vol par scénario, aucune baseline, aucune latence de bout en bout.

Navigation guidée par le langage. Adang et al. (2025)[PP] pilotent un drone de 5 pouces vers un objet désigné en langage naturel, avec tout le calcul sur Jetson Orin Nano. La perception est un

modèle de fondation, CLIPSeg (segmentation conditionnée par le texte), dont la carte de chaleur alimente une petite politique visuomotrice à 20 Hz [§V]. CLIPSeg est le goulot : 12 Hz au mieux après conversion ONNX, sous la fréquence de la commande [§V, §VI-C]. Sur 30 essais en environnement et requêtes inconnus, 76,67 % atteignent le but à moins de 1 m (66,67 % sans cap de référence externe) [§VI-D]^{m} ; la baseline est une implantation minimale écrite par les auteurs. Pas d'évitement d'obstacles, ni de puissance, ni de latence mesurée. C'est le seul modèle de type vision–langage exécuté à bord dans cette section.

Ce que ces quatre travaux changent. Ils déplacent la référence de la gamme Jetson du TX2 vers l'Orin, et montrent qu'en suivi et en navigation sémantique le goulot est un réseau de perception dense (profondeur, segmentation, appariement), pas le détecteur ni la politique *(déduit)*. Ils reproduisent aussi les manques de la littérature Zurich : aucune puissance, aucune autonomie, aucun lien chiffré entre cadence de perception et vitesse sûre, aucune quantification au-delà du FP16, aucun portage FPGA ou MCU.

7.4 Localisation et plateformes hétérogènes

Guo et al. (2021) proposent de réunir contrôle de vol (PID) et prétraitement sur un Zynq-7020, avec une Jetson AGX Xavier pour l'inférence. C'est une proposition sans aucune mesure de latence, de masse ou de puissance, à citer avec prudence [§III–IV]. Pourjabar et al. (2023)[PP] localisent un essaim de nano-drones par UWB, sans vision ; le module radio seul consomme environ 350 mW par drone [§V-C], un ordre de grandeur à garder face au budget de calcul d'un nano-drone.

La localisation visuelle absolue sans GNSS n'a qu'un représentant. Sharma (2026)[PP] (auteur unique ; accepté à IROS 2026 selon le PDF, non vérifié) apparient l'image d'une caméra orientée vers le bas avec une image satellite (SuperPoint + LightGlue) et fusionnent le résultat avec un VIO et l'IMU, à 60–150 m d'altitude [§III]. Sur Orin NX, l'appariement tourne à 2,6 Hz sur GPU et 0,5 Hz sur CPU, LightGlue prenant 82 % du temps GPU [§IV-D]^{m}. L'erreur de position fusionnée est de 2,94 m contre 10,37 m pour le VIO seul [§IV-B, §IV-E4]^{m}, sur cinq vols à 2–4 m/s ; l'ATE atteint 6,04 m au pire à 150 m d'altitude [§IV-E2]. La comparaison à un autre VIO vient d'un autre article et d'autres données (non appariée), et puissance, mémoire et latence de bout en bout sont `n/r`. L'appariement par attention de LightGlue, goulot mesuré, n'a aucun équivalent FPGA ou NPU dans le corpus.

8 Contre-drone : détecter des drones

Sur les 19 articles de contre-drone du corpus, 12 relèvent du sol → air ou ne déclarent pas le capteur. Les deux surveys du domaine (Dong et al., 2025; Ding et al., 2025)[PP] ne font pas la distinction : ils mêlent Det-Fly et ARD-MAV, pris depuis un drone, aux jeux pris du sol, et ne discutent aucune plateforme embarquée chiffrée. Cette section suit donc le critère du profil de la base : seul l'air → air relève de l'IA embarquée.

8.1 Sol → air : des références de contraste

Les détecteurs sol → air du corpus sont tous mesurés sur GPU de bureau ou sur ordinateur portable :

- YOLOv4 élagué (Liu et al., 2021) : 90,5 mAP50 et 69 FPS sur Tesla P100, sur un jeu propre de deux drones DJI [Table 4] ; l'élagage fait chuter le rappel sur les petits drones à 30,7 %, qu'une augmentation ciblée remonte à 72,6 % [§4.3] ;
- F-YOLOv7 (Du et al., 2025) : 98,8 d'AP50 de validation sur DUT Anti-UAV avec soustraction de fond, sur RTX 4090 [Table 2] ;

— DotD-YOLOv9-C (Gao et al., 2024) : 92,6 de mAP@0.5 sur Anti2, sur RTX 4060 portable, sans aucun temps d'inférence [Table 5] ;
— YOLO-GCOF (Yu and Mo, 2025) : 91,5 de mAP@50 sur DUT Anti-UAV^{m}, annoncé pour Raspberry Pi 4B sans aucun chiffre sur la carte ;
— soustraction de fond + MobileNetV2 (Seidaliyeva et al., 2020) : F1 0,742 sur Drone-vs-Bird, 9 FPS en 1080p sur un matériel non nommé [Table 1, §3.4] ;
— réseau de caméras stéréo panoramiques (Zheng et al., 2023) : 9 FPS avec une RTX 3070 par groupe de 8 objectifs [§VII-B.3]^{m} ;
— fusion IR + visible + audio (Svanstrom et al., 2020) sur portable : la fusion à deux capteurs supprime les fausses alarmes relevées en 10 minutes sans drone [§V-D].

Le seul portage FPGA est celui de Nguyen et al. (2024) sur ZCU104 (section 5), sur un jeu d'images d'Internet et de caméras au sol. Trois idées de ces travaux restent utiles pour l'embarqué : l'augmentation « petits objets » après élagage, l'appariement DotD sans coût d'inférence, et les jeux multi-classes (drone, oiseau, avion) pour mesurer les fausses alarmes. En revanche, la soustraction de fond, centrale dans trois d'entre eux, suppose une caméra fixe : elle ne fonctionne pas depuis un drone en mouvement, ce que reconnaissent Seidaliyeva et al. (2020, §2.1).

Caméras événementielles. Le survey de Magrini et al. (2025)[PP] recense la détection de drones par caméra événementielle (DVS) : représentations des événements, détecteurs (nuages de points, DETR multimodal, SNN), suivi, signature des hélices, et une douzaine de jeux (FRED, NeRDD, Ev-UAV, SFERA…) [§4–§6, Table 1]. Les systèmes décrits sont presque tous à capteur fixe ; la distinction sol → air / air → air n'est pas faite par les auteurs *(déduit)*. Le survey ne donne aucun chiffre propre : les avantages annoncés (latence de l'ordre de la microseconde, plage dynamique > 120 dB, faible consommation) sont affirmés [§1] sans mesure ni comparaison à un GPU embarqué, et les puces neuromorphiques citées (Loihi, Speck) n'ont aucune puissance rapportée. Il sert de carte des jeux événementiels, pas de résultat embarqué ; comme la soustraction de fond, l'intérêt du capteur (fond statique supprimé) se réduit quand la caméra bouge avec le drone *(déduit)*.

8.2 Air → air : le cas embarqué

Évaluer les détecteurs. Zheng et al. (2021) posent explicitement la distinction : en air → air, le fond peut être urbain ou naturel et la cible faire moins de 10×10 pixels [§I]. Sur Det-Fly, les huit détecteurs évalués vont de 69,5 (RefineDet) à 82,4 d'AP (Grid R-CNN), YOLOv3 étant à 72,3 d'AP pour 32 ms sur RTX 2080Ti [§V-A, §V-B]^{m}. L'AP moyenne des huit passe de 88,3 % sur fond de ciel à 62,0 % sur fond urbain [Table III]. Aucun détecteur n'est porté à bord, alors que le choix de ResNet-50 est motivé par l'embarqué [§IV].

Exploiter le mouvement. En air → air, les méthodes les plus précises combinent apparence et mouvement :
— Dogfight (Ashraf et al., 2021)[PP] (CVPR 2021 probable) segmente les drones image par image, puis retrouve des candidats par frontières de mouvement et les valide par un I3D sur des cuboïdes de 8 images. Le F1 passe de 0,90 (apparence) à 0,92 (apparence et mouvement) sur NPS-Drones [Table 3]. Aucun temps de calcul n'est rapporté ; la fenêtre temporelle impose au moins 4 images de latence *(déduit)*.
— GLAD (Guo et al., 2023)[PP] combine un YOLOv5s global, un module de mouvement avec compensation de l'ego-motion par homographie, et un YOLOv5s local sur une région de 300×300 suivie par Kalman. Sur ARD-MAV, il obtient 0,80 d'AP50 contre 0,56 pour YOLOv5s à 640 et 0,73 pour TPH-YOLOv5l à 1536 (12,8 FPS) [Table IV]. Sur Jetson Xavier NX, en TensorRT, il tourne à 23,6 FPS en moyenne, mais à 5,1 FPS quand le module de mouvement global est appelé [Table VIII] ; la précision sur la carte et la puissance ne sont pas mesurées.

— GL-YOMO (Liu et al., 2024)[PP] suit la même logique global/local avec flot optique et Kalman, à 21,6 FPS sur Xavier NX [§IV-E]. Sur Drone-vs-Bird, son AP (0,763) est sous celle de RT-DETR (0,773), à un seuil d'IoU de 0,1 [Table II]. Le point de vue du capteur n'est pas déclaré.

Fermer la boucle à bord. SCOUT (Yousuf et al., 2026)[PP] est le seul intercepteur du corpus dont toute la chaîne tourne à bord, détection, suivi et commande, sur une Jetson Orin NX 16 Go [§IV-A]. Un YOLO26n, pré-entraîné sur quatre jeux dont Det-Fly et DUT Anti-UAV puis affiné sur 3 931 images de la cible (un DJI Neo), passe en TensorRT en FP16 ; ByteTrack, un filtre géométrique de rejet des sauts et une loi PD saturée « gardien de but » ferment la boucle par MAVROS [§III]. Chiffres rapportés :

— mAP@50 de 0,955 (0,824 en mAP@50-95) sur une validation de 437 images de la même cible [Table I] ;
— 48 FPS pour la chaîne de détection en TensorRT contre 22,5 en PyTorch, avec une inférence de 7,9 ms et 20,8 ms pour la chaîne côté détecteur, hors SDK caméra et transport d'image [§III-B.2, Table IV][m] ;
— en vol (104,5 s, en intérieur), 31,82 FPS de publication, un écart maximal de 100,7 ms entre messages et 92,2 % d'images avec détection valide [Table III].

Les deux débits ne mesurent pas la même chose (banc partiel contre publication en vol) et ne se comparent pas. La puissance est `n/r`, ainsi que la charge CPU/GPU ; la gamme est celle des Jetson (autour de 10 à 25 W) *(déduit)*. Les limites sont nettes : un vol en salle (20×40×5 m), une seule cible pilotée à la main, aucun taux d'interception [§IV-D], une validation du même domaine que l'affinage (risque de fuite *(déduit)*), ni AP_S ni précision par distance, ni code publié.

GLAD et SCOUT sont les deux travaux air → air du corpus avec un débit mesuré sur la carte, tous deux sur Jetson et sans puissance ; seul SCOUT est évalué en vol. La décomposition de GLAD montre que la partie non neuronale (homographie, Lucas-Kanade, morphologie) devient le goulot sur Jetson, ce qui plaide pour son accélération matérielle *(déduit)*. L'idée global → local contourne aussi la perte de résolution du sous-échantillonnage à 640 px sans tête P2 : un petit YOLO sur une région de 320×320 est un candidat naturel pour un FPGA *(déduit)*.

8.3 Bilan

Aucun détecteur air → air du corpus n'est mesuré sur SoC FPGA ou MCU, et aucun n'a de puissance mesurée. Un seul, SCOUT, est évalué en boucle fermée sur un intercepteur, en salle, contre une seule cible et sans métrique d'interception (Yousuf et al., 2026, §IV-D)[PP]. La détection événementielle air → air est absente du corpus. Il manque aussi un jeu air → air multi-classes (drones, oiseaux, avions) qui permette de mesurer les fausses alarmes d'un intercepteur ; Anti2 (Gao et al., 2024) a les classes mais mêle les points de vue. C'est le manque le plus net de la base (section 11).

9 Co-design calcul, énergie et vol

9.1 Le calcul agit sur la mission par le temps et la masse

MAVBench. Boroujerdian et al. (2019) (MICRO 2018) évaluent le calcul en boucle fermée : simulateur AirSim et Jetson TX2 réelle en *hardware-in-the-loop*, modèle d'énergie du drone et cinq applications complètes. Leur constat central : sur un drone de 300 à 400 W, le calcul consomme moins de 5 % de la puissance [§I], mais il agit sur l'énergie totale par le temps de mission et la vitesse sûre. Monter la fréquence et le nombre de cœurs du TX2 réduit le temps de mission de 84 % et l'énergie de 82 % en livraison de colis [§V-C]. Tout est en simulation sauf le TX2 ; la masse du calculateur ne varie pas avec sa puissance, et aucune précision de détection n'est rapportée.

Le modèle F-1. Krishnan et al. (2020) puis Krishnan et al. (2022)[PP] formalisent un « roofline pour drone ». La vitesse sûre maximale dépend du débit de décision $f = \min(1/T_{\text{capteur}}, 1/T_{\text{calcul}}, 1/T_{\text{contrôle}})$, de la portée du capteur et de l'accélération maximale, elle-même réduite par la masse du calculateur et de son dissipateur. Un point de genou sépare trois régimes : limité par le capteur, par le calcul ou par la physique. Le modèle est validé en vol sur quatre drones S500, avec une erreur de 5 à 10 % sur la vitesse sûre (Krishnan et al., 2022, Fig. 7b). Ses études de cas donnent des arguments directement utiles :

- une AGX Xavier à 230 FPS donne un plafond plus bas qu'un Intel NCS à 150 FPS sur un DJI Spark, à cause de sa masse et de son dissipateur (280 + 162 g contre 47 g) [§VI-A] ;
- une redondance double (2 × TX2) coûte 33 % de vitesse sûre [§VI-C] ;
- PULP-Dronet, à 6 FPS, est limité par le calcul et devrait gagner un facteur 4,3 [§VII].

Les limites sont connues : pas de traînée, masse réduite au dissipateur estimé par le TDP, consommation électrique du calcul hors modèle, et qualité de détection absente (une détection ratée ne réduit pas la portée du capteur dans le modèle) *(déduit)*. Aucun FPGA n'y figure.

Mesures en vol. Les mesures réelles du lien calcul–vol viennent surtout de la gamme nano (section 6) : coût en autonomie décomposé en masse et calcul, bilan de puissance du drone entier, taux de détection qui baisse avec la vitesse. Dans la gamme Jetson, Loquercio et al. (2021) relient latence et vitesse sûre, et Kaufmann et al. (2023) donnent une latence sensorimotrice de 40 ms. L'intercepteur SCOUT (Yousuf et al., 2026, Table IV)[PP] décompose la latence de sa chaîne de détection par étage sur Orin NX, sans puissance (section 8). Côté neuromorphique, Vitale et al. (2021)[PP] montrent qu'une perception à 20 kHz reste sous-exploitée quand la mécanique a 100 à 150 ms de retard [§III-A].

Le chaînon manquant. Les papiers YOLO/FPGA du corpus donnent des FPS et parfois des watts, jamais l'effet sur l'autonomie ou la vitesse de vol sûre : ni Calì et al. (2025), ni Elhence et al. (2025), ni Nguyen et al. (2024), ni les analyses du DAC-SDC. Le cadre existe (F-1, MAVBench), les données partielles aussi (FPS, puissance à la carte) ; il manque la masse des cartes et l'application du modèle. Le défi « hardware-in-the-loop » de Wan et al. (2022, §IV)[PP] (co-simulation FPGA + AirSim) va dans ce sens, sans réalisation.

9.2 Modèles vision-langage embarqués : où placer le calcul

Trois preprints récents portent à bord d'un drone des modèles vision-langage (VLM) ou vision-langage-action (VLA), tous en gamme Jetson. Leur intérêt pour le co-design est moins la tâche que la répartition du coût entre les étages du modèle et entre le drone et le sol.

Le front-end visuel est le goulot. Dans SINGER (Adang et al., 2025)[PP], une politique de navigation légère tourne à 20 Hz, mais son entrée vient de CLIPSeg (CLIP ViT-B/16, 86 M de paramètres), qui plafonne à 3 Hz sur Jetson Orin Nano 8 Go sans optimisation et atteint 12 Hz une fois exporté en ONNX et exécuté par ONNX Runtime CUDA [§V]^{m} ; la chaîne d'image entière tourne à 12–13 Hz [§VI-C]. La perception est donc plus lente que la commande, découplée de façon asynchrone sans que la latence résultante soit mesurée. Puissance, mémoire et latence sont `n/r`. Les résultats de navigation sont repris à la section 7. LiteVLA-H (williams et al., 2026)[PP] fait le même constat sur un VLA de 256 M de paramètres en FP16 sur Jetson AGX Orin : un jeton d'action sort en 50,65 ms (19,74 Hz), une phrase de description en 149,90 à 164,57 ms [§6.1]^{m}, et le pre-fill multimodal (image et prompt) pèse 47,8 ms, soit 94 % de la latence d'action [§6.2]. Un ordonnanceur à deux cadences intercale une description toutes les trois actions, pour un surcoût de 0,1 Go et de 3,6 W par rapport à l'action seule [§7.2] ; la puissance absolue, sa méthode et sa portée sont `n/r`. La latence ne couvre que l'inférence, sans capteur ni actionneur [§5.1], et aucun vol réel n'est fait [§9.5] ;

les écarts de trajectoire de la Table 6 mêlent simulation et matériel sans protocole décrit et ne sont pas exploitables.

Embarqué, cloud ou partagé. Azimi et al. (2026)[PP] profilent SmolVLM-256M en trois répartitions : tout à bord sur une Jetson dont le modèle n'est pas nommé (ses spécifications sont celles d'une Orin NX 16 Go *(déduit)*), tout dans le cloud sur RTX A6000, ou coupé après la projection visuelle, l'encodeur restant à bord et le décodeur partant au cloud avec des jetons visuels en INT8 [§II, §IV-D, §V-B1]. Hors réseau, une requête prend 2,76 s à bord, 0,72 s au cloud et 2,09 s en mode partagé [§V-A1]^{m}. Le partage réduit l'énergie prélevée sur le drone de 26 à 15 J par requête (−42 %) et le pic de mémoire GPU de 854 à 472 Mo [§V-A2, §V-A3], mais il ne minimise jamais la latence de bout en bout : sur une trace 4G émulée, il prend de 2,17 à 3,59 s, contre 2,73 à 2,77 s à bord et 0,77 à 3,87 s au cloud selon le débit [§V-B2, Table III]. Les énergies viennent de la télémétrie `tegrastats` au niveau du module d'un côté, de RAPL et PyNVML de l'autre : portées différentes, non comparables. L'énergie radio n'est pas mesurée *(déduit)*, la qualité des réponses non plus, et tout est fait au banc.

Bilan. Les trois travaux s'accordent sur un point : à petite taille (86 à 256 M de paramètres), c'est l'encodeur visuel, et non le décodage ou la politique, qui fixe la latence. C'est une cible naturelle pour un accélérateur dédié, FPGA ou NPU, que le corpus n'explore pas *(déduit)*. Les latences vont de 50 ms (un jeton d'action) à près de 3 s (une réponse VLM), sans puissance absolue à la carte, sans quantification des poids déclarée (FP16 pour LiteVLA-H, `n/r` ailleurs), et sans lien entre cadence de perception et vitesse sûre : le modèle F-1 ne leur a pas été appliqué.

9.3 Fiabilité du calcul embarqué

L'axe ne compte que deux articles. Ahmed and Jenihhin (2022) passent en revue les fautes des plateformes de calcul de drone (soft errors, fautes permanentes, vieillissement) et les techniques de tolérance. Ils constatent que les SoC FPGA dominent les études de fautes et que la reconfiguration partielle dynamique est la technique dominante pour les accélérateurs CNN [§5.1]. Le survey ne donne presque aucune donnée quantitative (une couche CNN quantifiée 39 % moins sensible aux radiations, citée d'un tiers, §5), ne décrit pas sa méthode de sélection, et ne recense aucune étude d'injection de fautes sur un détecteur de type YOLO en contexte drone [§5.2, §6]. Son modèle de fiabilité multi-couches reste conceptuel. MAVBench cite les soft errors comme extension non réalisée (Boroujerdian et al., 2019, §VI-C). Le seul chiffre sur le coût de la tolérance aux fautes est modélisé : −33 % de vitesse sûre pour une redondance double (Krishnan et al., 2022, §VI-C). La mémoire de configuration SRAM d'un FPGA est sensible aux SEU, point absent de tous les papiers YOLO/FPGA du corpus *(déduit)*.

10 Comparer les gammes de puissance

10.1 Débit et puissance rapportés

La figure 1 place les 79 lignes de `benchmarks.csv` qui ont à la fois un débit et une puissance, sur 324. Les points pleins ont une puissance mesurée (puce ou carte) ; les points creux, une puissance estimée ou de portée non décrite.

Pour la détection (panneau de gauche), la figure montre trois groupes. Les deux points MCU (SSD-MobileNetV2 sur GAP8) sont vers 0,14 W et 2 FPS. Les GPU embarqués (Jetson) se regroupent entre 7 et 15 W pour quelques dizaines d'images par seconde. Les FPGA s'étalent sur trois ordres de grandeur de débit, de 1,4 à 30 W ; les points au-dessus de 1 000 FPS sont les réseaux minuscules du DAC-SDC, mesurés sans chargement d'images. Ce que la figure ne permet pas : conclure qu'une

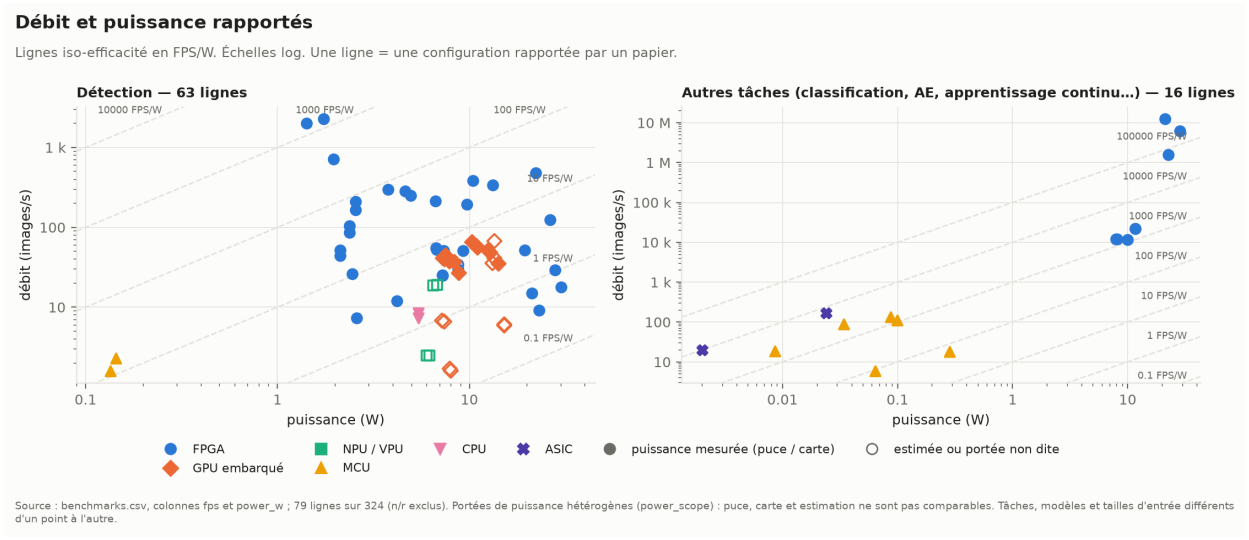


FIGURE 1 – Débit et puissance rapportés, en échelles logarithmiques ; droites pointillées d'iso-efficacité en FPS/W. Figure générée par `bin/pdb plot` à partir de `benchmarks.csv` (28/09/2026).

famille est plus efficace qu'une autre. Aucun couple de points ne partage à la fois le modèle, la résolution, la précision numérique et la méthode de mesure *(déduit)*.

10.2 Les rares comparaisons à modèle égal

TABLE 9 – Comparaisons du corpus où un même réseau est mesuré sur plusieurs familles de plateformes.

Travail	Modèle	Résultat	Réserve
SkyNet (Zhang et al., 2019b)[PP]	SkyNet, DAC-SDC	TX2 : 67,3 FPS, 13,5 W ; Ultra96 : 25,1 FPS, 7,3 W [Tables 5–6]	portée non décrite ; lot de 4 sur FPGA
SATAY (Montgomerie-Corcoran et al., 2023)	YOLOv5n 640	ZCU104 : 317 mJ/image ; TX2 : 277 mJ [Table IV][m]	portée non décrite ; runtime du TX2 `n/r`
Elhence et al. (2025)	LCAM-YOLOX	KV260 : 195 FPS ; Jetson Nano : 65 FPS ; STM32H7A3 : 15 FPS [§V-D][m]	précision et puissance `n/r` hors FPGA ; chiffre MCU invraisemblable
TinyissimoYOLO (Moosmann et al., 2023)	réseau 88×88	MAX78000 : 5,5 ms, 196 µJ ; Apollo4b : 6,1 mJ [§III][m]	MCU seulement
Rey et al. (2025)	YOLOv8n INT8	Orin NX : 65,8 FPS, 10,3 W ; Orin Nano : 44,9 FPS, 7,5 W [Table 4]	Jetson seulement ; télémétrie ; jeu privé facile
Alqahtani et al. (2024)[PP]	YOLOv8n	Orin Nano : 16 ms ; RPi 5 + Hailo-8 : 76 ms ; mAP COCO 31–32 [§IV][m]	précision numérique `n/r` ; pas de FPGA
Feng et al. (2022)	YOLOv3-tiny	Xavier NX : 41,1 FPS ; RPi + NCS2 : 18,8 ; Nano : 6,8 [Table 3]	pas de mAP ; sans TensorRT

Le tableau 9 montre qu'aucun article ne mesure le même détecteur sur les trois gammes (nano, FPGA, Jetson) avec la même portée de puissance. Les comparaisons FPGA–Jetson existantes utilisent des Jetson de 2017 (TX2) ou des modèles minuscules ; la seule qui ajoute un MCU (Elhence et al.) n'est pas crédible sur ce point. Les baselines Jetson récentes (Orin, TensorRT INT8) existent dans le corpus (Rey et al., 2025), mais sans FPGA en face.

10.3 Ordres de grandeur par gamme

Faute de comparaison directe, le corpus donne des ordres de grandeur, à ne lire que comme tels :

- **nano** : de 4 à 41 MMAC par image pour la navigation, 534 MMAC pour le seul détecteur déployé (SSD-MbV2, 1,6 FPS) ; de 34 à 284 mW ; 0,4 mJ par image pour la pose humaine (Palossi et al., 2021, §V-B)[PP] ; sur GAP9, 318 MMAC à 32,8 FPS pour une estimation de pose de porte en INT8 (Carlotti et al., 2026, §V)[PP], sans puissance mesurée (section 6.2) ;
- **FPGA** : de 2,5 W (Zynq-7020, carte) à 10 W (KV260, carte) et 30 W (ZCU104, à la prise), pour des YOLO réduits à quelques centaines de FPS d'accélérateur, et quelques dizaines de bout en bout ;
- **Jetson** : de 7 à 15 W de télémétrie pour YOLOv8n et YOLOv8s en INT8 (45 à 66 FPS), 40 ms pour les réseaux de vol agile sur TX2, de 23 à 35 FPS pour les trackers et GLAD sur Xavier ; sur Orin, 8,2 ms perception → commande pour un suivi de bout en bout (Lu et al., 2025, §IV-B)[PP], 31,82 FPS en vol pour le détecteur air → air de SCOUT (Yousuf et al., 2026, Table III)[PP] et 50,65 ms par action pour un modèle vision-langage-action (williams et al., 2026, §6.1)[PP], tous trois sans puissance.

L'écart entre gammes est de l'ordre de trois ordres de grandeur en puissance, mais la tâche change aussi : navigation en 200×200 en niveaux de gris d'un côté, détection en 640×640 de l'autre *(déduit)*.

10.4 Couverture du corpus

La figure 2 croise la famille de plateforme des mesures et l'axe des articles. Elle confirme les déséquilibres décrits dans ce document : la détection drone est surtout mesurée sur GPU de bureau (17 articles), le contre-drone aussi (9 articles), aucune mesure FPGA ne concerne un nano-drone et aucune mesure du corpus ne porte sur la fiabilité. Un zéro signifie « absent de la base », pas « absent de la littérature ».

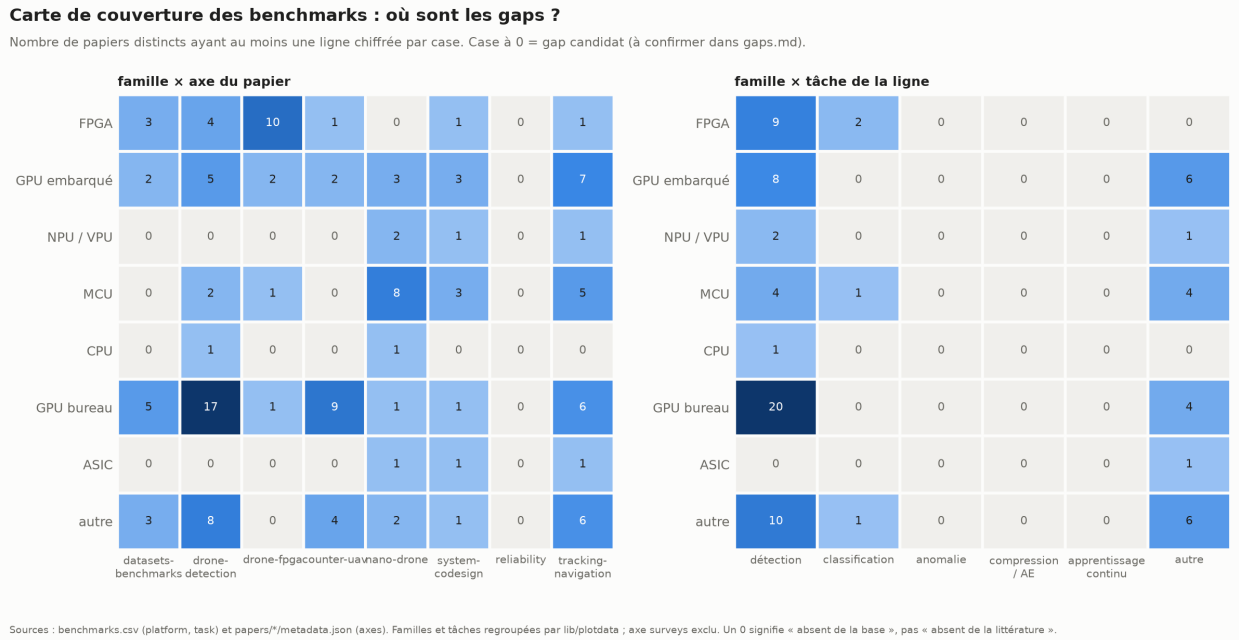


FIGURE 2 – Nombre d'articles ayant au moins une ligne chiffrée, par famille de plateforme et par axe (gauche) ou tâche (droite). Figure générée par `bin/pdb plot` (28/09/2026).

11 Zones non couvertes et pistes de recherche

Les gaps ci-dessous viennent de `gaps.md` (2e passe, 28/09/2026, 73 fiches et 324 lignes), complétés le 1er octobre par les 13 articles ajoutés (86 fiches, 352 lignes) ; les trois dernières lignes du tableau en sont issues. Un gap *étayé* est constaté dans plusieurs fiches (mesure absente, limite reconnue par les auteurs) ; cela ne prouve pas qu'il est absent de la littérature. Un gap à l'état d'*hypothèse* ne repose que sur l'absence de papiers dans la base.

11.1 Trois gaps structurants

Le décalage algorithme / matériel. C'est l'hypothèse de départ de la base, et le corpus l'étaye. Les détecteurs qui font l'état de l'art sur VisDrone ajoutent une tête P2 et de l'attention (section 4). Les implantations FPGA restent sur des YOLO anciens et, pour tenir, retirent la branche multi-échelle (Calì et al., 2025) ou remplacent l'attention (Karki et al., 2026)[PP]. La seule mesure embarquée d'une tête P2 (Jetson TX2) montre un facteur 3 à 4 en latence (Zhang, 2023, Table 6). Deux familles d'alternatives à P2 existent, jamais évaluées sur FPGA : transférer l'information de P2 vers P3 (TPH-YOLOv5++), ou recadrer à pleine résolution autour des régions utiles (SAHI, UFPMP-Det, GLAD).

La précision sur petits objets après quantification. Aucune des 352 lignes ne rapporte d'AP_S. Les pertes de quantification connues sont globales et souvent fortes (6 à 30 points de mAP selon le modèle et le jeu). On ne sait donc pas si la quantification, indispensable sur FPGA et MCU, détruit précisément ce que les YOLO drone cherchent à gagner.

La métrique de mission. Le lien entre latence, masse et vitesse sûre est modélisé (Krishnan et al., 2022)[PP] et mesuré pour des nano-drones, jamais pour un détecteur sur FPGA. Le modèle lui-même ignore la qualité de perception, et la gamme nano montre qu'un réseau plus rapide peut moins bien servir la mission (Palossi et al., 2021, Table IV)[PP].

11.2 Questions de thèse candidates

Les trois questions ci-dessous sont des déductions à partir des gaps, pas des conclusions du corpus.

1. **Détecteur air → air sur SoC embarquable.** Peut-on détecter un drone de quelques pixels à bord d'un intercepteur, sur KV260 ou Zynq UltraScale+, avec une AP, une latence de bout en bout et une puissance à la carte mesurées, et comment se compare-t-on à une Jetson Orin à protocole égal ? SCOUT fournit la baseline Orin NX (YOLO26n, TensorRT FP16, 31,82 FPS en vol (Yousuf et al., 2026, Table III)[PP]), à compléter par la puissance. Données : Det-Fly, ARD-MAV, NPS-Drones. Point de départ : l'architecture globale/locale de GLAD, dont la partie non neuronale est à accélérer.
2. **Petits objets et précision numérique.** Quelle est la perte d'AP_S d'un YOLO drone (avec et sans tête P2) quand on passe de FP32 à INT8 puis INT4, en PTQ et en QAT, mesurée sur la carte ? Quelle alternative à P2 (recadrage, transfert vers P3) tient dans la mémoire on-chip d'une petite FPGA à précision égale ?
3. **Du FPS à la vitesse sûre.** Comment traduire le débit, la puissance et la masse d'un accélérateur de détection en vitesse de vol sûre et en autonomie, en intégrant la qualité de détection au modèle F-1 ? À quelle gamme de puissance (nano, FPGA, Jetson) correspond l'optimum pour un drone donné ?

Laboratoires français à approcher : `labs.md` ne recense encore que le LIRMM (test et fiabilité), sans papier du corpus à l'appui ; la liste reste à construire.

TABLE 10 – Gaps du corpus drone : statut et piste principale.

Gap	Statut	Piste
Décalage algorithme / matériel : YOLO drone (P2, attention) jamais portés sur FPGA	étayé	YOLOv8n-P2 ou Drone-YOLO nano en INT8 sur KV260 (Vitis AI), contre FINN ou hls4ml ; mAP VisDrone avant et après
Quantification et petits objets : 0 ligne avec AP_S sur 352	étayé	balayage PTQ / QAT (FP32, INT8, INT4) d'un YOLO drone sur VisDrone, AP_S mesurée sur la carte
Tête P2 et haute résolution : coût mémoire on-chip non mesuré	étayé (coût) ; hypothèse (absence FPGA)	tailles d'activation par couche de YOLOv8n et YOLOv8n-P2 face au budget BRAM d'un ZU3EG ou d'une KV260
Paramètres et FLOPs ≠ latence sur cible	étayé	trois variantes légères d'un même YOLO profilées sur KV260 et Orin, à précision égale
Post-traitement sur le PS : goulot de bout en bout	étayé	NMS matériel ou tête sans NMS ; latence caméra → sortie instrumentée
Calcul adaptatif ou épars jamais évalué à bord	étayé	SAHI à tuiles fixes contre saut de tuiles vides sur KV260, latence au pire cas
Métriques non comparables ; benchmarks sans métrique d'efficacité	étayé	protocole commun : métrique, résolution, portée de la puissance
Métrique système absente des papiers YOLO/FPGA	étayé	designs FPGA publiés placés sur le modèle F-1 avec masse de carte mesurée
Fiabilité des accélérateurs de détection sur drone	étayé (corpus mince)	injection de fautes sur un détecteur FPGA avec métrique de mission
Pas de comparaison entre gammes de puissance	étayé	même réseau, même entrée, même portée de puissance sur GAP8, FPGA et Jetson
Détection et navigation sur le même budget	étayé	partage d'un SoC par reconfiguration partielle, interférence mesurée
Suivi embarqué sans puissance ni FPGA	étayé	HiFT ou SiamAPN++ sur FPGA, énergie par image
Contre-drone évalué sur GPU de bureau	étayé	YOLOv8n sur Det-Fly, INT8 sur KV260 contre Orin, puissance à la carte
Détecteur air → air embarqué sur intercepteur	étayé ; partiellement comblé sur Jetson (SCOUT)	détecteur sur SoC FPGA avec AP, FPS, W et latence de bout en bout ; SCOUT (Orin NX, sans puissance) comme baseline ; Det-Fly et ARD-MAV
Air → air : coût du mouvement multi-images	étayé (coût) ; hypothèse (FPGA)	profil par étage de GL-YOMO ou GLAD ; tampon on-chip de 8 images
Fusion visible + thermique à bord	hypothèse	recherche ciblée (`/paper-discover`)
Apprentissage continu à bord du drone	hypothèse ; un seul entraînement à bord (NeRF sur GAP9, latences simulées)	base `fpga` ; énergie d'un pas d'apprentissage mesurée sur GAP9
Code et bitstreams rarement publiés	étayé (relevé approximatif)	distinguer code d'entraînement et design matériel
GAP9 : aucune puissance mesurée, aucune détection	étayé (3 papiers)	détecteur INT8 sur NE16, puissance de la puce et du module mesurées, face au GAP8
Navigation sur Orin : perception dense sans puissance	étayé (4 papiers)	profondeur, segmentation ou appariement (LightGlue) profilés en W sur Orin, puis portés sur FPGA ou NPU
Modèles vision-langage embarqués sans bilan énergétique	étayé (3 papiers)	encodeur visuel d'un VLM en INT8 sur FPGA, latence et puissance à la carte

12 Conclusion

La vision embarquée sur drone dispose de jeux de données de référence (VisDrone, UAVDT, DAC-SDC, Det-Fly), d'une littérature abondante de détecteurs pour petits objets et de démonstrations convaincantes dans chaque gamme de puissance : SSD-MobileNetV2 sur GAP8 à 134 mW, YOLOX sur KV260 à 10 W, perception et contrôle de course sur Jetson TX2, suivi agile et détection air → air en vol sur Jetson Orin NX. Le corpus montre pourtant que ces trois littératures se croisent peu :

- les détecteurs les plus précis sur VisDrone sont mesurés sur GPU de bureau, et le seul portage embarqué d'une tête P2 (Drone-YOLO sur TX2) coûte un facteur 3 à 4 en latence ;
- les designs FPGA optimisent le débit sur des réseaux minuscules (DAC-SDC) ou simplifiés, avec des précisions non comparables et sans AP_S ;
- le co-design calcul–vol est modélisé, rarement mesuré, et jamais pour un FPGA ;
- le contre-drone air → air a des jeux publics (Det-Fly, NPS-Drones, ARD-MAV) mais deux chiffres embarqués seulement (GLAD, SCOUT), tous deux sur Jetson et sans puissance ; seul SCOUT ferme la boucle en vol, en salle et sans taux d'interception ;
- la navigation et les modèles vision-langage embarqués sur Orin (profondeur, segmentation, appariement d'images) ont un goulot de perception dense jamais mesuré en puissance ni porté sur FPGA ; le GAP9, nouvelle génération nano, n'a encore ni puissance mesurée ni détecteur dans le corpus.

Ces manques dessinent un sujet de thèse cohérent : porter un détecteur de petits objets récent sur un SoC embarquable, mesurer honnêtement sa précision par taille d'objet et sa puissance à la carte, et traduire le résultat en métrique de mission.

Pistes concrètes.

1. **Papier à lire en priorité** : les deux références de Hozhabr and Giorgi (2025) sur le post-traitement matériel (NMS pipeliné d'Anupreetham et al., système tout-FPGA de D. Zhang et al.), absentes de la base : elles répondent au goulot PS observé dans quatre papiers.
2. **Expérience à reproduire** : YOLOv8n entraîné sur Det-Fly (Zheng et al., 2021), en INT8 sur KV260 (Vitis AI) et sur Jetson Orin, avec AP et AP_S mesurées sur la carte, latence de bout en bout et puissance à la carte des deux côtés.
3. **Gap à creuser** : placer les designs de Calì et al. (2025) et Elhence et al. (2025) sur le modèle F-1 de Krishnan et al. (2022), pour obtenir la première métrique de vitesse sûre d'un détecteur FPGA.

Références

Maximilian Adang, JunEn Low, Ola Shorinwa, and Mac Schwager. SINGER : An Onboard Generalist Vision-Language Navigation Policy for Drones. arXiv preprint, 2025. URL `https://arxiv.org/abs/2509.18610`. arXiv :2509.18610. Preprint non relu par les pairs.

Foisal Ahmed and Maksim Jenihhin. A Survey on UAV Computing Platforms : A Hardware Reliability Perspective. *Sensors 22(16), 6286*, 2022. doi : 10.3390/s22166286. URL `https://doi.org/10.3390/s22166286`.

Fatih Cagatay Akyon, Sinan Onur Altinuc, and Alptekin Temizel. Slicing Aided Hyper Inference and Fine-tuning for Small Object Detection. arXiv preprint, 2022. URL `https://arxiv.org/abs/2202.06934`. arXiv :2202.06934. Preprint non relu par les pairs.

Daghash K Alqahtani, Muhammad Aamir Cheema, Maria A Rodriguez, and Adel N Toosi. A Comprehensive Evaluation of Deep Learning Object Detection Models on Heterogeneous Edge Devices. arXiv preprint, 2024. URL `https://arxiv.org/abs/2409.16808`. arXiv :2409.16808. Preprint non relu par les pairs.

Muhammad Waseem Ashraf, Waqas Sultani, and Mubarak Shah. Dogfight : Detecting Drones from Drones Videos. arXiv preprint, 2021. URL https://arxiv.org/abs/2103.17242. arXiv :2103.17242. Preprint non relu par les pairs.

Zoha Azimi, Reza Farahani, Schahram Dustdar, and Christian Timmerer. Cloud, Edge, or Split ? Profiling Onboard and Split Vision-Language Model Deployment for Drone AI. arXiv preprint, 2026. URL https://arxiv.org/abs/2609.25415. arXiv :2609.25415. Preprint non relu par les pairs.

Yann V Bellec. DroneScan-YOLO : Redundancy-Aware Lightweight Detection for Tiny Objects in UAV Imagery. arXiv preprint, 2026. URL https://arxiv.org/abs/2604.13278. arXiv :2604.13278. Preprint non relu par les pairs.

Michaela Blott, Thomas B. Preußer, Nicholas J. Fraser, Giulio Gambardella, Kenneth O'brien, Yaman Umuroglu, Miriam Leeser, and Kees Vissers. FINN-R : An End-to-End Deep-Learning Framework for Fast Exploration of Quantized Neural Networks. *ACM Transactions on Reconfigurable Technology and Systems 11(3)*, 2018. doi : 10.1145/3242897. URL https://arxiv.org/abs/1809.04570.

Behzad Boroujerdian, Hasan Genc, Srivatsan Krishnan, Wenzhi Cui, Aleksandra Faust, and Vijay Janapa Reddi. MAVBench : Micro Aerial Vehicle Benchmarking. In *2018 51st Annual IEEE/ACM International Symposium on Microarchitecture (MICRO)*, 2019. URL https://arxiv.org/abs/1905.06388.

Rik J Bouwmeester, Federico Paredes-Vallés, and Guido C H E De Croon. NanoFlowNet : Real-time Dense Optical Flow on a Nano Quadcopter. arXiv preprint, 2022. URL https://arxiv.org/abs/2209.06918. arXiv :2209.06918. Preprint non relu par les pairs.

Riccardo Calì, Laura Falaschetti, and Giorgio Biagetti. Optimized Implementation of YOLOv3-Tiny for Real-Time Image and Video Recognition on FPGA. *Electronics 14(20), 3993*, 2025. doi : 10.3390/electronics14203993. URL https://doi.org/10.3390/electronics14203993.

Jinshan Cao, Wenshu Bao, Haixing Shang, Ming Yuan, and Qian Cheng. GCL-YOLO : A GhostConv-Based Lightweight YOLO Network for UAV Small Object Detection. *Remote Sensing 15(20), 4932*, 2023. doi : 10.3390/rs15204932. URL https://doi.org/10.3390/rs15204932.

Ziang Cao, Changhong Fu, Junjie Ye, Bowen Li, and Yiming Li. SiamAPN++ : Siamese Attentional Aggregation Network for Real-Time UAV Tracking. arXiv preprint, 2021a. URL https://arxiv.org/abs/2106.08816. arXiv :2106.08816. Preprint non relu par les pairs.

Ziang Cao, Changhong Fu, Junjie Ye, Bowen Li, and Yiming Li. HiFT : Hierarchical Feature Transformer for Aerial Tracking. arXiv preprint, 2021b. URL https://arxiv.org/abs/2108.00202. arXiv :2108.00202. Preprint non relu par les pairs.

Ziang Cao, Ziyuan Huang, Liang Pan, Shiwei Zhang, Ziwei Liu, and Changhong Fu. TCTrack : Temporal Contexts for Aerial Tracking. arXiv preprint, 2022. URL https://arxiv.org/abs/2203.01885. arXiv :2203.01885. Preprint non relu par les pairs.

Ilenia Carboni, Elia Cereda, Lorenzo Lamberti, Daniele Malpetti, Francesco Conti, and Daniele Palossi. Tiny-DroNeRF : Tiny Neural Radiance Fields aboard Federated Learning-enabled Nanodrones. arXiv preprint, 2026. URL https://arxiv.org/abs/2603.01850. arXiv :2603.01850. Preprint non relu par les pairs.

Nicholas Carlotti, Michele Antonazzi, Elia Cereda, Mirko Nava, Nicola Basilico, Daniele Palossi, and Alessandro Giusti. Self-supervised Domain Adaptation for Visual 3D Pose Estimation of Nano-drone Racing Gates by Enforcing Geometric Consistency. arXiv preprint, 2026. URL https://arxiv.org/abs/2603.02936. arXiv :2603.02936. Preprint non relu par les pairs.

Guanghai Ding, Yihua Ren, Yuting Liu, Qijun Zhao, and Shuiwang Li. Vision-Based Anti Unmanned Aerial Technology : Opportunities and Challenges. arXiv preprint, 2025. URL https://arxiv.org/abs/2507.10006. arXiv :2507.10006. Preprint non relu par les pairs.

Yifei Dong, Fengyi Wu, Sanjian Zhang, Guangyu Chen, Yuzhi Hu, Masumi Yano, Jingdong Sun, Siyu Huang, Feng Liu, Qi Dai, and Zhi-Qi Cheng. Securing the Skies : A Comprehensive Survey on Anti-UAV Methods, Benchmarking, and Future Directions. arXiv preprint, 2025. URL https://arxiv.org/abs/2504.11967. arXiv :2504.11967. Preprint non relu par les pairs.

Dawei Du, Yuankai Qi, Hongyang Yu, Yifan Yang, Kaiwen Duan, Guorong Li, Weigang Zhang, Qingming Huang, and Qi Tian. The Unmanned Aerial Vehicle Benchmark : Object Detection and Tracking. arXiv preprint, 2018. URL https://arxiv.org/abs/1804.00518. arXiv :1804.00518. Preprint non relu par les pairs.

Yan Du, Teng Wu, Zifeng Dai, Hui Xie, Changzhen Hu, and Shengjun Wei. F-yolov7 : fast and robust real-time UAV detection. *Computing 107(1), 50*, 2025. doi : 10.1007/s00607-024-01406-7. URL https://doi.org/10.1007/s00607-024-01406-7.

Anubhav Elhence, Anubhav Panda, Vinay Chamola, and Biplab Sikdar. FPGA-Accelerated YOLOX With Enhanced Attention Mechanisms for Real-Time Wildfire Detection on AAVs. *IEEE Transactions on Instrumentation and Measurement 74, 1-14*, 2025. doi : 10.1109/TIM.2025.3556164. URL https://doi.org/10.1109/TIM.2025.3556164.

Haogang Feng, Gaoze Mu, Shida Zhong, Peichang Zhang, and Tao Yuan. Benchmark Analysis of YOLO Performance on Edge Intelligence Devices. *Cryptography 6(2), 16*, 2022. doi : 10.3390/cryptography6020016. URL https://doi.org/10.3390/cryptography6020016.

Eric Flamand, Davide Rossi, Francesco Conti, Igor Loi, Antonio Pullini, Florent Rotenberg, and Luca Benini. GAP-8 : A RISC-V SoC for AI at the Edge of the IoT. In *2018 IEEE 29th International Conference on Application-specific Systems, Architectures and Processors (ASAP) 1-4*, 2018. doi : 10.1109/ASAP.2018.8445101. URL https://doi.org/10.1109/ASAP.2018.8445101.

Xiaofeng Fu, Guoting Wei, Xia Yuan, Yongshun Liang, and Yuming Bo. Efficient YOLOv7-Drone : An Enhanced Object Detection Approach for Drone Aerial Imagery. *Drones 7(10), 616*, 2023. doi : 10.3390/drones7100616. URL https://doi.org/10.3390/drones7100616.

Depeng Gao, Jianlin Tang, Hongqi Li, Bingshu Wang, Jianlin Qiu, Shuxi Chen, and Xiangxiang Mei. A Novel Dataset and Detection Method for Unmanned Aerial Vehicles Using an Improved YOLOv9 Algorithm. *Sensors 24(23), 7512*, 2024. doi : 10.3390/s24237512. URL https://doi.org/10.3390/s24237512.

Hanqing Guo, Ye Zheng, Yin Zhang, Zhi Gao, and Shiyu Zhao. Global-Local MAV Detection under Challenging Conditions based on Appearance and Motion. arXiv preprint, 2023. URL https://arxiv.org/abs/2312.11008. arXiv :2312.11008. Preprint non relu par les pairs.

Junpeng Guo, Bo Jiang, and Hong Xu. FPGA-based UAV Heterogeneous Computing Platform Architecture. In *2021 6th International Conference on Computational Intelligence and Applications (ICCIA) 252-256*, 2021. doi : 10.1109/ICCIA52886.2021.00056. URL https://doi.org/10.1109/ICCIA52886.2021.00056.

Drew Hanover, Antonio Loquercio, Leonard Bauersfeld, Angel Romero, Robert Penicka, Yunlong Song, Giovanni Cioffi, Elia Kaufmann, and Davide Scaramuzza. Autonomous Drone Racing : A Survey. *IEEE Transactions on Robotics (T-RO), Vol. 40, 2024*, 2023. doi : 10.1109/TRO.2024.3400838. URL https://arxiv.org/abs/2301.01755.

Seyed Hani Hozhabr and Roberto Giorgi. A Survey on Real-Time Object Detection on FPGAs. *IEEE Access 13, 38195-38238*, 2025. doi : 10.1109/ACCESS.2025.3544515. URL https://doi.org/10.1109/ACCESS.2025.3544515.

Bo Huang, Jianan Li, Junjie Chen, Gang Wang, Jian Zhao, and Tingfa Xu. Anti-UAV410 : A Thermal Infrared Benchmark and Customized Scheme for Tracking Drones in the Wild. *IEEE Transactions on Pattern Analysis and Machine Intelligence 46(5), 2852-2865*, 2024. doi : 10.1109/TPAMI.2023.3335338. URL https://doi.org/10.1109/TPAMI.2023.3335338.

Yecheng Huang, Jiaxin Chen, and Di Huang. UFPMP-Det : Toward Accurate and Efficient Object Detection on Drone Imagery. arXiv preprint, 2021. URL https://arxiv.org/abs/2112.10415. arXiv :2112.10415. Preprint non relu par les pairs.

Brian K S Isaac-Medina, Matt Poyser, Daniel Organisciak, Chris G Willcocks, Toby P Breckon, and Hubert P H Shum. Unmanned Aerial Vehicle Visual Detection and Tracking using Deep Neural Networks : A Performance Benchmark. arXiv preprint, 2021. URL https://arxiv.org/abs/2103.13933. arXiv :2103.13933. Preprint non relu par les pairs.

Nan Jiang, Kuiran Wang, Xiaoke Peng, Xuehui Yu, Qiang Wang, Junliang Xing, Guorong Li, Jian Zhao, Guodong Guo, and Zhenjun Han. Anti-UAV : A Large Multi-Modal Benchmark for UAV Tracking. arXiv preprint, 2021. URL https://arxiv.org/abs/2101.08466. arXiv :2101.08466. Preprint non relu par les pairs.

Hyun-Ki Jung. YOLO-Drone : An Efficient Object Detection Approach Using the GhostHead Network for Drone Images. *Journal of Information Systems Engineering and Management, Vol. 10, No. 26s, 2025, pp. 236-247*, 2025. doi : 10.52783/jisem.v10i26s.4216. URL https://arxiv.org/abs/2511.10905.

Hyun-Ki Jung and Gi-Sang Choi. Improved YOLOv5 : Efficient Object Detection Using Drone Images under Various Conditions. *Applied Sciences 12(14), 7255*, 2022. doi : 10.3390/app12147255. URL https://doi.org/10.3390/app12147255.

Suraj Karki, Qazi Arbab Ahmed, and Thorsten Jungeblut. No Attention, No Problem : DPU-Aware Attention Approximation in Modern YOLO on FPGA. arXiv preprint, 2026. URL https://arxiv.org/abs/2607.13106. arXiv :2607.13106. Preprint non relu par les pairs.

Elia Kaufmann, Leonard Bauersfeld, Antonio Loquercio, Matthias Müller, Vladlen Koltun, and Davide Scaramuzza. Champion-level drone racing using deep reinforcement learning. *Nature 620(7976), 982-987*, 2023. doi : 10.1038/s41586-023-06419-4. URL https://doi.org/10.1038/s41586-023-06419-4.

Srivatsan Krishnan, Zishen Wan, Kshitij Bhardwaj, Paul Whatmough, Aleksandra Faust, Gu-Yeon Wei, David Brooks, and Vijay Janapa Reddi. The Sky Is Not the Limit : A Visual Performance Model for Cyber-Physical Co-Design in Autonomous Machines. *IEEE Computer Architecture Letters 19(1), 38-42*, 2020. doi : 10.1109/LCA.2020.2981022. URL https://doi.org/10.1109/LCA.2020.2981022.

Srivatsan Krishnan, Zishen Wan, Kshitij Bhardwaj, Ninad Jadhav, Aleksandra Faust, and Vijay Janapa Reddi. Roofline Model for UAVs : A Bottleneck Analysis Tool for Onboard Compute Characterization of Autonomous Unmanned Aerial Vehicles. arXiv preprint, 2022. URL https://arxiv.org/abs/2204.10898. arXiv :2204.10898. Preprint non relu par les pairs.

Lorenzo Lamberti, Luca Bompani, Victor Javier Kartsch, Manuele Rusci, Daniele Palossi, and Luca Benini. Bio-inspired Autonomous Exploration Policies with CNN-based Object Detection on Nano-drones. arXiv preprint, 2023. URL https://arxiv.org/abs/2301.12175. arXiv :2301.12175. Preprint non relu par les pairs.

Lorenzo Lamberti, Vlad Niculescu, Michał Barcis, Lorenzo Bellone, Enrico Natalizio, Luca Benini, and Daniele Palossi. Tiny-PULP-Dronets : Squeezing Neural Networks for Faster and Lighter Inference on Multi-Tasking Autonomous Nano-Drones. arXiv preprint, 2024. URL https://arxiv.org/abs/2407.02405. arXiv :2407.02405. Preprint non relu par les pairs.

Haiying Liu, Fengqian Sun, Jason Gu, and Lixia Deng. SF-YOLOv5 : A Lightweight Small Object Detection Algorithm Based on Improved Feature Fusion Mode. *Sensors 22(15), 5817*, 2022. doi : 10.3390/s22155817. URL https://doi.org/10.3390/s22155817.

Hansen Liu, Kuangang Fan, Qinghua Ouyang, and Na Li. Real-Time Small Drones Detection Based on Pruned YOLOv4. *Sensors 21(10), 3374*, 2021. doi : 10.3390/s21103374. URL https://doi.org/10.3390/s21103374.

Juanqin Liu, Leonardo Plotegher, Eloy Roura, Cristino De Souza Junior, and Shaoming He. Real-Time Detection for Small UAVs : Combining YOLO and Multi-frame Motion Analysis. arXiv preprint, 2024. URL https://arxiv.org/abs/2411.02582. arXiv :2411.02582. Preprint non relu par les pairs.

Antonio Loquercio, Elia Kaufmann, René Ranftl, Matthias Müller, Vladlen Koltun, and Davide Scaramuzza. Learning High-Speed Flight in the Wild. *Science Robotics 2021 Vol. 6, Issue 59, abg5810*, 2021. doi : 10.1126/scirobotics.abg5810. URL https://arxiv.org/abs/2110.05113.

Junjie Lu, Yulin Hui, Xuewei Zhang, Wencan Feng, Hongming Shen, Zhiyu Li, and Bailing Tian. YOPOv2-Tracker : An End-to-End Agile Tracking and Navigation Framework from Perception to Action. arXiv preprint, 2025. URL https://arxiv.org/abs/2505.06923. arXiv :2505.06923. Preprint non relu par les pairs.

Gabriele Magrini, Lorenzo Berlincioni, Luca Cultrera, Federico Becattini, and Pietro Pala. Drone Detection with Event Cameras. arXiv preprint, 2025. URL https://arxiv.org/abs/2508.04564. arXiv :2508.04564. Preprint non relu par les pairs.

Carlo Marra, Beatrice Alessandra Motetti, Alessio Burrello, Enrico Macii, Massimo Poncino, and Daniele Jahier Pagliari. BlankSkip : Early-exit Object Detection onboard Nano-drones. arXiv preprint, 2026. URL https://arxiv.org/abs/2603.28149. arXiv :2603.28149. Preprint non relu par les pairs.

Alexander Montgomerie-Corcoran, Petros Toupas, Zhewen Yu, and Christos-Savvas Bouganis. SATAY : A Streaming Architecture Toolflow for Accelerating YOLO Models on FPGA Devices. In *2023 International Conference on Field Programmable Technology (ICFPT) 179-187*, 2023. doi : 10.1109/ICFPT59805.2023.00025. URL https://doi.org/10.1109/ICFPT59805.2023.00025.

Julian Moosmann, Marco Giordano, Christian Vogt, and Michele Magno. TinyissimoYOLO : A Quantized, Low-Memory Footprint, TinyML Object Detection Network for Low Power Microcontrollers. In *IEEE AICAS 2023 (d'après le DOI 10.1109/AICAS57966.2023.10168657)*, 2023. doi : 10.1109/AICAS57966.2023.10168657. URL https://arxiv.org/abs/2306.00001.

Hanna Müller, Victor Kartsch, and Luca Benini. GAP9Shield : A 150GOPS AI-capable Ultra-low Power Module for Vision and Ranging Applications on Nano-drones. arXiv preprint, 2024. URL https://arxiv.org/abs/2407.13706. arXiv :2407.13706. Preprint non relu par les pairs.

Aditya Prashant Naidu, Hem Gosalia, Ishaan Gakhar, Shaurya Singh Rathore, Krish Didwania, and Ujjwal Verma. DEAL-YOLO : Drone-based Efficient Animal Localization using YOLO. arXiv preprint, 2025. URL https://arxiv.org/abs/2503.04698. arXiv :2503.04698. Preprint non relu par les pairs.

Dai-Duong Nguyen, Dang-Tuan Nguyen, Minh-Thuy Le, and Quoc-Cuong Nguyen. FPGA-SoC implementation of YOLOv4 for flying-object detection. *Journal of Real-Time Image Processing 21(3), 63*, 2024. doi : 10.1007/s11554-024-01440-w. URL https://doi.org/10.1007/s11554-024-01440-w.

Daniele Palossi, Antonio Loquercio, Francesco Conti, Eric Flamand, Davide Scaramuzza, and Luca Benini. A 64mW DNN-based Visual Navigation Engine for Autonomous Nano-Drones. arXiv preprint, 2018. URL https://arxiv.org/abs/1805.01831. arXiv :1805.01831. Preprint non relu par les pairs.

Daniele Palossi, Nicky Zimmerman, Alessio Burrello, Francesco Conti, Hanna Müller, Luca Maria Gambardella, Luca Benini, Alessandro Giusti, and Jérôme Guzzi. Fully Onboard AI-powered Human-Drone Pose Estimation on Ultra-low Power Autonomous Flying Nano-UAVs. arXiv preprint, 2021. URL https://arxiv.org/abs/2103.10873. arXiv :2103.10873. Preprint non relu par les pairs.

Federico Paredes-Vallés, Jesse Hagenaars, Julien Dupeyroux, Stein Stroobants, Yingfu Xu, and Guido de Croon. Fully neuromorphic vision and control for autonomous drone flight. arXiv preprint, 2023. URL https://arxiv.org/abs/2303.08778. arXiv :2303.08778. Preprint non relu par les pairs.

Mahyar Pourjabar, Ahmed Alkatheeri, Manuele Rusci, Agata Barcis, Vlad Niculescu, Eliseo Ferrante, Daniele Palossi, and Luca Benini. Land & Localize : An Infrastructure-free and Scalable Nano-Drones Swarm with UWB-based Localization. arXiv preprint, 2023. URL https://arxiv.org/abs/2307.10255. arXiv :2307.10255. Preprint non relu par les pairs.

Lucas Rey, Ana M Bernardos, Andrzej D Dobrzycki, David Carramiñana, Luca Bergesio, Juan A Besada, and José Ramón Casar. A Performance Analysis of You Only Look Once Models for Deployment on Constrained Computational Edge Devices in Drone Applications. *Electronics 2025, 14(3), 638*, 2025. doi : 10.3390/electronics14030638. URL https://arxiv.org/abs/2502.15737.

Angel Romero, Ashwin Shenai, Ismail Geles, Elie Aljalbout, and Davide Scaramuzza. Dream to Fly : Model-Based Reinforcement Learning for Vision-Based Drone Flight. arXiv preprint, 2025. URL https://arxiv.org/abs/2501.14377. arXiv :2501.14377. Preprint non relu par les pairs.

Safa Mohammed Sali, Mahmoud Meribout, and Ashiyana Abdul Majeed. Real Time FPGA Based CNNs for Detection, Classification, and Tracking in Autonomous Systems : State of the Art Designs and Optimizations. arXiv preprint, 2025. URL https://arxiv.org/abs/2509.04153. arXiv :2509.04153. Preprint non relu par les pairs.

Alessandro Saviolo and Giuseppe Loianno. NOVA : Navigation via Object-Centric Visual Autonomy for High-Speed Target Tracking in Unstructured GPS-Denied Environments. arXiv preprint, 2025. URL https://arxiv.org/abs/2506.18689. arXiv :2506.18689. Preprint non relu par les pairs.

Ulzhalgas Seidaliyeva, Daryn Akhmetov, Lyazzat Ilipbayeva, and Eric T. Matson. Real-Time and Accurate Drone Detection in a Video with a Static Background. *Sensors 20(14), 3856*, 2020. doi : 10.3390/s20143856. URL https://doi.org/10.3390/s20143856.

Sanket Sharma. NGPS : GPS-Denied Aerial Geo-Localization and 2.5D Reconstruction via Deep Satellite Image Matching and Multi-Rate Sensor Fusion. arXiv preprint, 2026. URL https://arxiv.org/abs/2607.18936. arXiv :2607.18936. Preprint non relu par les pairs.

Amr Suleiman, Zhengdong Zhang, Luca Carlone, Sertac Karaman, and Vivienne Sze. Navion : A 2-mW Fully Integrated Real-Time Visual-Inertial Odometry Accelerator for Autonomous Navigation of Nano Drones. *IEEE Journal of Solid-State Circuits 54(4), 1106-1119*, 2019. doi : 10.1109/JSSC.2018.2886342. URL https://doi.org/10.1109/JSSC.2018.2886342.

Fangyu Sun, Fanxing Li, Linzuo Zhang, Yu Hu, Renbiao Jin, Shuyu Wu, Wenxian Yu, and Danping Zou. E2E-Fly : An Integrated Training-to-Deployment System for End-to-End Quadrotor Autonomy. arXiv preprint, 2026. URL https://arxiv.org/abs/2604.12916. arXiv :2604.12916. Preprint non relu par les pairs.

Fredrik Svanstrom, Cristofer Englund, and Fernando Alonso-Fernandez. Real-Time Drone Detection and Tracking With Visible, Thermal and Acoustic Sensors. In *Proc. Intl Conf on Pattern Recognition, ICPR, Milan, Italy, 10-15 January 2021*, 2020. URL https://arxiv.org/abs/2007.07396.

Yaman Umuroglu, Nicholas J. Fraser, Giulio Gambardella, Michaela Blott, Philip Leong, Magnus Jahre, and Kees Vissers. FINN : A Framework for Fast, Scalable Binarized Neural Network Inference. In *FPGA '17 : ACM/SIGDA International Symposium on Field-Programmable Gate Arrays*, 2016. doi : 10.1145/3020078.3021744. URL https://arxiv.org/abs/1612.07119.

Antonio Vitale, Alpha Renner, Celine Nauer, Davide Scaramuzza, and Yulia Sandamirskaya. Event-driven Vision and Control for UAVs on a Neuromorphic Chip. arXiv preprint, 2021. URL https://arxiv.org/abs/2108.03694. arXiv :2108.03694. Preprint non relu par les pairs.

Zishen Wan, Ashwin Lele, Bo Yu, Shaoshan Liu, Yu Wang, Vijay Janapa Reddi, Cong Hao, and Arijit Raychowdhury. Robotic Computing on FPGAs : Current Progress, Research Challenges, and Opportunities. arXiv preprint, 2022. URL https://arxiv.org/abs/2205.07149. arXiv :2205.07149. Preprint non relu par les pairs.

Justin williams, Kishor Datta Gupta, Roy George, and Mrinmoy Sarkar. LiteVLA-H : Dual-Rate Vision-Language-Action Inference for Onboard Aerial Guidance and Semantic Perception. arXiv preprint, 2026. URL https://arxiv.org/abs/2605.00884. arXiv :2605.00884. Preprint non relu par les pairs.

Xiaowei Xu, Xinyi Zhang, Bei Yu, Xiaobo Sharon Hu, Christopher Rowen, Jingtong Hu, and Yiyu Shi. DAC-SDC Low Power Object Detection Challenge for UAV Applications. *IEEE Transactions on Pattern Analysis and Machine Intelligence 43(2), 392-403*, 2021. doi : 10.1109/TPAMI.2019.2932429. URL https://doi.org/10.1109/TPAMI.2019.2932429.

Chenhongyi Yang, Zehao Huang, and Naiyan Wang. QueryDet : Cascaded Sparse Query for Accelerating High-Resolution Small Object Detection. arXiv preprint, 2021. URL https://arxiv.org/abs/2103.09136. arXiv :2103.09136. Preprint non relu par les pairs.

Fan Yang, Heng Fan, Peng Chu, Erik Blasch, and Haibin Ling. Clustered Object Detection in Aerial Images. arXiv preprint, 2019. URL https://arxiv.org/abs/1904.08008. arXiv :1904.08008. Preprint non relu par les pairs.

Azmain Yousuf, Siwei Cai, Knut Peterson, Lifeng Zhou, and David Han. Project SCOUT : Interceptor Drone for Perimeter Defense. arXiv preprint, 2026. URL https://arxiv.org/abs/2609.21005. arXiv :2609.21005. Preprint non relu par les pairs.

Wanjun Yu and Kongxin Mo. YOLO-GCOF : A Lightweight Low-Altitude Drone Detection Model. *IEEE Access 13, 53053-53064*, 2025. doi : 10.1109/ACCESS.2025.3553477. URL https://doi.org/10.1109/ACCESS.2025.3553477.

Chunhui Zhang, Guanjie Huang, Li Liu, Shan Huang, Yinan Yang, Xiang Wan, Shiming Ge, and Dacheng Tao. WebUAV-3M : A Benchmark for Unveiling the Power of Million-Scale Deep UAV Tracking. arXiv preprint, 2022. URL https://arxiv.org/abs/2201.07425. arXiv :2201.07425. Preprint non relu par les pairs.

Jingwei Zhang, Guoqing Li, Meng Zhang, Xinye Cao, Yu Zhang, Xiang Li, Ziyang Chen, and Jun Yang. A comprehensive analysis of DAC-SDC FPGA low power object detection challenge. *Science China Information Sciences 67(8), 182401*, 2024. doi : 10.1007/s11432-023-3958-4. URL https://doi.org/10.1007/s11432-023-3958-4.

Pengyi Zhang, Yunxin Zhong, and Xiaoqiong Li. SlimYOLOv3 : Narrower, Faster and Better for Real-Time UAV Applications. arXiv preprint, 2019a. URL https://arxiv.org/abs/1907.11093. arXiv :1907.11093. Preprint non relu par les pairs.

Xiaofan Zhang, Haoming Lu, Cong Hao, Jiachen Li, Bowen Cheng, Yuhong Li, Kyle Rupnow, Jinjun Xiong, Thomas Huang, Honghui Shi, Wen-Mei Hwu, and Deming Chen. SkyNet : a Hardware-Efficient Method for Object Detection and Tracking on Embedded Systems. arXiv preprint, 2019b. URL https://arxiv.org/abs/1909.09709. arXiv :1909.09709. Preprint non relu par les pairs.

Zhengxin Zhang. Drone-YOLO : An Efficient Neural Network Method for Target Detection in Drone Images. *Drones 7(8), 526*, 2023. doi : 10.3390/drones7080526. URL https://doi.org/10.3390/drones7080526.

Qi Zhao, Binghao Liu, Shuchang Lyu, Chunlei Wang, and Hong Zhang. TPH-YOLOv5++ : Boosting Object Detection on Drone-Captured Scenarios with Cross-Layer Asymmetric Transformer. *Remote Sensing 15(6), 1687*, 2023. doi : 10.3390/rs15061687. URL https://doi.org/10.3390/rs15061687.

Ye Zheng, Zhang Chen, Dailin Lv, Zhixing Li, Zhenzhong Lan, and Shiyu Zhao. Air-to-Air Visual Detection of Micro-UAVs : An Experimental Evaluation of Deep Learning. *IEEE Robotics and Automation Letters 6(2), 1020-1027*, 2021. doi : 10.1109/LRA.2021.3056059. URL https://doi.org/10.1109/LRA.2021.3056059.

Ye Zheng, Canlun Zheng, Xiaoyu Zhang, Fei Chen, Zhang Chen, and Shiyu Zhao. Detection, Localization, and Tracking of Multiple MAVs With Panoramic Stereo Camera Networks. *IEEE Transactions on Automation Science and Engineering 20(2), 1226-1243*, 2023. doi : 10.1109/TASE.2022.3176294. URL https://doi.org/10.1109/TASE.2022.3176294.

Pengfei Zhu, Longyin Wen, Dawei Du, Xiao Bian, Heng Fan, Qinghua Hu, and Haibin Ling. Detection and Tracking Meet Drones Challenge. arXiv preprint, 2020. URL https://arxiv.org/abs/2001.06303. arXiv :2001.06303. Preprint non relu par les pairs.

Xingkui Zhu, Shuchang Lyu, Xu Wang, and Qi Zhao. TPH-YOLOv5 : Improved YOLOv5 Based on Transformer Prediction Head for Object Detection on Drone-captured Scenarios. arXiv preprint, 2021. URL https://arxiv.org/abs/2108.11539. arXiv :2108.11539. Preprint non relu par les pairs.

A Glossaire des acronymes

Acronyme	Signification
ASIC	*Application-Specific Integrated Circuit*, circuit intégré conçu pour une seule fonction
CNN	*Convolutional Neural Network*, réseau de neurones convolutif
COCO	*Common Objects in Context*, jeu de détection généraliste (80 classes) et protocole d'AP moyenné sur les seuils d'IoU 0,5 à 0,95
CPU	*Central Processing Unit*, processeur généraliste
DMA	*Direct Memory Access*, transfert mémoire sans intervention du processeur
DVS	*Dynamic Vision Sensor*, caméra événementielle : chaque pixel émet un événement quand sa luminosité change
FINN	*FINN (AMD-Xilinx)*, toolflow dataflow open source pour réseaux quantifiés sur FPGA
FP32	*Floating Point 32 bits*, flottant simple précision ; FP16 : demi-précision
FPGA	*Field-Programmable Gate Array*, circuit logique reprogrammable ; en SoC (Zynq, Kria), associé à des cœurs ARM
GPU	*Graphics Processing Unit*, processeur graphique ; « GPU de bureau » (RTX, Titan, Tesla) par opposition au GPU embarqué des Jetson
IA	intelligence artificielle

Acronyme	Signification
INT8	*entiers sur 8 bits*, précision numérique après quantification ; INT4 : 4 bits
MCU	*Microcontroller Unit*, microcontrôleur (Cortex-M, GAP8, MAX78000)
NPU	*Neural Processing Unit*, accélérateur de réseaux de neurones (Hailo-8, Edge TPU, VPU Myriad)
PID	*Proportionnel-Intégral-Dérivé*, régulateur classique du contrôle de vol
PS	*Processing System*, partie processeur (cœurs ARM) d'un SoC FPGA ; PL : logique programmable
PTQ	*Post-Training Quantization*, quantification après entraînement, avec un jeu de calibration
QAT	*Quantization-Aware Training*, entraînement qui simule la quantification, en général moins coûteux en précision que la PTQ
SEU	*Single Event Upset*, inversion d'un bit par une particule (radiations) ; la mémoire de configuration d'un FPGA y est sensible
SNN	*Spiking Neural Network*, réseau de neurones impulsionnels, exécuté sur puce neuromorphique (Loihi)
SoC	*System on Chip*, puce intégrant processeurs et accélérateurs (SoC FPGA : Zynq, Kria)
SRAM	*Static RAM*, mémoire statique ; dans un FPGA, elle stocke aussi la configuration
TDP	*Thermal Design Power*, puissance thermique nominale d'une puce, pas sa consommation mesurée
UWB	*Ultra-Wideband*, radio à bande ultra-large, utilisée pour la télémétrie de distance
VOC	*PASCAL Visual Object Classes*, jeu de détection généraliste (20 classes)

B Lexique

Terme	Sens dans ce document
air → air	contre-drone où le détecteur est à bord d'un drone (intercepteur) ; seul cas qui relève de l'IA embarquée
backbone	partie du réseau qui extrait les caractéristiques, avant le neck et les têtes
boucle fermée	la perception pilote réellement le drone pendant l'essai, par opposition à une évaluation sur données enregistrées
bout en bout (latence, débit)	de l'acquisition de l'image à la sortie des boîtes, pré- et post-traitement compris
dataflow, streaming	architecture d'accélérateur où chaque couche a son propre bloc matériel, les données circulant en flux entre blocs
déduit	inférence de la fiche ou de ce document, par opposition à ce que disent les auteurs
depthwise, GhostConv	convolutions allégées (par canal, ou générant une partie des cartes par opérations bon marché) ; peu de FLOPs mais souvent mal servies par les accélérateurs
DSP packing	calcul de plusieurs multiplications à faible précision dans un même bloc DSP
ego-motion	mouvement propre de la caméra embarquée, à compenser avant d'exploiter le mouvement de la cible
élagage (pruning)	suppression de canaux, de couches ou de poids ; seul l'élagage structuré accélère sur matériel
flot optique	champ de déplacement apparent des pixels entre deux images
hardware-in-the-loop	simulation du drone et de son environnement avec le calculateur réel dans la boucle
`n/r`	valeur non rapportée par les auteurs ; jamais estimée
pixel throughput	débit normalisé par la résolution : FPS × pixels par image
point de genou	dans le modèle F-1, débit de décision au-delà duquel accélérer le calcul n'augmente plus la vitesse sûre
preprint ([PP])	article déposé sur arXiv, non relu par les pairs dans la version ingérée
quantification	passage des poids et activations à une précision réduite (INT8, INT4, W4/A4)
roofline, modèle F-1	modèle de performance borné par le calcul et la mémoire ; F-1 : sa version pour drone, qui borne la vitesse sûre
sol → air	contre-drone où le capteur est fixe au sol
sortie anticipée (early-exit)	arrêt de l'inférence à une couche intermédiaire quand une branche légère juge le résultat suffisant
soustraction de fond	détection de ce qui bouge par différence avec un modèle du fond ; suppose une caméra fixe
space-to-depth	réorganisation d'une carte spatiale en canaux, qui garde le détail sans augmenter la résolution traitée
télémétrie	mesure de puissance par les capteurs de la carte (tegrastats, PMIC) ; portée puce ou module
test-dev, validation	splits d'évaluation de VisDrone ; les chiffres de l'un ne se comparent pas à ceux de l'autre
toolflow	chaîne automatique qui transforme un réseau entraîné en accélérateur (FINN, SATAY, Vitis AI)
tuilage	découpage d'une image haute résolution en tuiles inférées séparément
Wx/Ay	précision numérique : poids sur x bits, activations sur y bits

Glossaires

Chaque entrée renvoie aux sections où le terme apparaît ; dans le texte, chaque apparition est un lien vers son entrée. Une valeur suivie de [constructeur, hors corpus] vient de la documentation du constructeur, [hors corpus] de connaissances générales : ni l'une ni l'autre n'est tirée du corpus. Les acronymes et le vocabulaire propre à ce document sont dans les deux annexes précédentes.

Glossaire des plateformes

Apollo4b MCU Ambiq à Cortex-M4F (1,8 V, 192 MHz), le plus sobre en puissance du banc de TinyissimoYOLO : 59 μW/MHz mais 6,1 mJ par inférence, soit environ 31 fois l'énergie du MAX78000 *(déduit)*, (Moosmann et al., 2023, §III). Puissance du MCU seul (portée puce), sans watts absolus. Gamme nano. 10

Crazyflie Nano-quadrirotor de Bitcraze, 27 g et 10 cm d'envergure (Lamberti et al., 2023, §III-A)[PP] ; contrôleur de vol STM32F405 à 168 MHz (Palossi et al., 2021, §III)[PP]. Le Crazyflie 2.1 Brushless embarque une LiPo de 350 mAh (Carboni et al., 2026, §III-B)[PP]. Porteur de l'AI-deck (GAP8) et du GAP9Shield (GAP9). Gamme nano : le budget de la plateforme est d'environ 1 W au total, dont quelques centaines de mW de calcul (Marra et al., 2026, Abstract, §1)[PP]. 6

DPU (DPUCZDX8G) IP d'inférence CNN de Xilinx (AMD) livrée avec Vitis AI : processeur programmable en INT8, implanté dans la PL des Zynq UltraScale+, auquel le compilateur envoie un flot d'instructions. Configurations B512 à B4096, où le nombre est le parallélisme crête en opérations par cycle (B4096 : 4 096 op./cycle, soit environ 1,2 TOPS à 300 MHz *(déduit)*), jusqu'à quatre cœurs par puce [constructeur, hors corpus]. Sur ZCU104, une B4096 occupe 55,8 k LUT, 710 DSP, 142 BRAM et 46 URAM, pour 8,76 W estimés par Vivado (B512 : 4,79 W) (Karki et al., 2026, Table III)[PP]. C'est le flot FPGA le plus courant du corpus drone : YOLOv26n modifié à 34,05 FPS sur un cœur B4096 (Karki et al., 2026, §IV-C)[PP], YOLOv4 sur deux cœurs (Nguyen et al., 2024), LCAM-YOLOX à 195 FPS sur KV260 (Elhence et al., 2025, §V-D). Les ressources du DPU ne sont pas rapportées par Nguyen et al. (2024). 4, 5

Google Edge TPU (Coral) ASIC d'inférence INT8 de Google, 4 TOPS pour 2 W [constructeur, hors corpus], en clé USB ou module. Sur Raspberry Pi 5 + Coral USB, YOLOv8 doit passer en 320×320 (mAP COCO 16 à 32) pour 21 à 97 ms et 0,47 à 0,62 mWh par requête (Alqahtani et al., 2024, §III-B2, §IV)[PP]. Comparé à un FPGA Zynq-7020 : 103 à 149 FPS pour 1,2 à 2,4 W, mais puissance tirée de la datasheet puis extrapolée, contre une mesure de carte entière côté FPGA (Calì et al., 2025, Table 15). 5

GPU de bureau ou de serveur Cartes graphiques GeForce, Titan, Tesla et A-series de NVIDIA, de 120 à 450 W [constructeur, hors corpus]. Elles servent dans le corpus drone à l'entraînement ou à des mesures de FPS « non embarquées » : aucune n'est montée à bord, et aucune puissance mesurée n'accompagne les FPS (sauf Nguyen et al., 2024, Tables 5 et 14). Ces chiffres ne sont donc comparables ni aux Jetson ni aux FPGA, et un FPS sur RTX ne prouve pas la faisabilité embarquée. Gamme : bureau ou serveur, centaines de W. 4, 10

GPU de cloud (T4, A10, A6000, Titan RTX) Cartes de serveur ou de service de cloud. Tesla T4 de Google Colab : YOLO-Drone en 1,8 ms (Jung, 2025, Table 2). A10 de 24 Go : évaluation de YOLO-GCOF (Yu and Mo, 2025, §IV-D7). RTX A6000 sur serveur Xeon Gold : SmolVLM-256M en 720 ms entièrement dans le cloud contre 2 760 ms entièrement à bord et 2 090 ms en découpage cloud-bord (Azimi et al., 2026, §V-A1)[PP]. Deux Titan RTX pour l'entraînement de SiamAPN++ (Cao et al., 2021a, Fig. 4a)[PP]. Gamme : serveur. 4, 9

GeForce GTX 1080 Ti GPU Pascal de 2017, plateforme des mesures de vitesse d'avant 2022. ClusDet : 273 ms par image (Yang et al., 2019, Table 1)[PP] ; UFPMP-Det (Huang et al., 2021, Table 3)[PP] ; SiamRPN++ sur backbone SkyNet à 41,2 FPS (Zhang et al., 2019b, Table 8)[PP]. Entraînement de Dogfight (Ashraf et al., 2021, Table 1)[PP]. Portable : une GTX 1070 Max-Q sert à NanoFlowNet (141 FPS, TensorRT 7.2.2, lot de 1, Bouwmeester et al., 2022, Table IV[PP]) et une MX150 au détecteur multi-capteurs sol → air de Svanstrom et al. (2020, §III-B). 3, 4

GeForce RTX 2060 GPU Turing de milieu de gamme. Station d'évaluation de SF-YOLOv5 : 11,0 à 12,2 ms par image pour la version légère contre 49,4 ms pour SF-YOLOv5L (Liu et al., 2022, Tables 3 et 4). Aucune puissance rapportée. 4

GeForce RTX 2080 Ti GPU Turing haut de gamme, référence de bureau du détecteur aérien : temps d'inférence de 32 ms (YOLOv3), 84 ms (SSD512) et 157 ms (Grid R-CNN) sur Det-Fly (Zheng et al., 2021, §V-A, Table II), QueryDet à 14,9 FPS (Yang et al., 2021, Table 1)[PP]. Baseline GPU du ZCU104 : YOLOv4 à 66,9 FPS pour 255,4 W, soit un FPS/W deux à trois fois plus faible que le FPGA (Nguyen et al., 2024, §5.3, Tables 5 et 14). La RTX 2080 non Ti de bureau mesure 2,6 ms pour un réseau de vol (Loquercio et al., 2021, Table 1). 5, 8

GeForce RTX 3060, 3070 et 3080 Ti GPU Ampere de milieu à haut de gamme. RTX 3060 : entraînement de GCL-YOLO sur deux cartes, 42 à 58 FPS sans plateforme de test précisée (Cao et al., 2023, Table 3), simulation d'YOPOv2-Tracker en 3 ms (Lu et al., 2025, §IV-B-1)[PP]. RTX 3070 : GLAD à 146,5 FPS (Guo et al., 2023, Table IV)[PP]contre 23,6 FPS sur Xavier NX, et détection de MAV à 9 FPS (97,8 ms) (Zheng et al., 2023, §VII-B3). RTX 3080 Ti : entraînement de Drone-YOLO (Zhang, 2023, §4.1, Table 4), porté ensuite sur TX2. 7

GeForce RTX 3090 et 3090 Ti GPU Ampere haut de gamme, environ 450 W de TDP pour la 3090 Ti *(déduit)*. Entraînement et test de TPH-YOLOv5 (Zhu et al., 2021, §4.1)[PP], puis TPH-YOLOv5 de Zhao et al. sur 3090 Ti : 7,4 FPS (TPH-YOLOv5) et 11,9 FPS (TPH-YOLOv5++) en Table 5, 25,1 et 42,2 FPS en Tables 4 et 6 (Zhao et al., 2023), Efficient YOLOv7-Drone à 89,3 FPS (Fu et al., 2023, Tables 2 et 5). Exemple type de résultat non embarqué, sans puissance ni transposition à un calculateur de bord. 4

GeForce RTX 4090 GPU Ada Lovelace de 24 Go, le plus puissant du corpus. F-YOLOv7 : 169 FPS en débit sur GPU (Du et al., 2025, Table 2, §5.2) ; entraînement de la politique E2E-Fly (Sun et al., 2026, §VII-B)[PP]. Les versions portables servent à DroneScan-YOLO (96,7 FPS sur RTX 4090 Laptop, Bellec, 2026, Table 4[PP]) et à DotD-YOLOv9 (RTX 4060 Laptop, Gao et al., 2024, Table 5). Aucune de ces valeurs n'est une mesure embarquée ni accompagnée d'une puissance. 4, 8

Tesla P100 GPU de serveur NVIDIA (Pascal). Seule plateforme d'inférence de Liu et al. (2021, §4.2, Table 4) : YOLOv4 de référence à 43 FPS, YOLOv4 élagué (canaux 0,9) à 79 FPS. Les auteurs n'ont mesuré aucune cible embarquée, et les FPS sur P100 ne disent rien de la latence sur Jetson, FPGA ou MCU. 8

Hailo-8 NPU dataflow de la société Hailo, 26 TOPS INT8 pour environ 2,5 W typiques [constructeur, hors corpus]; utilisée via la carte Raspberry Pi AI HAT+ et HailoRT (Alqahtani et al., 2024, §III-B2)[PP]. Seul NPU du corpus drone : YOLOv8n, mAP COCO 32 en 76 ms (jusqu'à 240 ms), 0,20 à 0,36 mWh par requête hors repos ; SSD MobileNet V1 en 89 ms (Alqahtani et al., 2024, §IV)[PP]. Précision numérique `n/r`. 10

Intel N100 (Radxa X4) Processeur x86 basse consommation d'Intel, 4 cœurs et TDP de 6 W [constructeur, hors corpus], sur la carte Radxa X4. Ordinateur de bord (avec RealSense D435i) du drone VIS-R de 750 g d'E2E-Fly : la boucle perception-contrôle y a une latence inférieure à 30 ms contre environ 90 ms avec un calcul déporté (Sun et al., 2026, §VI-A, §VI-C2)[PP]. Puissance, latence d'inférence et taille de la politique `n/r` ; gamme intermédiaire entre FPGA et Jetson (quelques W à environ 10 W, ordre de grandeur *(déduit)*, non mesuré). 7

Jetson Gamme NVIDIA de modules embarqués (SoC ARM + GPU CUDA, mémoire LPDDR partagée) et de kits de développement ; logiciel JetPack et TensorRT (FP32, FP16, INT8), modes de puissance réglables [constructeur, hors corpus]. Référence de la gamme « Jetson » (autour de 10 W) et ordinateur de bord de la plupart des drones agiles et de navigation du corpus (TX2, Xavier NX, Orin). Les puissances rapportées sont rarement des mesures à l'entrée de la carte : télémétrie tegrastats ou jtop de portée mal définie. 0–2, 5–12

Jetson AGX Xavier Module haut de gamme de la génération Volta, 10 à 30 W et 32 TOPS INT8 [constructeur, hors corpus]; TDP « de l'ordre de 30 W » (Krishnan et al., 2020, §4). Ordinateur de bord des suiveurs aériens : HiFT à 31,2 FPS sans TensorRT (Cao et al., 2021b, §5)[PP], TCTrack à 27 FPS contre 125,6 sur PC (Cao et al., 2022, §5)[PP], SiamAPN++ à 34,9 FPS (Cao et al.,

2021a, §V)[PP]. VGG-16 de contrôle à 28 Hz (Krishnan et al., 2020, §4). Mode de puissance non précisé dans ces papiers. 7, 9

Jetson Nano GPU Maxwell 128 cœurs (0,5 TFLOPS), 4 Go de LPDDR4, 5 à 10 W (Feng et al., 2022, Table 2). YOLOv3-tiny 416 à 6,8 FPS pour 7,2 W, YOLOv3 à 1,7 FPS pour 7,9 W (portée non précisée, Feng et al., 2022, Table 3) ; YOLOv4-tiny à 15 FPS (Table 6). LCAM-YOLOX à 65 FPS contre 195 sur KV260 (Elhence et al., 2025, §V-D). Latence de 104 à 509 ms pour YOLOv8 n/s/m (Alqahtani et al., 2024, §IV)[PP]. Baseline de l'énergie des réseaux à impulsions sur Loihi (modes 5 et 10 W) (Paredes-Vallés et al., 2023, §Energy benchmark)[PP]. 6, 10

Jetson Orin Génération Jetson à GPU Ampere et CPU Cortex-A78AE [constructeur, hors corpus]: Orin Nano, Orin NX, AGX Orin. La plus récente du corpus et la plus utilisée par les papiers de 2025-2026 sur la navigation et les modèles vision-langage embarqués. 0, 5, 7, 10–12

Jetson AGX Orin Module haut de gamme Orin : jusqu'à 275 TOPS INT8 et 15 à 60 W pour la version 64 Go [constructeur, hors corpus]. Cible de LiteVLA-H, un modèle vision-langage-action de 256 M de paramètres en FP16 : 19,7 Hz (50,7 ms) en mode action et 6,1 à 6,7 Hz en mode sémantique (williams et al., 2026, Table 2, §6.1)[PP], avec un surcoût de 3,6 W sans méthode de mesure (puissance absolue et mode de puissance `n/r`). Gamme Jetson haute, dizaines de W. 9

Jetson Orin Nano 6 × Cortex-A78AE, GPU Ampere 1 024 cœurs + 32 Tensor Cores, 8 Go, 7 à 15 W (Rey et al., 2025, Table 2) ; 40 TOPS INT8 annoncés pour la version 8 Go [constructeur, hors corpus]. YOLOv8n INT8 à 44,9 FPS pour 7,48 W, en FP32 à 37,0 FPS pour 8,35 W, puissance de portée *puce* par télémétrie (Rey et al., 2025, Table 4). Version 4 Go : YOLOv8n en 16 ms, YOLOv8m en 50 ms, énergie au repos de 362 mWh sur 5 min, la plus haute du banc (Alqahtani et al., 2024, §IV, Fig. 2a)[PP]. Version 8 Go de SINGER : CLIPSeg de 3 à 12 Hz avec ONNX CUDA (Adang et al., 2025, §V, §VI-C)[PP]. 7, 9, 10

Jetson Orin NX 8 × Cortex-A78AE, 16 Go, 10 à 25 W (Rey et al., 2025, Table 2). La même table donne un GPU Ampere de 2 048 cœurs + 64 Tensor Cores, alors que la fiche constructeur annonce 1 024 cœurs + 32 Tensor Cores et 100 TOPS INT8 pour la version 16 Go [constructeur, hors corpus]. YOLOv8n INT8 : 65,8 FPS pour 10,3 W de puce, YOLOv8s INT8 56,3 FPS pour 11,0 W (Rey et al., 2025, Table 4). Ordinateur de bord le plus fréquent des drones agiles de 2025-2026 : YOLOv11-small à 92 Hz (TensorRT FP16) et complétion de profondeur en 31,6 ms (Saviolo and Loianno, 2025, §IV-B, §IV-C)[PP], YOPOv2-Tracker en 8,2 ms (Lu et al., 2025, §IV-B-3)[PP], YOLO26n + ByteTrack à 48 FPS (20,8 ms) sur le drone intercepteur de SCOUT (Yousuf et al., 2026, Table IV)[PP], géolocalisation NGPS à 2,6 Hz sur GPU contre 0,5 Hz sur CPU (Sharma, 2026, §IV-D)[PP]. Puissance non rapportée dans ces quatre derniers papiers. 7–12

Jetson TX2 GPU Pascal 256 cœurs (1,33 TFLOPS crête), 8 Go, JetPack 4.4.1 (Zhang, 2023, §4.1). Plateforme GPU imposée de DAC-SDC (Xu et al., 2021, §2.2) : SkyNet à 67,3 FPS pour 13,5 W (mesure de l'organisateur, portée non précisée) (Zhang et al., 2019b, Table 5)[PP]. Ordinateur de bord du drone gagnant de la course Swift : détecteur de portes de 40 ms (TensorRT FP16) sur GPU et politique de 8 ms sur CPU (Kaufmann et al., 2023, Methods) ; réseau de vol à 24,3 FPS (41,6 ms) (Loquercio et al., 2021, Table 1). Drone-YOLO nano et tiny en 127 et 190 ms (Zhang, 2023, Table 6). Baseline de SATAY : YOLOv5n 640 en 32,3 ms pour 8,58 W (Montgomerie-Corcoran et al., 2023, Table IV). VGG-16 de contrôle à 10 Hz (Krishnan et al., 2020, §4). 3–5, 7, 9–12

Jetson Xavier NX GPU Volta 384 cœurs + 48 Tensor Cores (1,3 TFLOPS), 8 Go de LPDDR4x, 10 à 15 W, mode 15 W à 6 cœurs (Feng et al., 2022, Table 2) ; 21 TOPS INT8 [constructeur, hors corpus]. YOLOv3-tiny 416 à 41,1 FPS pour 13,5 W, YOLOv3 à 6,1 FPS pour 15,2 W (portée non précisée, Feng et al., 2022, Table 3). Détecteur de MAV GLAD à 23,6 FPS (Guo et al., 2023, Table VIII)[PP], GL-YOMO à 21,6 FPS en 640 × 640 (Liu et al., 2024, §IV-E)[PP]. 8, 10

Intel Loihi (Kapoho Bay) Puce neuromorphique d'Intel à réseaux de neurones impulsionnels. La clé Kapoho Bay embarque 2 puces, 256 neuro-cores, 262 144 neurones, 260 M de synapses et 3 cœurs x86 (Vitale et al., 2021, §II-A)[PP]. Transformée de Hough en 250 μs (20 kHz contre 1 kHz sur CPU) à partir d'une caméra événementielle, hôte Atom x5-Z8350 (Vitale et al., 2021, Fig. 2, §II-B)[PP]. Atterrissage entièrement neuromorphique à 200 Hz, à 27 μJ par inférence mesurés non pas

sur la Kapoho Bay mais sur une carte Nahuku, sans entrées-sorties, contre trois à quatre ordres de grandeur de plus sur Jetson Nano (Paredes-Vallés et al., 2023, Abstract, §Energy benchmark)[PP]. La puissance du système embarqué (UP Squared + USB) n'est pas rapportée. 6, 8

MAX78000 MCU de Maxim (Analog Devices) à accélérateur CNN intégré (1,2 V, 50 MHz) : entrée limitée à 88×88 et 442 ko de poids. TinyissimoYOLO y tourne en 5,5 ms (180 FPS) pour 196 μJ par inférence, à 107 MAC/cycle, soit le meilleur point du banc devant STM32H7A3, STM32L4R9 et Apollo4b (Moosmann et al., 2023, Abstract, §II-C, §III). Puissance du MCU seul. Gamme nano, mais sans cible drone testée. 6, 10

Intel NCS et NCS2 (Myriad) Neural Compute Stick : clé USB 3.0 d'Intel à VPU Movidius Myriad, utilisée avec un Raspberry Pi. Le NCS2 (Myriad X, environ 1 TFLOPS) ajoute 1 W à la carte, 0,64 W au repos (Feng et al., 2022, Tables 2 et 4) : YOLOv3-tiny 416 à 18,8 FPS pour 6,5 W (portée non précisée), YOLOv3 à 2,5 FPS (Table 3), mais confiance moyenne nulle sur une des vidéos. Le NCS de première génération exécute le VGG-16 de contrôle à 1,3 Hz, et DroNet y suffit à une vitesse de vol maximale supérieure à celle de Xavier + VGG-16 (Krishnan et al., 2020, §4). 9, 10

PULP Parallel Ultra-Low Power : plateforme matérielle open source de l'ETH Zürich et de l'université de Bologne, à cluster de cœurs RISC-V partageant une mémoire L1 (Flamand et al., 2018, §I). Base des puces GAP8 et GAP9, et des réseaux Tiny-PULP-Dronets (Lamberti et al., 2024)[PP]. Gamme nano : quelques dizaines de mW.

GAP8 SoC RISC-V de GreenWaves (TSMC 55 nm LP), un fabric controller et un cluster de 8 cœurs, 512 ko de L2 et 64 ko de L1 (Palossi et al., 2021, §III)[PP], avec un accélérateur de convolution (HWCE) (Flamand et al., 2018, §IV) : 27 mW pour le FC seul, 75 mW au pire cas à 1,2 V (Table II ; méthode de mesure non décrite). Sur PULP-Shield, DroNet atteint 6 FPS pour 64 mW de shield (1,0 V, FC 50 MHz, cluster 100 MHz) et 18 FPS pour 284 mW (1,2 V, 250 MHz) (Palossi et al., 2018, §VI-A, §VII)[PP]. PULP-Frontnet : 134,7 FPS pour 86,6 mW de puce, ou 18,5 FPS pour 8,6 mW (Palossi et al., 2021, §V-B)[PP]. Tiny-PULP-Dronet : 89 FPS pour 34 mW de puce (Lamberti et al., 2024, §III-A)[PP]. 1, 2, 6, 10–12

AI-deck Carte Bitcraze de 4,4 g à GAP8, caméra monochrome Himax HM01B0 QVGA, HyperRAM de 64 Mbit et HyperFlash de 512 Mbit (Palossi et al., 2021, §III)[PP], montée sur Crazyflie. L'AI-deck consomme 134,5 mW de carte avec SSD-MobileNetV2 1,0× à 1,6 FPS, et 143,5 mW à 2,3 FPS avec la version 0,75× (Lamberti et al., 2023, Table II)[PP]; BlankSkip : 1,86 FPS (537 ms) contre 1,50 FPS (667 ms) pour le réseau statique (Marra et al., 2026, Table 2)[PP]; NanoFlowNet : 5,6 FPS (Bouwmeester et al., 2022, Table IV)[PP], contre 141 FPS sur une GPU de portable. Aucun détecteur type YOLO ne tourne à plus de quelques FPS. 6

GAP9 (NE16) MCU RISC-V de GreenWaves, dérivé de PULP, avec accélérateur NE16 : 15,6 GOPS en DSP, 32,2 GMAC/s en apprentissage automatique à 330 μW/GOP, jusqu'à 370 MHz, 1,6 Mo de L2 et 2 Mo de mémoire non volatile (Müller et al., 2024, §2.1)[PP]. Les papiers divergent sur le nombre de cœurs de cluster (8 selon Carlotti et al., 2026, §IV-A[PP], 9 selon Müller et al., 2024, §2.1[PP]) *(déduit)*: 8 cœurs de cluster et un fabric controller. NE16 : CNN de 6 M de paramètres (318 MMAC) en 30,4 ms soit 32,8 FPS (Carlotti et al., 2026, §V)[PP], puissance `n/r` (le « moins de 100 mW » est un chiffre constructeur cité par les auteurs). Tiny-DroNeRF (apprentissage embarqué d'un NeRF) : pas d'entraînement de 73 ms à 60 mW, estimé par simulation cycle-exact et non mesuré sur le matériel (Carboni et al., 2026, §III-B, §V-C)[PP]; NE16 n'y est pas utilisé (propagation arrière en virgule flottante). 0–2, 6, 10–12

GAP9Shield Carte de 6 g (4 050 mm^3) à GAP9 pour Crazyflie, avec PSRAM de 256 Mbit, flash de 512 Mbit, caméra OV5647, module Wi-Fi et télémètre VL53L1 (Müller et al., 2024, §2.1, §3.1)[PP]. Mesures du shield (sans méthode de puissance décrite) : caméra à 80 mW (QVGA, 15 fps) et 120 mW (VGA, 45 fps), Wi-Fi à environ 250 mW, télémètre jusqu'à 150 mW ; aucun chiffre de détection mesuré par les auteurs (YOLO modifié à 38 ms et 2,5 mJ rapporté d'un travail antérieur, §3.2). Plateforme de Tiny-DroNeRF et de l'adaptation de domaine auto-supervisée. 6

Raspberry Pi Ordinateur monocarte ARM, utilisé comme CPU de référence ou comme hôte d'un accélérateur (NCS2, Coral, Hailo). Raspberry Pi 4B de 4 Go de LPDDR4, 3 à 6,25 W (Feng et al.,

2022, Table 2). Le Raspberry Pi 3B manque de mémoire pour le VGG-16 de contrôle et sature sur DroNet (Krishnan et al., 2020, §4). Sur RPi 5 en CPU, YOLOv8 coûte de 316 à 1 348 ms et de 1,0 à 3,6 mWh par requête (Alqahtani et al., 2024, §IV)[PP]. Gamme : quelques W. 4, 8, 10

Raspberry Pi 5 4 × Cortex-A76 à 2,4 GHz, 8 Go, 5 à 7 W (Rey et al., 2025, Table 2). En CPU seul : YOLOv8n FP32 à 8,5 FPS (118 ms) pour 5,44 W de puce, YOLOv8s à 7,3 FPS (211 ms) (Rey et al., 2025, Table 4) ; le pipeline en temps réel n'a pas pu être tenu (§5.1). Avec la carte AI HAT+ (Hailo-8), YOLOv8n passe à 76 ms (Alqahtani et al., 2024, §IV)[PP]. Hôte courant des accélérateurs USB ou M.2 de comparaison, jamais embarqué sur un drone dans le corpus. 10

STM32H7A3 MCU STMicroelectronics à Cortex-M7 (3,3 V, 192 MHz dans le banc de Moosmann et al., 2023, §III) : TinyissimoYOLO en 359 ms par inférence, soit environ 65 fois le MAX78000 (§III, Fig. 2a ; rapport calculé *(déduit)*). Le tableau de Elhence et al. (2025, §V-D) annonce 15 FPS pour un modèle de 6,7 à 9,6 M de paramètres, valeur invraisemblable pour un Cortex-M7 *(déduit)*. Le pic théorique d'un STM32H7 à 400 MHz, 276 MMAC/s pour 346 mW, est celui de la comparaison de Palossi et al. (2018, §VI-B)[PP] avec GAP8 (non mesuré). Gamme nano à centaines de mW. 5, 6, 10

Zynq Famille de SoC FPGA de Xilinx (AMD) : un processeur ARM durci (PS) et une logique programmable (PL) sur la même puce, reliés par des bus AXI. Le corpus en utilise deux générations, le Zynq-7000 et le Zynq UltraScale+ MPSoC (dont le module Kria K26). Le panorama des calculateurs de drone de Ahmed and Jenihhin (2022, Table 2, §3.1.3) range les SoC FPGA Xilinx parmi les cartes de vol les plus utilisées ; le prototype de Guo et al. (2021, §III) associe un Zynq-7020 à une Jetson AGX Xavier. Gamme de puissance : FPGA (de 1 à 30 W de carte selon le kit). 2

Zynq UltraScale+ MPSoC Seconde génération de Zynq, en 16 nm (Zhang et al., 2024, Table 1, §2.2) ; PS quadri Cortex-A53 (Nguyen et al., 2024, §4.3), double Cortex-R5F et GPU Mali-400 [constructeur, hors corpus]; PL à DSP48E2, BRAM et, sur les plus grosses puces, URAM [constructeur, hors corpus]. Cible du DPU de Vitis AI. Dans le texte, « UltraScale » seul peut aussi désigner les FPGA Virtex UltraScale(+) sans processeur (VCU110, VCU118). Gamme FPGA : 1,4 à 30 W de carte selon le kit (Ultra96 contre ZCU104 mesurée à la prise). 11

Kria KV260 Kit de démarrage AMD Xilinx « Vision AI » à module Kria K26 (puce XCK26, non citée par les papiers du corpus ; 117 120 LUT et 1 248 DSP [constructeur, hors corpus]). Le survey de Sali et al. (2025, Table V)[PP] donne 70 560 LUT, valeur du XCZU3EG et non du K26 *(déduit)*. Seule carte FPGA du corpus montée comme ordinateur compagnon d'un drone (Pixhawk, caméra USB) : LCAM-YOLOX INT8 à 195 FPS pour 9,72 W de carte sur un cœur DPU, 387 FPS pour 10,45 W sur deux, soit 37,15 FPS/W (Elhence et al., 2025, §V-A, §V-D, §V-G). Les mêmes auteurs placent ce travail sur ZCU102 dans le texte et sur KV260 dans la Table VII (Sali et al., 2025, §VI-A)[PP]. SiamRPN++ : 6,37 FPS pour 1,11 W (Sali et al., 2025, Table IX)[PP]. Environ 10 W de carte : la gamme d'une Jetson, pas celle d'un FPGA nano. 5, 10–12

XCZU3EG Plus petite puce Zynq UltraScale+ du corpus : 71 k LUT, 360 DSP, DDR4 de 2 Go sur la carte (Zhang et al., 2024, Table 1, §2.2) ; 432 BRAM18 (Blott et al., 2018, §5.1) ; précisément 70 560 LUT, 141 120 FF et 216 BRAM36, sans URAM [constructeur, hors corpus]. Zhang et al. indiquent « 7,6 Mo » de BRAM, probablement des Mbit *(déduit)*. Puce de l'Ultra96, carte des éditions 2019 à 2022 de DAC-SDC. 11

Ultra96 (V1, V2) Carte Avnet à XCZU3EG, 2 Go de LPDDR4 [constructeur, hors corpus]. Carte FPGA du concours DAC-SDC de 2019 (V1) puis de 2020 à 2022 (V2), puissance mesurée par l'organisateur à la carte (Zhang et al., 2024, §2.3). V1 : SkyNet à 25,1 FPS pour 7,26 W (Zhang et al., 2024, Table 3) (pic théorique 144 GOPS à 200 MHz, Zhang et al., 2019b, §6.4[PP]). V2 : UltraNet à 212,7 FPS pour 6,65 W en 2020 (Table 4), puis jusqu'à 2 020,6 FPS pour 1,41 W en 2022 (Table 6) avec DSP packing (Zhang et al., 2024, §3.3, §3.5). FINN-R y atteint 5,1 TOP/s à 300 MHz pour 11,8 W de carte (Blott et al., 2018, Table 5). 3, 5

XCZU7EV Puce Zynq UltraScale+ EV : 230 400 LUT et 1 728 DSP (Sali et al., 2025, Table V)[PP]; 460 800 FF, 312 BRAM36 et 96 URAM [constructeur, hors corpus]. Référence de désignation : XCZU7EV-2FFVC1156E (Nguyen et al., 2024, §4.3). Puce de la ZCU104.

ZCU104 Carte d'évaluation Xilinx à XCZU7EV, 4 Cortex-A53. Carte FPGA la plus utilisée

du corpus drone. DPU B512 à B4096 : YOLOv26n modifié à 34,05 FPS (29,4 ms) pour 8,76 W estimés par Vivado (Karki et al., 2026, §IV-C, Table III)[PP]. YOLOv4 sur deux cœurs DPU : 17,9 FPS pour 30,1 W et YOLOv4-tiny 125 FPS pour 26,4 W, mesurés à la prise (16,1 W au repos), donc un kit de développement et non un calculateur embarquable (Nguyen et al., 2024, Tables 12, 13, 15). LCAM-YOLOX à 337 FPS (deux cœurs) pour 13,2 W de carte (Elhence et al., 2025, §V-D). SATAY : YOLOv5n 640 en 21,4 ms pour 14,5 W (portée non précisée), 317 mJ contre 277 mJ sur TX2 (Montgomerie-Corcoran et al., 2023, Table IV, §VI-B). 5, 8, 10

Zynq-7000 Première génération de Zynq, en 28 nm (Zhang et al., 2024, Table 1, §2.2) ; PS double Cortex-A9, à 750 MHz sur Z-turn (Calì et al., 2025, §3). Le Cortex-A9 traite 24,2 Mpixels/s contre 5,68 pour le Cortex-M4 d'un Pixhawk (Guo et al., 2021, §I). Petite cible bas coût du corpus drone : concours DAC-SDC 2018, FINN, YOLOv3-Tiny réduit à 208 FPS pour 2,55 W de carte (Calì et al., 2025, Tables 9 et 14).

XC7Z020 (Zynq-7020) Puce Zynq-7000 la plus utilisée du corpus : 53 200 LUT, 220 DSP, DDR3 de 512 Mo sur PYNQ-Z1 (Xu et al., 2021, §2.2), 280 BRAM18 (Blott et al., 2018, §5.1). Les BRAM y font 630 Ko selon Xu et al. (2021, §2.2), mais « 4,9 Mo » selon Zhang et al. (2024, Table 1), qui confond probablement Mbit et Mo *(déduit)*. Cartes du corpus : PYNQ-Z1, Z-turn Board V2. Un design YOLOv3-Tiny réduit en occupe 41 605 LUT (78,2 %), 204 DSP (92,7 %) et 138 BRAM18 (Calì et al., 2025, Table 7). 5, 7, 10

PYNQ-Z1 Carte de développement Digilent [constructeur, hors corpus] à XC7Z020-1CLG400C, « environ 1-4 W » (Xu et al., 2021, §2.2). Carte FPGA imposée de DAC-SDC en 2018, où les gagnants mesurés par l'organisateur à la carte atteignent 12,0 FPS pour 4,2 W (TGIIF, SSD) et 26,0 FPS pour 2,45 W (SystemsETHZ) (Zhang et al., 2024, Table 2, §3.1). FINN-R y mesure 2,25 à 2,5 W de carte (Tincy YOLO : 133 GOP/s à 100 MHz) (Blott et al., 2018, Table 5). Gamme FPGA, quelques W. 3

Z-turn Board V2 Carte MYiR à XC7Z020CLG400-2, 1 GiB de DDR3, PS à 750 MHz, environ 150 euros (Calì et al., 2025, §3, §5.2). Cible d'un YOLOv3-Tiny réduit (une tête, FINN) : 43,9 à 208,7 FPS pour une PL de 50 à 200 MHz, et 2,12 à 2,55 W de carte entière (PS et DDR compris) (Calì et al., 2025, Tables 9 et 14, §4.3.2). Le système réel retombe à environ 30 FPS en streaming caméra, le goulot étant sur le PS (Calì et al., 2025, §4.4). 5

ZC706 (XC7Z045) Carte d'évaluation Xilinx à Zynq-7000 Z7045 : 2 Cortex-A9, 218 600 LUT, 545 BRAM (Umuroglu et al., 2016, §5.1), 900 DSP [constructeur, hors corpus]. Carte du premier FINN (200 MHz) : de 8,1 W (SFC-fix) à 28,5 W (MFC-max) mesurés au mur (carte entière), pour jusqu'à 12,4 M images/s sur MNIST (Umuroglu et al., 2016, Tables 3 et 4). Sert aussi d'hôte de test à l'ASIC Navion (Suleiman et al., 2019, §V-B). Puissance de carte de laboratoire, hors gamme drone. 6

Glossaire des modèles

AlexNet Classifieur de 2012 à 5 convolutions et 3 couches denses. Dans le corpus, backbone de tous les trackers siamois pour drone (SiamAPN++, HiFT, TCTrack), choisi pour la latence : 3,4 ms sur Jetson AGX Xavier contre 13,7 pour MobileNetV2, à cause du coût d'accès mémoire des réseaux mobiles (Cao et al., 2022, §4.1, Table 1)[PP]. 7

Attention / Transformer Mécanisme de pondération de positions par produit de requêtes et de clés, empilé en Transformer [hors corpus]. Apparaît dans le corpus drone sous trois formes : têtes Transformer ou Swin de TPH-YOLOv5, Transformer de suivi (HiFT, TCTrack), attention de canal et spatiale (CBAM dans LCAM-YOLOX). Sur FPGA, elle pose problème : le module C2PSA de YOLO11 doit être approché par des convolutions 1×1 et un hard-sigmoid pour passer sur le DPU (Karki et al., 2026, §III-B)[PP]. 0, 4, 5, 7, 11

BlankSkip Sortie anticipée (*early exit*) pour détecteur : une branche légère (0,078 M de paramètres) accrochée à une couche intermédiaire d'un SSD-MobileNetV2 classe l'image « vide » ou « non vide » et court-circuite le détecteur dans le premier cas ; le seuil est réglable en vol (Marra et al., 2026, §3)[PP]. Sur GAP8 (INT8, DORY) : 54,0 de mAP à 1,86 FPS en moyenne contre 55,5 à 1,50 FPS

pour le modèle statique (+24 %) (Marra et al., 2026, Table 2)[PP]; 2,07 FPS sur vidéo d'exploration (Marra et al., 2026, §4.2.1)[PP]. Puissance non mesurée. 4, 6

ByteTrack Suivi multi-objets par association de détections, y compris celles de faible confiance, en deux passes [hors corpus]. SCOUT l'associe à YOLO26n sur Jetson Orin NX (deux pools, seuil 0,50, confiance minimale 0,06) et ajoute un filtre géométrique de rejet des sauts de détection (Yousuf et al., 2026, §III-B)[PP]. Cité par la revue sur caméras événementielles comme suiveur de référence sur FRED (Magrini et al., 2025, §5)[PP]. 8

CLIP Modèle image-texte entraîné par contraste, dont les embeddings relient une requête textuelle à une image [hors corpus]. Dans SINGER, un champ sémantique CLIP est distillé dans la scène de Gaussian Splatting du simulateur (Adang et al., 2025, §IV-B)[PP]. 9

CLIPSeg Segmentation guidée par texte au-dessus de CLIP ViT-B/16 (86 M de paramètres) : une requête et une image donnent une carte de chaleur. Étage de perception de SINGER sur Jetson Orin Nano : 3 Hz sans optimisation, 12 Hz en ONNX sur CUDA, qui borne la boucle de perception (Adang et al., 2025, §V)[PP]. 7, 9

Darknet À la fois le framework C d'entraînement de YOLO et la famille de backbones Darknet-19 (YOLOv2) et Darknet-53 (YOLOv3, résiduel). Dans le corpus : Darknet-53 est le backbone de YOLOv3 sur Det-Fly (Zheng et al., 2021, §IV), le framework sert aux mesures sur Jetson sans TensorRT de Feng et al. (2022), et Nguyen et al. (2024) convertissent leurs modèles Darknet vers Keras puis Vitis AI. 5

DepthAnythingV2 Modèle de fondation d'estimation de profondeur monoculaire à backbone ViT [hors corpus]. NOVA utilise la variante ViT-S, alignée sur la disparité stéréo par un polynôme d'ordre 2 pour compléter la profondeur : 31,6 ms par image sur Jetson Orin NX (Saviolo and Loianno, 2025, §IV-C)[PP]. 7

DETR *DEtection TRansformer* : backbone CNN suivi d'un encodeur-décodeur transformer qui produit un ensemble fixe de boîtes à partir de requêtes apprises ; l'appariement hongrois supprime ancres et NMS [hors corpus]. Dans le corpus, évalué sur GPU : 97,1 d'AP50 sur MAV-VID à 21,4 FPS (Isaac-Medina et al., 2021, Table 1)[PP]. RT-DETR (sa version temps réel) sert de comparaison à GL-YOMO sur Drone-vs-Bird (AP 0,773) (Liu et al., 2024, Table II)[PP]. 8

DreamerV3 Apprentissage par renforcement avec modèle du monde : un RSSM prédit dynamique, récompense et continuation à partir d'images, et l'acteur-critique s'entraîne sur des trajectoires imaginées. Dream-to-Fly l'applique à la course de drones à partir de pixels 64×64 : seul DreamerV3 converge, en 20 M d'interactions et environ 240 h d'entraînement, là où PPO et SAC échouent (Romero et al., 2025, §IV-A)[PP]. Validé en hardware-in-the-loop (calcul déporté), sans mesure embarquée. 7

DroNet CNN résiduel léger à deux sorties (angle de braquage en régression, probabilité de collision en classification), entraîné sur des images de voiture et de vélo pour la navigation d'un drone sans carte [hors corpus]. Environ 41 MMAC par image (Palossi et al., 2018, §III-A)[PP]. C'est le réseau de navigation de référence des nano-drones du corpus (PULP-Dronet, Tiny-PULP-Dronet, roofline de Krishnan et al.). 6

PULP-Dronet DroNet porté sur le SoC GAP8 : Fixed16 Q4.12 avec réentraînement QAT, max-pooling 2×2, fine-tuning sur images de la caméra embarquée, tiling par AutoTiler sur 8 cœurs (Palossi et al., 2018, §IV)[PP]. 89,1 % de précision de collision ; 6 FPS pour 64 mW ou 18 FPS pour 284 mW (Palossi et al., 2018, §VI, Table II)[PP]. Gamme nano (mW). 6, 9

Tiny-PULP-Dronet PULP-Dronet réduit : canaux multipliés par $\gamma = 0{,}125$ et branches by-pass supprimées, car le réseau est creux (jusqu'à 92 % de neurones inactifs) et sur-apprend (Lamberti et al., 2024, §II)[PP]. 6,4 kB et 1,5 MMAC contre 320 kB et 41 MMAC ; 88 % de précision, 89 FPS pour 34 mW sur GAP8, contre 10 FPS à fréquence égale (Lamberti et al., 2024, §III)[PP]. 6

Faster R-CNN Détecteur en deux étapes : un réseau de propositions (RPN) génère des régions, puis une tête les classe et affine les boîtes [hors corpus]. Plus précis mais plus lent que les détecteurs en une étape : 18,0 FPS contre 32,4 pour SSD512 sur MAV-VID (Isaac-Medina et al., 2021, Table 1)[PP], 70,5 d'AP sur Det-Fly (Zheng et al., 2021, Table II). Base de ClusDet.

ClusDet Faster R-CNN + FPN précédé d'un réseau de propositions de *groupes* d'objets (CPNet), d'une régression d'échelle (ScaleNet) et d'une fusion itérative (Yang et al., 2019, §3)[PP] : les groupes sont recadrés puis détectés à échelle normalisée. VisDrone val : 26,7 d'AP (ResNet-50, 273 ms sur GTX 1080 Ti) à 28,4 (ResNeXt-101, 773 ms) (Yang et al., 2019, Table 1)[PP]. Typique des méthodes de précision hors temps réel. 4

PULP-Frontnet CNN sans connexions résiduelles qui estime la pose d'une personne devant un nano-drone pour l'interaction humain-drone, quantifié en INT8 (NEMO) et déployé par DORY sur GAP8 (Palossi et al., 2021, §IV)[PP]. Trois variantes : la 80×32 tient 18,5 FPS pour 8,6 mW (puissance minimale) ou 134,7 FPS pour 86,6 mW (Palossi et al., 2021, §V-B)[PP]. 6

GhostConv Convolution « fantôme » (GhostNet) : une convolution réduite produit une partie des canaux, le reste étant généré par des opérations linéaires peu coûteuses [hors corpus]. Réduit paramètres et FLOPs : backbone de GCL-YOLO, tête de YOLO-Drone, C3Ghost de GL-YOMO. Seule, elle fait pourtant chuter le mAP50 de GCL-YOLO de 32,7 à 28,8 (Cao et al., 2023, §4.5), et elle est moins efficace sur DPU *(déduit)*. 4

Filtre de Kalman Estimateur récursif d'état à partir de mesures bruitées, qui alterne prédiction (modèle de mouvement) et mise à jour [hors corpus]. Omniprésent dans le corpus comme brique de suivi : prédiction de la fenêtre locale de GLAD (Guo et al., 2023, §III)[PP], validation des correspondances de GL-YOMO, correction de la dérive de la VIO dans Swift (Kaufmann et al., 2023, Methods). 8

UKF Filtre de Kalman *unscented* : propage des points sigma au travers du modèle non linéaire, sans le linéariser [hors corpus]. NOVA en fait tourner un à 200 Hz pour fusionner IMU et détections asynchrones (Saviolo and Loianno, 2025, §III-B3)[PP] ; NGPS, un UKF à 15 états fusionnant GPS visuel, VIO et IMU (Sharma, 2026, §III-E)[PP]. 7

LightGlue Réseau d'appariement de points d'intérêt à attention, qui peut s'arrêter tôt sur les paires faciles [hors corpus]. Dans NGPS (RANSAC sur homographie, au moins 20 correspondances), il représente 82 % du temps GPU : le module tourne à 2,6 Hz sous CUDA et 0,5 Hz sur CPU, sur Jetson Orin NX (Sharma, 2026, §IV-D)[PP]. Le positionnement visuel atteint 2,94 m de RMSE contre 10,37 m pour la VIO seule (Sharma, 2026, §IV-E4)[PP]. 7, 11

LiteVLA-H Modèle vision-langage-action de 256 M de paramètres, à deux modes (action en 1 à 2 tokens, sémantique en phrase) et ordonnanceur à deux cadences où l'action passe en priorité (williams et al., 2026, §3)[PP]. Sur Jetson AGX Orin en FP16 : 50,65 ms (19,74 Hz) pour l'action, 149,90 ms (6,67 Hz) pour une phrase (williams et al., 2026, §6.1)[PP], la latence étant dominée par le pre-fill multimodal. Surcoût du double régime : 3,6 W. 9

MobileNet Famille de backbones légers fondés sur la convolution séparable en profondeur (depthwise puis pointwise 1×1) ; V2 ajoute les blocs résiduels inversés à goulot linéaire [hors corpus]. Présents dans le corpus de la détection embarquée (SSD) à la navigation (Loquercio).

MobileNetV2 Blocs résiduels inversés à goulot linéaire. Dans le corpus : classifieur 32×32 drone / oiseau / fond après soustraction de fond (Seidaliyeva et al., 2020, §3.4), backbone des SSD sur GAP8 (Lamberti et al., BlankSkip), de RetinaNet allégé dans QueryDet (28,94 d'AP) (Yang et al., 2021, Table 7)[PP]et baseline de la détection de feu à 13 FPS et 68,23 % (Elhence et al., 2025, §V-A1). 7, 8

NanoFlowNet Réseau de flux optique dense dérivé de STDC-Seg (convolutions séparables, filtres divisés par 4), guidé à l'entraînement par les frontières de mouvement, pour l'évitement d'obstacles d'un nano-drone (Bouwmeester et al., 2022, §III)[PP]. 5,57 FPS en niveaux de gris 112×160 sur GAP8 (INT8 PTQ) ; 141 FPS et 7,122 px d'erreur de bout sur MPI Sintel sur GTX 1070 (Bouwmeester et al., 2022, Table IV)[PP]. 6

NeRF *Neural Radiance Field* : un MLP encode une scène 3D comme densité et couleur en tout point, rendue par intégration le long des rayons [hors corpus]. Hors temps réel : dans le corpus, seulement porté à l'échelle d'un nano-drone par Tiny-DroNeRF. 6, 11

Instant-NGP NeRF accéléré par une table de hachage multi-résolution et de petits MLP, avec une grille d'occupation [hors corpus]. Version de départ de Tiny-DroNeRF : 527 MB, 17,52 GOp par pas, 32,59 dB de PSNR (Carboni et al., 2026, Table II)[PP]. 6

Tiny-DroNeRF Instant-NGP réduit (1 image par pas, 160×160, table de hachage 2^{13}) et écrit

en C pour le cluster du SoC GAP9 d'un nano-drone, en float16 (Carboni et al., 2026, §IV)[PP]. 0,284 MB de paramètres, 26,94 dB de PSNR (5,7 dB de moins), 73 ms par pas d'entraînement amorti, 4,1 s par rendu de 160×160, mesurés au simulateur cycle-accurate GVSOC et non sur la puce (Carboni et al., 2026, §V-C)[PP]; 21,2 dB avec des images de vol réel (Carboni et al., 2026, §V-D)[PP]. 6

NMS *Non-Maximum Suppression* : suppression des boîtes redondantes d'un détecteur par seuil d'IoU [hors corpus]. Dans le corpus c'est souvent le goulot : sur ARM, Nguyen et al. le mesurent à environ 3,9 ms par image (Nguyen et al., 2024, Table 12), et Karki et al. (2026)[PP]concluent que le post-traitement sur l'ARM, non le DPU, limite le débit de bout en bout (Karki et al., 2026, §IV-C)[PP]. YOLO26 est annoncé sans NMS, mais celui-ci est conservé pour l'évaluation (Karki et al., 2026, §III-B3)[PP]; Soft-NMS dans LCAM-YOLOX. 5, 11, 12

ResNet Famille de réseaux à connexions résiduelles (ResNet-18, -50, -101…). Backbone par défaut des détecteurs de précision du corpus (ClusDet, QueryDet, UFPMP-Det, SSD512, Faster R-CNN, Dogfight) ; ResNet-18 allégé dans YOPOv2-Tracker (Lu et al., 2025, §III-C)[PP]; le DroNet de Loquercio et Palossi en est un dérivé peu profond à connexions résiduelles (Palossi et al., 2018, §III-A)[PP]. Tiny-PULP-Dronet en retire les by-pass (Lamberti et al., 2024, §II)[PP]. 7, 8

RetinaNet Détecteur en une étape à ancres sur pyramide de caractéristiques, entraîné avec la *focal loss* [hors corpus]. Dans le corpus : 77,9 d'AP sur Det-Fly avec ResNet-50 (Zheng et al., 2021, Table II), 78,21 % de mAP en baseline de la détection de feu (Elhence et al., 2025, §V-A1), et base de QueryDet.

QueryDet RetinaNet à tête P2 dont les niveaux fins ne sont évalués qu'aux positions proposées par une carte de présence de petits objets (*Cascade Sparse Query*, convolution éparse) (Yang et al., 2021, §3.2)[PP]. Sur VisDrone : 28,32 d'AP à 2,75 FPS avec CSQ contre 28,35 à 1,16 FPS sans (Yang et al., 2021, Table 2)[PP]. Il réduit le coût de la tête P2, au prix d'une convolution éparse peu adaptée au FPGA *(déduit)*. 4

SAHI *Slicing Aided Hyper Inference* : cadre indépendant du détecteur, qui découpe l'image en tuiles recouvrantes, détecte sur chacune puis fusionne par NMS (Akyon et al., 2022, §3)[PP]. Applicable sans réentraînement ; avec fine-tuning sur tuiles, FCOS atteint 38,5 d'AP50 sur VisDrone (Akyon et al., 2022, Table 1)[PP]. Multiplie le nombre d'inférences par image, ce qui l'éloigne du temps réel embarqué *(déduit)*. 4, 11

SINGER Politique de navigation vers un but sémantique donné par texte, entièrement embarquée, entraînée par imitation d'un expert (RRT* + MPC) dans un simulateur photoréaliste (Adang et al., 2025, §IV)[PP]. En vol réel (30 essais, bureau factice) : but atteint à moins de 1 m dans 76,67 % des cas avec le nord fourni, 66,67 % avec capteurs embarqués seuls, contre 53,33 % pour une baseline CLIPSeg + PD (Adang et al., 2025, §VI-D)[PP]. 7, 9

SkyNet Réseau de détection mono-objet conçu de bas en haut pour DAC-SDC : un « Bundle » (convolutions depthwise 3×3 et pointwise 1×1, BN, ReLU6) empilé 6 fois, choisi par recherche sous contrainte de latence GPU et FPGA, avec bypass et tête YOLO à deux ancres (Zhang et al., 2019b, §4–5)[PP]. Vainqueur de DAC-SDC'19 : IoU 0,716, 25,05 FPS et 7,26 W sur Ultra96, 67,33 FPS et 13,5 W sur TX2 (Zhang et al., 2019b, Tables 5–6)[PP]. Sert aussi de backbone à SiamRPN++ et SiamMask. Repris par plusieurs équipes DAC-SDC 2020–2021, dont une version en streaming à 299,3 FPS (Zhang et al., 2024, Table 5). 5, 10

SmolVLM-256M Modèle vision-langage compact : encodeur SigLIP, projection par *pixel shuffle* et décodeur SmolLM2-135M (Azimi et al., 2026, §II)[PP]. Profilé par Azimi et al. (2026)[PP]sur un Jetson et un GPU cloud : 2,76 s tout embarqué, 0,72 s tout cloud, 2,09 s avec coupure après la projection (moins 24 % face à l'embarqué), pour 15 J à bord contre 26 J (Azimi et al., 2026, §V-A1, Fig. 6 et 9)[PP]. 9

SSD *Single Shot MultiBox Detector* : détecteur en une étape à ancres (*default boxes*) sur plusieurs cartes de résolutions décroissantes, suivi d'un NMS. Dans le corpus : TGIIF, un SSD élagué en 8 bits, gagne le volet FPGA de DAC-SDC'18 (IoU 0,62 à 11,96 FPS sur XC7Z020) (Xu et al., 2021, §5.2.1) ; SSD512 est évalué sur MAV-VID (96,7 d'AP50 à 32,4 FPS) (Isaac-Medina et al., 2021, Table 1)[PP]et sur Det-Fly (78,7 d'AP en 84 ms avec ResNet-50, 68,8 en 53 ms avec MobileNetV2)

(Zheng et al., 2021, Table II, §V-B). 5

SSD-MobileNetV2 SSD à backbone MobileNetV2, décliné en trois largeurs (1,0×, 0,75×, 0,5×). Sur nano-drone (AI-deck GAP8, 160 MHz, INT8), la version 1,0× tient 1,6 FPS pour 134,5 mW à la carte (Lamberti et al., 2023, Table II)[PP]; BlankSkip la mesure à 1,50 FPS pour 55,5 de mAP (version 0,5× : 3,50 FPS, 41,5) (Marra et al., 2026, Table 2)[PP]. Détecteurs multi-objets du corpus sur GAP8. 6, 10, 12

SuperPoint Détecteur-descripteur de points d'intérêt appris (descripteurs de 256 dimensions) [hors corpus]. Dans NGPS, il extrait les points de l'image du drone et de la tuile satellite avant l'appariement par LightGlue (Sharma, 2026, §III-C)[PP]. 7

Tête P2 Tête de détection supplémentaire sur la carte de stride 4 (160×160 à 640 px), dédiée aux objets minuscules. Recette récurrente des YOLO drone : TPH-YOLOv5, Drone-YOLO, Efficient YOLOv7-Drone, GCL-YOLO, DEAL-YOLO, QueryDet, DroneScan-YOLO. Gain important (43,7 vers 50,5 de mAP50 pour Drone-YOLO) mais coût élevé en activations : 13,68 vers 10,89 FPS pour TPH-YOLOv5 (Zhao et al., 2023, Table 5) et latence TX2 multipliée par 4,1 pour Drone-YOLO nano (Zhang, 2023, Table 6). Absente des YOLO portés sur FPGA du corpus ; SF-YOLOv5, lui, retire P5 sans ajouter P2. 0, 4, 5, 8, 11, 12

Tracker siamois Suivi d'objet unique par réseau jumeau : le gabarit (127×127) et la zone de recherche (287×287) passent par le même backbone, et une corrélation entre cartes donne la position de la cible [hors corpus]. Famille dominante du suivi aérien du corpus, avec un backbone AlexNet pour tenir sur Jetson (SiamAPN++, HiFT, TCTrack) ; SiamRPN++ et SiamMask à backbone SkyNet sont évalués sur GOT-10k (36,4 et 39,0 d'AO) (Zhang et al., 2019b, Tables 8–9)[PP]. 7

SiamAPN++ Tracker siamois à réseau de propositions d'ancres adaptatives à double caractéristique (APN-DF) et agrégation attentionnelle (AAN) (Cao et al., 2021a, §III)[PP]. 56,0 d'AUC de succès sur UAV20L (Cao et al., 2021a, Fig. 4a)[PP]; 34,9 FPS sur Jetson AGX Xavier en vol réel (Cao et al., 2021a, §V)[PP]. 7, 11

HiFT *Hierarchical Feature Transformer* : l'encodeur fusionne les cartes de corrélation de haute résolution (couches 3 et 4) par attention multi-têtes, le décodeur prend celle de la couche 5 à la place des requêtes d'objets (Cao et al., 2021b, §3.2)[PP], tête sans ancres. 78,7 de précision à 20 px sur UAV123 (Cao et al., 2021b, Table 1)[PP]; 31,2 FPS sur Jetson AGX Xavier en test réel (Cao et al., 2021b, §5)[PP]. 7, 11

TCTrack Tracker siamois qui injecte le contexte temporel : convolutions dont les poids sont recalibrés par les descripteurs des images passées (TAdaConv) et Transformer à mémoire constante (AT-Trans) (Cao et al., 2022, §3)[PP]. 58,2 d'AUC de succès sur UAVTrack112_L à 125,6 FPS sur PC (GPU n/r), 27 FPS sur Jetson AGX Xavier en test réel (Cao et al., 2022, §1, §5)[PP]. 7

UFPMP-Det Détecteur de petits objets en deux temps : un détecteur grossier propose des régions, qui sont fusionnées et assemblées en une seule mosaïque (*Unified Foreground Packing*), détectée en une passe par un réseau à tête multi-proxy (MP-Det) (Huang et al., 2021, §3)[PP]. VisDrone val : 36,6 d'AP (ResNet-50) à 39,2 (ResNeXt-101), 152 ms sur GTX 1080 Ti pour la configuration de la Table 3 (Huang et al., 2021, Tables 1 et 3)[PP]. 4, 11

UltraNet Réseau de détection mono-objet de huit couches de convolution, quantifié en W4/A4, qui domine DAC-SDC à partir de 2020 avec SkyNet. Les équipes 2021–2022 le portent en architecture streaming avec *DSP packing* : la version SEUer 2022 atteint 70,3 d'IoU, 2 020,6 FPS et 1,41 W sur ZU3EG (Zhang et al., 2024, Table 6). IoU mono-objet, non comparable au mAP multi-classe de VisDrone. 5

YOLO *You Only Look Once* : famille de détecteurs en une étape, qui prédisent en une seule passe, sur une grille, des boîtes, un score d'objet et des scores de classe, puis filtrent les doublons par NMS. Depuis YOLOv3, l'architecture se découpe en backbone, neck (fusion multi-échelle) et tête de détection. C'est le détecteur dominant du corpus drone : du Tiny YOLO quantifié sur Zynq (Tincy YOLO) aux YOLOv5 à YOLO26 sur Jetson, FPGA ou GPU de bureau, et la base de presque toutes les variantes « petits objets » (têtes P2, Transformers, convolutions Ghost). 0, 4–6, 8–11

YOLOv3 Troisième version : backbone Darknet-53 (blocs résiduels), prédiction à trois échelles par un neck de type FPN, trois ancres par échelle, classes en sigmoïdes indépendantes. Face à

YOLOv2 : multi-échelle et backbone plus profond, donc meilleurs petits objets. Dans le corpus : référence de détection de drone sur GPU, avec 72,3 d'AP sur Det-Fly pour 32 ms sur RTX 2080 Ti (Zheng et al., 2021, Table II) et 97,7 d'AP50 sur Anti-UAV à 36 FPS (plateforme n/r) (Isaac-Medina et al., 2021, Table 1)[PP]; mesuré sur Jetson Nano, Jetson Xavier NX et Raspberry Pi avec NCS2 par Feng et al. (2022) : 1,7 FPS sur Nano à 416, 6,1 sur Xavier NX (Feng et al., 2022, Table 3). 4, 5, 8

YOLOv3-tiny Version réduite de YOLOv3 : suite de convolutions 3×3 et de max-pooling, deux échelles de sortie au lieu de trois. Sur Jetson Xavier NX elle atteint 41,1 FPS à 416 pour 13,5 W, contre 6,8 FPS sur Nano (Feng et al., 2022, Table 3). Sur FPGA, Calì et al. (2025) la réduisent encore (une seule tête 13×13, filtres divisés par 5, W4/A4 par FINN) : 17,68 de mAP@0,5 sur la seule classe « car » de VisDrone-DET, 164,79 FPS et 2,55 W de carte à 200 MHz sur XC7Z020 (Calì et al., 2025, Tables 9 et 14). SATAY la porte en W8A16 sur Virtex UltraScale (Montgomerie-Corcoran et al., 2023, Table III). 0, 4, 5, 10

SlimYOLOv3 YOLOv3-SPP3 élagué par *network slimming* : régularisation L1 sur les facteurs d'échelle des BatchNorm puis suppression des canaux sous un seuil global et un seuil local. À 832×832, la variante -SPP3-90 retire 85,9 % des FLOPs et 87,5 % des paramètres pour 42,6 % de temps d'inférence en moins sur GTX 1080 Ti seulement (Zhang et al., 2019a, §5)[PP]: l'élagage de canaux ne suit pas les FLOPs en latence. Son principe est repris par Liu et al. (2021) pour YOLOv4. 4

YOLOv4 Quatrième version : backbone CSPDarknet53, module SPP et neck PANet, tête de YOLOv3 à ancres, activation Mish, augmentations Mosaic. Dans le corpus, deux usages. Détection de petits drones : Liu et al. (2021) l'élaguent (canaux, couches, *shortcut*) : 90,5 de mAP@0,5 à 69 FPS contre 93,6 à 43 FPS pour le modèle complet, sur Tesla P100 (Liu et al., 2021, Table 4). Portage FPGA : Nguyen et al. (2024) l'adaptent au DPU (Mish vers LeakyReLU, SPP 5/6/8) et l'élaguent à 0,6 sur ZCU104 : 82,41 de mAP@0,25 à 29,0 FPS contre 83,70 à 17,9 FPS, et 27,9 contre 30,1 W à la prise (Nguyen et al., 2024, Tables 11 et 13). 0, 5, 8

YOLOv4-tiny Version réduite de YOLOv4 (backbone CSPDarknet53-tiny, deux têtes). Nguyen et al. y ajoutent une troisième tête pour les petits objets (variante « 3L ») : 72,24 de mAP@0,25 à 125 FPS sur ZCU104 (DPU, 4 threads), contre 83,70 à 17,9 FPS pour YOLOv4 complet (Nguyen et al., 2024, Table 11). Sur Jetson Nano à 416, Feng et al. (2022) mesurent 15,0 FPS contre 1,6 pour YOLOv4 (Feng et al., 2022, Table 6). 5

YOLOv5 Version d'Ultralytics, sans article : réimplémentation PyTorch à ancres, backbone CSP, neck PANet, activation SiLU, tailles n à x par multiplicateurs de profondeur et de largeur [hors corpus]. C'est la base la plus utilisée des YOLO drone du corpus : TPH-YOLOv5, SF-YOLOv5, GCL-YOLO, GLAD, GL-YOMO. Jung and Choi (2022) y remplacent SiLU par ELU (« ConvELU ») : 95,5 contre 94,6 de mAP@0,5 sur un jeu propre (Jung and Choi, 2022, Tables 2–3). Zheng et al. (2023) l'emploient pour exclure les objets courants (RTX 3070). 4

YOLOv5n Taille *nano*. SATAY la déploie sur ZCU104 en 640×640 : 26,7 de mAP50 COCO, 21,41 ms et 14,5 W (méthode de mesure n/r), contre 32,28 ms et 8,58 W pour le Jetson TX2 (Montgomerie-Corcoran et al., 2023, Table IV). 5, 10

YOLOv5s Taille *small*. SATAY la couvre sur Virtex UltraScale en W8A16 (VCU110 : 46,4 ms, 24,8 W) (Montgomerie-Corcoran et al., 2023, Table III). Elle sert de détecteur de base à GLAD et à la variante ConvELU de Jung et al. 4, 8

GCL-YOLO YOLOv5 allégé pour petits objets : backbone à convolutions Ghost (modules ELAG3, GSPPF), neck avec tête P2 et suppression de la tête P5, perte Focal-EIOU (Cao et al., 2023, §3). Quatre tailles N/S/M/L ; la version S fait 1,64 M paramètres, 39,6 de mAP50 sur VisDrone à 53 FPS (GPU de mesure n/r), contre 32,7 pour YOLOv5-S (Cao et al., 2023, Table 3). Aucune mesure sur plateforme drone. 4

GL-YOMO Suite de GLAD : YOLOv5 à quatre têtes P3–P6 (la tête ajoutée est P6, pas P2), C3Ghost, modules d'ASF-YOLO, plus détecteur de mouvement (Lucas-Kanade, template matching) et validation par filtre de Kalman, en pipeline global puis local (Liu et al., 2024, §III)[PP]. Sur Drone-vs-Bird : 76,3 d'AP (IoU 0,1) (Liu et al., 2024, Table II)[PP], soit moins que

RT-DETR (0,773) ; 21,6 FPS sur Jetson Xavier NX (Liu et al., 2024, §IV-E)[PP]. 8, 11

SF-YOLOv5 *Small-Fast* : YOLOv5s sans la couche C5 ni la sortie P5, avec un neck PB-FPN (chemin supplémentaire haut vers bas) et un SPPF devant chaque tête (Liu et al., 2022, §3). À l'inverse des variantes à tête P2, l'allègement vient du retrait de la tête des grands objets : 2,24 M paramètres, 13,8 GFLOPs, 34,3 de mAP@0,5 sur VisDrone, 11,5 ms sur RTX 2060 (Liu et al., 2022, Table 4). Aucun test embarqué. 4

TPH-YOLOv5 *Transformer Prediction Head* : YOLOv5x à quatre têtes (ajout d'une tête P2 « tiny »), blocs Transformer (puis Swin) dans les têtes, module CBAM, multi-scale testing fusionné par WBF et ensemble de modèles. Au challenge VisDrone 2021, un ensemble atteint 39,18 d'AP (Zhu et al., 2021, §4.2)[PP], mais le modèle seul fait 7,36 FPS (34,0 d'AP, VisDrone test-dev) sur RTX 3090 Ti (Zhao et al., 2023, Table 5). Référence de précision « YOLO drone SOTA », jamais portée sur un accélérateur dans le corpus. 4, 8

YOLOv7 Septième version : blocs ELAN, re-paramétrisation (RepConv), têtes auxiliaires à étiquetage guidé [hors corpus]. Base de deux variantes drone du corpus. Dans l'étude de Liu et al. (2022), YOLOv7 atteint 76,1 de mAP@0,5 en 18,0 ms sur RTX 2060 (jeu WIDER FACE) (Liu et al., 2022, Table 3). YOLOv7-tiny est le détecteur de Bo et al. cité par la revue d'Dong et al. (2025)[PP]. 4

Efficient YOLOv7-Drone YOLOv7 avec tête P2 ajoutée, tête P5 et stage 5 supprimés (moins 56,29 % de paramètres), convolution creuse à masque (TGM-CESC) et fusion descendante P2–P3–P4 (Fu et al., 2023, §3.2–3.4). À 640×640 sur VisDrone : 32,1 de mAP@0,5:0,95 à 89,29 FPS (RTX 3090) contre 28,6 à 212,76 FPS pour YOLOv7 (Fu et al., 2023, Table 5) ; 39,9 à 1280 (Fu et al., 2023, Table 3). « Efficient » vaut face aux méthodes coarse-to-fine, pas face à YOLOv7. 4

F-YOLOv7 YOLOv7 dont les blocs ELAN sont remplacés par un module *Faster* (convolution partielle de FasterNet) et dont la perte CIoU devient FIoU (sigmoïde au lieu de l'arctan) (Du et al., 2025, §4). Sur DUT Anti-UAV : 92,80 d'AP@0,5 à 169 FPS (RTX 4090) ; avec soustraction de fond en prétraitement (Pre-F-YOLOv7, caméra supposée fixe) 98,80 à 159 FPS (Du et al., 2025, Table 2). GPU de bureau seulement. 4, 8

YOLOv8 Version d'Ultralytics : tête découplée et *sans ancres*, blocs C2f (avec opération *split*), SiLU, régression par Distribution Focal Loss, tailles n à x [hors corpus]. Base des variantes drone Drone-YOLO, DEAL-YOLO, YOLO-GCOF et DroneScan-YOLO, et détecteur le plus comparé sur plateformes embarquées : Jetson Orin et Raspberry Pi 5 chez Rey et al. (2025) et Alqahtani et al. (2024)[PP], DPU de ZCU104 chez Karki et al., SATAY sur Virtex.

YOLOv8n Taille *nano*. Sur Jetson Orin NX (jeu propre de drones Tello), TensorRT INT8 donne 65,83 FPS à 71,9 de mAP50-95 contre 58,82 FPS à 84,4 en FP16, pour 10,3 à 10,9 W (Rey et al., 2025, Table 4) : la PTQ INT8 coûte 12,5 points. Sur le DPU de ZCU104, la variante « DPU-aware » (SiLU vers ReLU, split vers convolutions 1×1) perd 30 points sur KITTI après INT8 (0,64 vers 0,34 de mAP50-95) (Karki et al., 2026, Table II)[PP]. 4, 5, 7, 10–12

YOLOv8s Taille *small*. Orin NX : 56,32 FPS en INT8 contre 48,24 en FP16, 11,0 à 12,8 W (Rey et al., 2025, Table 4) ; Raspberry Pi 5 (NCNN FP32) : 7,32 FPS. SATAY la déploie sur Virtex UltraScale (VCU110 : 122,8 ms) (Montgomerie-Corcoran et al., 2023, Table III). Base de DroneScan-YOLO. 10

Drone-YOLO Famille de cinq modèles (nano à large) dérivés de YOLOv8 : tête P2 (PAFPN à quatre niveaux), fusion « sandwich » et sous-échantillonnage RepVGG (Zhang, 2023, §3). La tête P2 apporte l'essentiel du gain (mAP50 de 43,7 à 50,5 sur VisDrone val) mais coûte cher : sur Jetson TX2, la version nano met 127,4 ms contre 30,8 ms pour YOLOv8n à nombre de paramètres égal (Zhang, 2023, Tables 6–7). Large : 40,7 de mAP50 sur VisDrone test (Zhang, 2023, Table 4). 4, 11, 12

YOLO11 Version d'Ultralytics qui succède à YOLOv8 : blocs C3k2 et module d'attention C2PSA dans le backbone, tête sans ancres [hors corpus]. L'attention et SiLU ne passent pas sur la DPU : Karki et al. approchent C2PSA par des convolutions 1×1 et un hard-sigmoid (Karki et al., 2026, §III-B)[PP]. 5

YOLOv11n Taille *nano*. La variante DPU-aware perd peu après INT8 sur ZCU104 : 0,59 vers 0,57 de mAP50-95 sur VOC, 0,60 vers 0,59 sur KITTI (Karki et al., 2026, Table II)[PP], nettement mieux que YOLOv8n. Base de YOLO-Drone. 4

YOLOv11-small Taille *small*. NOVA l'entraîne sur COCO avec un zoom adaptatif autour de la boîte précédente (entrée 320×256) : 92 Hz sous TensorRT FP16 sur Jetson Orin NX (Saviolo and Loianno, 2025, §IV-B)[PP], détecteur du suivi de cible en vol. 7

YOLO26n Taille *nano* de YOLO26 (écrit aussi YOLOv26n), présentée comme détecteur de bout en bout sans NMS ni DFL (Karki et al., 2026, §III-B3)[PP]. Deux usages dans le corpus. Sur le drone intercepteur SCOUT, affiné sur 3 931 images du drone cible puis couplé à ByteTrack : TensorRT FP16 sur Jetson Orin NX, 48 FPS (20,8 ms) contre 22,5 FPS sous PyTorch (Yousuf et al., 2026, Table IV)[PP], 31,82 FPS en vol avec 92,2 % de détections valides (Yousuf et al., 2026, Table III)[PP]. Sur ZCU104, Karki et al. la compilent pour le DPU : 34,05 FPS de bout en bout, le NMS étant conservé (Karki et al., 2026, §IV-C)[PP]. 5, 8, 11

YOLOX Variante sans ancres, à tête découplée et affectation dynamique des positifs (SimOTA) [hors corpus]. Dans le corpus, base de LCAM-YOLOX (détection de feux de forêt). 0, 5, 12

LCAM-YOLOX YOLOX (neck FPN+PAN, trois têtes, 640×640) avec attention de canal et spatiale par couche (LCAM, type CBAM) et Soft-NMS, pour la détection de feux de forêt par drone (Elhence et al., 2025, §III). Élagué à 30 % puis PTQ INT8 pour le DPU : sur Kria KV260, 195 FPS et 9,72 W (carte) à 78,11 de mAP, 387 FPS à 2 cœurs ; Jetson Nano 65 FPS, STM32H7A3 15 FPS (précisions n/r) (Elhence et al., 2025, §V-A, §V-D). Tableaux absents de l'extraction : chiffres lus dans le texte. 5, 10

Tincy YOLO Tiny YOLO modifié par FINN-R : poids binaires et activations 3 bits (W1A3) sauf première et dernière couches (8 bits). 50,1 de mAP sur PASCAL VOC contre 57,1 pour le modèle de départ (Blott et al., 2018, §5.1). Premier YOLO quantifié sur SoC Zynq du corpus, rapporté en GOp/s : 133 sur PYNQ-Z1 (2,5 W) et 288 sur Ultra96 (9,7 W), sans FPS ni latence (Blott et al., 2018, Table 5). 5

TinyissimoYOLO Détecteur pour microcontrôleur inspiré de YOLOv1 : entrée 88×88, convolutions 3×3 uniquement, grille de sortie 4×4, INT8 par QAT, dimensionné pour les 442 kB de poids du MAX78000. 58,5 de mAP sur un VOC réduit à 3 classes ; sur MAX78000, 5,5 ms et 196 µJ par inférence (MCU seul), contre 359 ms sur STM32H7A3 (Moosmann et al., 2023, §III, Table II). Seul détecteur de type YOLO sur MCU du corpus. 6, 10

YOPOv2-Tracker Réseau unique de planification de trajectoire pour le suivi agile : entrée RGB-D 160×96, backbone ResNet-18 modifié, sortie de primitives de mouvement qui jouent le rôle d'ancres, entraîné par rétropropagation du coût de trajectoire sans démonstrations (Lu et al., 2025, §III)[PP]. Latence perception-action de 8,2 ms sur Jetson Orin NX en vol réel (3 ms sur PC) (Lu et al., 2025, §IV-B)[PP], suivi jusqu'à 6 m/s. 7

Glossaire des métriques et unités

AP Average Precision : aire sous la courbe précision-rappel d'une classe, les détections étant jugées justes au-delà d'un seuil d'IoU ; de 0 à 1 (ou en %), plus haut = mieux. L'interpolation de la courbe varie selon le protocole (11 points pour VOC, 101 pour COCO) [hors corpus] ; ARD-MAV la donne à 11 points (Guo et al., 2023, Table IV)[PP]. Piège : dans la notation COCO, « AP » désigne la moyenne sur les seuils d'IoU 0,50 à 0,95 [hors corpus], c'est-à-dire la mAP50-95 (ClusDet, 26,7 à 28,4 sur VisDrone val (Yang et al., 2019, Table 1)[PP]). D'autres articles notent « AP » sans seuil, ce qui interdit la comparaison : Dogfight donne 89 sur NPS-Drones et 72 sur FL-Drones, jeux ré-annotés par les auteurs (Ashraf et al., 2021, Tables 1–2)[PP]. Sur Det-Fly, l'AP va de 82,4 (Grid R-CNN) à 68,8 (SSD512 MobileNetV2), sur GPU de bureau (Zheng et al., 2021, §V). 2–4, 8, 11, 12

AP50 AP au seuil d'IoU 0,5 (AP@0.5), parfois étiquetée « mAP » dans la notation du jeu. Elle dépend fortement du jeu : le même Faster R-CNN ResNet-50 obtient 97,8 sur MAV-VID et 63,2 sur Drone-vs-Bird (Isaac-Medina et al., 2021, Table 1)[PP]. Sur VisDrone, le réglage fin sur tuiles (SAHI) amène TOOD à 43,5 d'AP50 en test-dev (Akyon et al., 2022, Table 1)[PP], valeur qui ne se

compare pas à l'AP COCO 0,5:0,95 du même jeu. 3, 4, 8

AP$_S$ AP restreinte aux petits objets (surface inférieure à 32^2 pixels dans le protocole COCO [hors corpus]) ; noté aussi mAP$_s$ ou mAP_small. C'est la métrique qui correspond au sujet drone, et elle est presque toujours absente : QueryDet ne rapporte que le rappel sur VisDrone (Yang et al., 2021, Table 2)[PP], Drone-YOLO n'en donne pas (Zhang, 2023, Tables 4–5), pas plus que le YOLOv4 sur ZCU104 de Nguyen et al. (Nguyen et al., 2024, Table 11). Un des rares cas : YOLOv7-Drone passe de 19,4 à 20,3 (tête P2) puis 22,0 (Fu et al., 2023, Tables 9 et 12), sur VisDrone val, entrée 640. Aucun article du corpus ne la mesure après quantification *(déduit)*. 0, 3–5, 8, 11, 12

ATE / erreur de trajectoire Absolute Trajectory Error : écart entre la trajectoire estimée et la trajectoire de référence, en mètres (RMS), ou normalisé par la longueur parcourue, en %. Plus bas = mieux. Navion donne une erreur normalisée de 0,28 % sur EuRoC, contre 0,22 % en logiciel (Suleiman et al., 2019, §V-A). NGPS annonce 1,7 à 6,0 m d'ATE entre 40 et 150 m contre 6,74 à 55,81 m pour un VIO monoculaire, avec un pire cas de 6,04 m à 150 m (Sharma, 2026, §IV-C et §IV-E2)[PP]. Une erreur en % et une erreur en mètres ne se comparent pas. 7

AUC de succès Aire sous la courbe de succès en suivi d'objet (protocole OPE, one-pass evaluation) : part des images où l'IoU dépasse un seuil, moyennée sur les seuils ; de 0 à 1, ou en %, plus haut = mieux. Valeurs du corpus, souvent lues sur des figures : SiamAPN++ 56,0 sur UAV20L et 58,0 sur UAV123@10fps (Cao et al., 2021a, Fig. 4)[PP]; TCTrack 58,2 sur UAVTrack112_L (Cao et al., 2022, §4.2)[PP]; MDNet 46,4 sur UAVDT-SOT à 0,28 FPS sur CPU (Du et al., 2018, §3.3)[PP]. Piège : jeu et séquences différents d'un article à l'autre, et vitesse mesurée sur un PC avant tout test en vol. 7

DAC-SDC Design Automation Conference System Design Contest : concours de détection d'un objet par image (jeu DJI-UAV) sur plateformes imposées. Le score combine l'IoU et l'énergie, score = IoU $\times$ (1 + ES), avec une énergie logarithmique à base différente pour FPGA et GPU (Xu et al., 2021, Éq. 3–6), et des seuils d'IoU 0,7 et de 30 FPS à partir de 2021 (Zhang et al., 2024, §2.3, Éq. 3–4). La puissance est mesurée au wattmètre sur la carte FPGA, par les capteurs internes sur TX2 (Xu et al., 2021, §2.3). Chiffres propres au concours (IoU mono-objet, FPS qui exclut le chargement depuis 2022) : jamais directement comparables à des résultats sur VisDrone. 2, 3, 5, 9, 10, 12

F1 Moyenne harmonique de la précision P et du rappel R : $F_1 = 2PR/(P+R)$, de 0 à 1 (ou en %), plus haut = mieux ; dépend du seuil de décision. Deux F1 du corpus ne se comparent pas : 74,2 sur Drone-vs-Bird à IoU 0,5 pour une soustraction de fond (Seidaliyeva et al., 2020, Table 1) ; 76,01 (infrarouge) et 78,49 (visible) en moyenne sur des intervalles de distance, et 93,23 pour un classifieur audio sur un autre jeu (Svanstrom et al., 2020, §VI). 3, 8

FLOPs Nombre d'opérations flottantes d'une inférence (GFLOPs : milliards) ; plus bas = mieux. Mesure de coût théorique, pas de latence : la convolution creuse de YOLOv7-Drone réduit les GFLOPs sans gain sur GPU dense, et le modèle final reste à 144,6 GFLOPs (Fu et al., 2023, Table 5). Ils dépendent de la résolution : TPH-YOLOv5 compte 556,6 GFLOPs à 25 FPS sur UAVDT (entrée 1024) et 315,4 à 7,4 FPS sur VisDrone (entrée 1536) (Zhao et al., 2023, Tables 5–6). L'élagage de 30 % de LCAM-YOLOX baisse de 8,45 à 6,31 GFLOPs (Elhence et al., 2025, Table IV). Ne pas confondre FLOPs (nombre) et FLOPS (débit). 4, 11

FPS Images (frames) traitées par seconde ; plus haut = mieux. Ce n'est pas l'inverse de la latence dès que le calcul est pipeliné, groupé ou multi-fil : YOLOv4 sur ZCU104 passe de 9,2 à 17,9 FPS avec quatre fils (latence de bout en bout de 107,94 ms avec un seul) (Nguyen et al., 2024, Tables 12–13). Pièges : FPS de l'accélérateur seul ou de la chaîne (208,69 FPS pour le cœur, environ 30 en streaming caméra, avec 32,2 ms de prétraitement et 25,8 ms de post-traitement sur l'ARM (Calì et al., 2025, Table 10, §4.4)) ; règle du concours (le FPS de DAC-SDC 2022 exclut le chargement des images : 2 020,6 en 2022 contre 299,3 en 2021 (Zhang et al., 2024, Tables 5–6, §2.3)) ; lot (voir ce terme) ; résolution d'entrée ; jeu d'images. Un FPS mesuré sur une vidéo de test n'est pas celui d'un flux de caméra. 2–11

FPS/W Débit par watt, FPS/P, soit des images par joule ; son inverse est l'énergie par image. Plus haut = mieux. N'a de sens qu'à portée de puissance égale (colonne `power_scope` : puce,

carte, estimée, non précisée). Calculs faits à partir de valeurs publiées *(déduit)*: YOLOv8n INT8 sur Orin NX, 65,83 FPS pour 10,305 W, soit 6,4 FPS/W, contre 6,0 sur Orin Nano (44,9 FPS pour 7,483 W), puissances de télémétrie (Rey et al., 2025, Table 4) ; SkyNet, 5,0 FPS/W sur TX2 et 3,5 sur Ultra96, portées non décrites, FPGA en lot de 4 (Zhang et al., 2019b, Tables 5–6)[PP]; SEUer 2022, environ 1 430 FPS/W sur ZU3 (1,413 W), mais avec un FPS qui exclut le chargement des images (Zhang et al., 2024, Table 6). Un FPS/W de MCU (Tiny-PULP-Dronet : 89 FPS pour 34 mW sur la puce, soit environ 2 600 FPS/W *(déduit)* (Lamberti et al., 2024, §III-A)[PP]) ne se compare pas à celui d'un détecteur : le réseau de collision et un YOLO n'ont pas la même tâche. 5

Gamme de puissance Ordre de grandeur de la puissance d'un résultat : *nano* (GAP8, MCU, ASIC, du mW à quelques centaines de mW), *FPGA* (SoC Zynq ou Kria, de 1 à 30 W selon la carte), *Jetson* (environ 10 W). Exemples : Navion à 24 mW sur la puce, 2 mW à 20 FPS (Suleiman et al., 2019, §V-A, §V-D) ; le Zynq-7020 de Calì et al., 2,12 à 2,55 W à la carte (Calì et al., 2025, Table 9) ; YOLOv8n sur Orin Nano, 7,5 W (Rey et al., 2025, Table 4). Trois ordres de grandeur séparent les gammes, mais aussi la tâche : navigation en niveaux de gris d'un côté, détection 640×640 de l'autre *(déduit)*. 0, 1, 5–9, 11, 12

GOPS Giga-opérations par seconde, débit de calcul ; plus haut = mieux (GOP : nombre d'opérations d'une inférence, propriété du modèle). Pour un réseau, GOPS = GOP × FPS. Pièges : 1 MAC compte pour 2 opérations [hors corpus], convention pas toujours rappelée ; crête contre débit effectif (GAP9 annonce 15,6 GOPS en DSP et 32,2 GMAC/s en apprentissage automatique (Müller et al., 2024, §2.1)[PP], sans détecteur derrière) ; GOPS sans FPS. DAC-SDC 2022 : 808,2 GOPS pour SEUer et 906,5 pour Ultrateam (Zhang et al., 2024, Table 6), mais avec un FPS qui exclut le chargement des images ; SATAY, 1 244 GOPS pour YOLOv8s sur VCU118, à 57,4 W de portée non décrite (Montgomerie-Corcoran et al., 2023, Table III). 5, 6

IoU Intersection over Union (indice de Jaccard) entre une boîte prédite A et une boîte de référence B : IoU $= |A \cap B|/|A \cup B|$, de 0 à 1, plus haut = mieux. Sert de seuil pour décider qu'une détection est juste (AP, mAP), et le seuil change d'un article à l'autre : 0,5 le plus souvent, 0,25 pour un YOLOv4 sur ZCU104 (Nguyen et al., 2024, Table 11), 0,1 en contre-drone (Liu et al., 2024, Table II)[PP], 0,7 pour l'AP de UAVDT (Du et al., 2018, §3.1)[PP]. Employée seule comme précision, l'IoU n'est pas comparable à une mAP (voir l'IoU moyen de DAC-SDC). 2, 3, 5, 7, 8

IoU moyen (DAC-SDC) Métrique du concours DAC-SDC : IoU moyen sur le jeu de test, avec un seul objet par image et sans tenir compte de la classe (Zhang et al., 2024, §2.3). Dans la base, les valeurs vont de 0,492 (SystemsETHZ 2018) à 0,731 (SkyNet 2020) (Zhang et al., 2024, Tables 2 et 4). Un IoU de 0,70 n'est pas une mAP de 70 : pas de classes, pas de seuil, pas d'images à plusieurs objets. Les objets occupent le plus souvent 1 à 2 % de l'image 640×360 (Zhang et al., 2024, §2.1). Le score du concours combine cet IoU avec l'énergie (voir DAC-SDC). Le même SkyNet donne 0,731 sur TX2 et 0,716 sur Ultra96 (Zhang et al., 2019b, Tables 5–6)[PP]. 3

Lot (batch) Nombre d'images traitées ensemble. Un débit en lot cache la latence par image : les 25,05 FPS de SkyNet sur Ultra96 sont obtenus en lot de 4, sans latence par image rapportée (Zhang et al., 2019b, §6.4)[PP]. Un lot de 1 est la bonne hypothèse pour un drone qui traite chaque image à l'arrivée : Drone-YOLO mesure sur une vidéo HD à lot 1 (Zhang, 2023, §5.2), tandis que la Table 4 de l'étude Jetson et Raspberry Pi 5 ne donne pas le lot (Rey et al., 2025, Table 4). 5, 10

MAC Multiply-ACcumulate : une multiplication suivie d'une addition, opération de base d'un réseau (MMAC : millions ; GMAC/s : débit). 1 MAC = 2 opérations dans la convention des GOPS [hors corpus]. Coût des modèles de nano-drone : PULP-Frontnet de 4,0 à 14,1 MMAC par image (Palossi et al., 2021, Table II)[PP]. Débit de la puce : GAP8 annonce 10 GMAC/s à 90 MHz (Abstract) contre 9,2 à 100 MHz en 8×8 bits (Flamand et al., 2018, Table I) ; MAX78000, 107 MAC par cycle (Moosmann et al., 2023, §III). Des MAC sans mesure de latence ne disent pas si le réseau tient dans le budget de vol. 6, 10

MAE de pose Mean Absolute Error : moyenne des valeurs absolues des erreurs, en unité de la grandeur (degrés pour un lacet, mètres pour une position) ; plus bas = mieux. Adaptation de domaine sur GAP8 : 13,1° de MAE de lacet sur des portes réelles pour un CNN de 6 M de paramètres, à 32,8 FPS et 30,4 ms (Carlotti et al., 2026, Table I)[PP]. Un angle moyen ne dit pas la

distribution des erreurs, qui compte pour le franchissement d'une porte *(déduit)*. 6

mAP mean Average Precision : moyenne des AP par classe ; plus haut = mieux. Sans seuil précisé, la valeur ne se lit pas. Cas du corpus : « mAP COCO » sans seuil (YOLOv8n à 31, YOLOv8s à 39, YOLOv8m à 44, quel que soit le Jetson, 32 sur Raspberry Pi 5 avec Hailo-8) (Alqahtani et al., 2024, §IV-C)[PP]; une astérisque sur la mAP COCO de SATAY non extraite du PDF (Montgomerie-Corcoran et al., 2023, Table III), alors que sa Table IV est en mAP50 ; « mAP (IoU n/r) » chez Elhence et al. (Elhence et al., 2025, §V-A) et dans BlankSkip (Marra et al., 2026, Table 2)[PP]. Autres pièges : jeu propre (voir mAP50-95), jeu restreint à quelques classes (3 classes de VOC, 3 objets au plus par image, pour TinyissimoYOLO (Moosmann et al., 2023, §I)), mesure sur GPU et non sur la cible embarquée. 2–8, 10, 11

mAP@0,25 mAP au seuil d'IoU 0,25, choisie par Nguyen et al. pour de petits objets volants (Nguyen et al., 2024, §3.5). YOLOv4 passe de 90,37 en FP32 à 83,70 en INT8 sur ZCU104, YOLOv4-tiny de 78,50 à 72,24 (Nguyen et al., 2024, Table 11). Jeu propre (2 000 images de test), seuil plus lâche que la mAP50 : aucune comparaison avec une mAP@0,5 publiée. 5

mAP50 mAP au seuil d'IoU 0,5 (notée aussi mAP@0.5, mAP@0,5, mAP@50). Elle est plus indulgente que la mAP50-95 sur la localisation : les deux ne se comparent pas. Pièges illustrés par VisDrone : test contre val (Drone-YOLO nano, 31,0 en test et 38,1 en val (Zhang, 2023, Tables 4–5)) ; classe unique (17,68 pour la seule classe *car* de VisDrone-DET, sur Zynq-7020 (Calì et al., 2025, Table 9)) ; jeu propre à une cible (93,6 pour YOLOv4 sur un jeu de drones des auteurs, sur GPU (Liu et al., 2021, Table 4)) ; résolution et split (55,3 en val avec une entrée de 1280 (Bellec, 2026, Table 4)[PP] contre 31,7 à 45,7 pour GCL-YOLO sur VisDrone-DET2021, split non précisé (Cao et al., 2023, Table 3)). 2–5, 8

mAP50-95 mAP moyennée sur les seuils d'IoU de 0,50 à 0,95 par pas de 0,05 (notée aussi mAP@[.5:.95], mAP@0.5:0.95 ; l'« AP » de COCO). Plus basse que la mAP50 sur le même modèle. Piège du jeu propre à une cible : YOLOv8n atteint 84,22 (FP32) puis 71,90 (INT8) sur Jetson Orin Nano, dans une salle avec un seul TurtleBot (Rey et al., 2025, Table 4), alors que le même type de modèle, modifié pour le DPU, tombe à 26 sur COCO et monte à 66 sur un jeu de personnes (Karki et al., 2026, Table II)[PP]. Sur VisDrone, test-dev et test-challenge diffèrent : un ensemble de cinq TPH-YOLOv5 donne 37,32 en test-dev et 39,18 en test-challenge (Zhu et al., 2021, §4.2, Table 3)[PP]. 5, 8

SA / mSA State Accuracy d'Anti-UAV : IoU sur les images où la cible est visible, et score de l'absence prédite sinon, moyenné par séquence puis sur le jeu (mSA) (Jiang et al., 2021, §III-E)[PP]; plus haut = mieux. Elle intègre la disparition de la cible, contrairement à l'AUC de succès. Exemples : SiamRCNN à 74,33 en validation infrarouge et 65,41 en test, KCF à 32,88 (Jiang et al., 2021, Tables III–IV)[PP]; SiamDT à 68,19 en test et 71,65 en validation sur Anti-UAV410, la validation étant optimiste puisque tirée des mêmes séquences que l'entraînement (Huang et al., 2024, §V-B). Jeu de contre-drone filmé du sol : métrique reprise, non contribution embarquée. 3

Portée de la puissance Ce que la puissance rapportée englobe, notée dans `power_scope` : *board* (carte entière au wattmètre), *chip* (rails ou télémétrie, par exemple `tegrastats`), *estimated* (outil de conception), *unspecified*. Dans la base, 247 lignes sur 352 n'ont aucune puissance. Deux puissances de portées différentes ne se comparent pas : 10,305 W de télémétrie sur Orin NX (Rey et al., 2025, Table 4), 13,20 W à la carte sur ZCU104 contre 9,72 sur KV260 (Elhence et al., 2025, §V-D), 16,1 W au repos à la prise sur un autre ZCU104 (Nguyen et al., 2024, §5.3), 34 mW sur la puce GAP8 pour Tiny-PULP-Dronet (Lamberti et al., 2024, §III)[PP] et 64 mW pour la carte de DroNet (Palossi et al., 2018, §VII)[PP]: ni le réseau ni la portée ne sont les mêmes. 0, 2, 5, 6, 9–11

PSNR Peak Signal-to-Noise Ratio : $10\log_{10}(\mathrm{MAX}^2/\mathrm{MSE})$, en dB, plus haut = mieux. Pour un rendu NeRF, mesure l'écart à l'image de référence. Tiny-DroNeRF : 26,94 dB sur des images de 160 pixels de côté, 5,7 dB sous Instant-NGP sur 800 pixels (Carboni et al., 2026, Table I)[PP], et 21,2 dB sur des données réelles de nano-drone (Carboni et al., 2026, §V-D)[PP]. Comparer deux PSNR suppose même résolution, même jeu et même nombre de vues. 6

RMSE de position Racine de l'erreur quadratique moyenne de position, en mètres ; plus bas = mieux, et très sensible aux écarts extrêmes. NGPS : 2,94 m sur cinq vols de 60 à 150 m, avec

2,6 FPS (Sharma, 2026, §IV-B)[PP]. Suivi de plusieurs MAV en simulation : environ 1,4 m (Zheng et al., 2023, §VI-C.3). La vérité terrain (capture de mouvement, GNSS, simulation) change d'un article à l'autre. 7

Taux de détection Part des images (ou des essais) où une détection valide est produite. Défini par chaque article, il n'est pas un rappel : NOVA donne 98,6 % en milieu urbain contre 93,1 % dans le scénario surélevé, en essais de terrain (Saviolo and Loianno, 2025, §V-E)[PP]; SCOUT, 92,2 % d'images avec détection valide en vol, sur une séquence de 104,5 s (Yousuf et al., 2026, Table III)[PP]. Ni l'un ni l'autre ne donne de faux positifs ni d'IoU *(déduit)*. 6, 7

Vitesse sûre Vitesse maximale à laquelle le drone peut encore s'arrêter avant un obstacle détecté à la distance d : $v = a_{\max}(\sqrt{T^2 + 2d/a_{\max}} - T)$, avec T la latence de perception à action et $a_{\max}$ l'accélération maximale (Krishnan et al., 2020, Éq. 3, §2.3). Plus haut = mieux. Le modèle F-1 en tire un roofline : l'erreur du modèle sur la vitesse sûre est de 5 à 10 %, et il surestime toujours (Krishnan et al., 2022, §IV)[PP]; alléger le dissipateur la relève de 75 % et doubler le calculateur la baisse de 33 % (Krishnan et al., 2022, §VI)[PP]. Les papiers YOLO et FPGA du corpus ne la mesurent pas *(déduit)*. 7, 9, 11, 12

BRAM Block RAM : mémoire embarquée du FPGA, en blocs de 18 ou 36 Kbit [hors corpus]; elle borne la taille des poids et des tampons en place. Unités non homogènes : 138 blocs pour YOLOv3-tiny réduit sur Zynq-7020 (Calì et al., 2025, Table 9) ; SATAY, pour YOLOv8s, 2 782,5 sur VCU110 et 661 sur VCU118 (Montgomerie-Corcoran et al., 2023, Table III), sans unité précisée dans la base ; Zhang et al. donnent la BRAM en Mo (Zhang et al., 2024, Tables 2–6). Ramener à des kbit avant de comparer. 5, 11

DSP Bloc de traitement du signal d'un FPGA : multiplieur-accumulateur câblé ; avec les LUT et la BRAM, il borne le parallélisme d'un accélérateur. DAC-SDC sur Zynq-7020 : 220 DSP pour TGIIF 2018 et 172 pour SystemsETHZ, contre 263 à 360 sur ZU3 entre 2019 et 2022 (Zhang et al., 2024, Tables 2–6) ; YOLOv3-tiny réduit : 204 DSP (Calì et al., 2025, Table 9). Un Zynq-7020 en compte 220 [constructeur, hors corpus] : TGIIF les emploie tous. Zhang et al. normalisent le FPS au prorata des DSP, approximation maison (Zhang et al., 2024, §4.4). La quantification change l'usage d'un DSP (plusieurs MAC INT8 par bloc [hors corpus]). 5, 6

W Watt, unité de puissance. Gamme FPGA et Jetson : 1,413 W pour SEUer sur ZU3 (carte) (Zhang et al., 2024, Table 6), 13,5 W pour SkyNet sur TX2 (portée non décrite) (Zhang et al., 2019b, Table 5)[PP]. À donner avec sa portée. 0–2, 5–12

mW Milliwatt (10^{-3} W) : unité de la gamme nano. GAP8 : 15 mW pour CIFAR-10 (Flamand et al., 2018, §IV), 34 mW pour Tiny-PULP-Dronet sur la puce (Lamberti et al., 2024, §III)[PP], 86,6 mW pour PULP-Frontnet (Palossi et al., 2021, §V-B)[PP]. 0–2, 6, 7, 10, 12

J Joule, unité d'énergie ($1\,\mathrm{J} = 1\,\mathrm{W} \cdot \mathrm{s}$). 0,179 J par image pour YOLOv8n INT8 sur Orin NX (Rey et al., 2025, Table 4). 9

mJ Millijoule (10^{-3} J). SATAY : 317 mJ par image sur ZCU104 contre 277 sur TX2 pour YOLOv5n en 640×640 (Montgomerie-Corcoran et al., 2023, Table IV) ; 6,1 mJ pour Apollo4b contre 196 μJ pour MAX78000 (Moosmann et al., 2023, §III). 6, 10

µJ Microjoule (10^{-6} J), énergie par inférence des MCU et du neuromorphique : 10 μJ pour GAP8 (Flamand et al., 2018, §IV), 27 μJ pour un réseau sur Loihi (Paredes-Vallés et al., 2023, Abstract)[PP]. 6, 10

s Seconde. Unité des temps d'entraînement ou de cycle d'une mission, par exemple 4,1 s pour rendre une image 160×160 (simulation) (Carboni et al., 2026, §V-C)[PP]. 6, 8, 9

ms Milliseconde (10^{-3} s), unité de latence : 5,5 ms pour TinyissimoYOLO sur MAX78000, 359 ms sur STM32H7A3 (Moosmann et al., 2023, §III). À situer : inférence seule ou chaîne. 4–10

Hz Hertz, fréquence ($1\,\mathrm{Hz} = 1\,\mathrm{s}^{-1}$). Pour une boucle de contrôle, c'est l'inverse de la période, comme le FPS pour une caméra : action à 19,74 Hz et sémantique à 6,67 Hz pour LiteVLA-H (williams et al., 2026, §6.1)[PP], caméra à 30 Hz contre 120 Hz de pilotes humains (Kaufmann et al., 2023, Discussion). 6, 7, 9

MHz Mégahertz, fréquence d'horloge. Le débit d'un même réseau dépend du point de fonctionnement : Tiny-PULP-Dronet à 89 FPS avec le contrôleur à 50 MHz, 160 FPS à 250 MHz (Lamberti et al.,

2024, §III-B)[PP]; DPU à 300 MHz sur Zynq UltraScale+ (Elhence et al., 2025, §V-D). 6

Mo Méga-octet (10^6 octets, « MB » dans les articles). Le réseau de proximité de PULP-Frontnet compte 6 116 Ko, soit environ 6,1 Mo (Palossi et al., 2021, Table II)[PP]. La BRAM d'un FPGA se donne parfois en Mo (Zhang et al., 2024, Tables 2–6). 4, 9